

1 连续动作空间下基于投影式安全盾的可证明 COLREGs 方向合规无人船避碰

2 **WeiYu Tang**

3 Graduate Research Assistant

4 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

5 School of Naval Architecture, Ocean and Civil Engineering

6 Shanghai Jiao Tong University, Shanghai, 200240, China

7 Email: weiyutang@sjtu.edu.cn

8 **Jie Xue, Ph.D.***

9 Assistant Research Professor

10 State Key Laboratory of Ocean Engineering

11 School of Naval Architecture, Ocean and Civil Engineering

12 Shanghai Jiao Tong University, Shanghai, 200240, China

13 Email: j.xue@sjtu.edu.cn

14 **Peijie Yang**

15 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

16 School of Naval Architecture, Ocean and Civil Engineering

17 Shanghai Jiao Tong University, Shanghai, 200240, China

18 Email: yangpeijie21@sjtu.edu.cn

19 **Qianbing Li**

20 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

21 School of Naval Architecture, Ocean and Civil Engineering

22 Shanghai Jiao Tong University, Shanghai, 200240, China

23 Email: qianbing_li@sjtu.edu.cn

24 Total Number of Pages: 【待填】

25 Submitted [Submission Date]

26 *Corresponding Author

1 Abstract

2 Objectives : 本文旨在为自主水面航行器的避碰控制建立一种在连续控制量上逐步成
3 立的《国际海上避碰规则》方向合规保证, 并界定其适用范围。该规则的让路条款具有方
4 向性: 未碰撞但从错误一侧通过的航迹仍属违规。

5 Methods : 我们把让路条款表述为控制量平面上的半平面约束, 与执行器量程及单步
6 无碰条件求交, 得到凸的安全控制集, 并以一个二维二次规划把策略输出投影到该集合的
7 最近可行点; 该投影并入环境转移, 使策略在训练中即适应修正。数据为公开的双船会遇
8 仿真场景库, 共 2000 个算例; 官方划分为 1400 训练 / 600 测试, 我们把官方训练侧再切
9 为 1300 训练与 100 验证。共设 9 种对照配置构成单变量递进序列, 每种以 8 个固定种子
10 训练。

11 Findings : 在投影可行的每一让路决策步上, 方向合规由硬约束构造式成立, 与训练
12 结果及随机种子无关; 转入兜底的步不在此列。测试集上每局违规次数为【待填】、碰撞
13 率为【待填】、到达率为【待填】; 到达率不作为效能主张。

14 Novelty : 据我们所知, 这是首个在连续控制量上实现该规则方向合规的投影式安全
15 机制, 并给出分级的保证陈述, 逐条附假设与边界, 且列出未被证明的部分。

16 Practical Applications : 该机制的合规判定不依赖训练结果, 可作为既有控制系统之上
17 的合规校验层, 用于功能验证与责任界定, 其保证只覆盖投影可行的让路步。在线计算量
18 为每步一个二维二次规划, 无需加速硬件即可实时运行。

19 Keywords : COLREGs 合规; 安全强化学习; 投影式安全盾; 连续动作空间; 二次规划
20 ; 无人水面航行器

1. Introduction

两船在海上相遇，各自向右转向，安全交错而过。这一幕之所以有效，靠的不是任何一方的临场判断，而是一套双方都遵守、并且都知道对方会遵守的规则。当船上没有人时，这种可预期性就成了必须被兑现的技术指标——海事责任认定不只看有没有撞上，还看船舶是否按规则行动，一次未发生碰撞却从错误一侧通过的会遇在事故调查中依然是违规操作。

无人水面航行器的避碰必须遵守《国际海上避碰规则》(IMO 1972)。与陆上交通规则相比，该规则集有一处决定性的不同，即让路条款具有**方向性**：对遇时两船各自向右转向，交叉时让路船向右避让、直航船保向保速，追越时追越船负责让清。因此一个动作即使在几何上避开了碰撞，若转向方向违反规则仍属违规。这使合规无法用最终有没有撞上来验证，也使它成为安全强化学习中并不常见的一类问题——需要保证的不是某个状态量的界，而是每一步动作落在哪个方向的半平面里。

现有工作沿两条路径推进，各自放弃了一项关键属性。第一条是离散动作加动作屏蔽，把动作空间离散成有限网格，每步先用规则状态机算出合规子集再屏蔽其余 (Krasowski and Althoff 2024)；合规因而可证，且不依赖训练结果与随机种子，代价是放弃连续控制，量化既引入抖动，又把控制精度锁死在网格分辨率上。对本文的任务还有一处更具体的损失：规则要求让路转向足够明显，这在数学上是一个下确界，而网格取不到它，只能退到最近的档位，于是每一次合规让路都要比规则所需多转一些。第二条是连续动作加软性奖励，把规则写成奖励里的一项惩罚 (Meyer et al. 2020; Heiberg et al. 2022; Müller et al. 2026)；控制虽然连续了，保证却随之消失，因为奖励只能塑造期望行为，不能排除任何一个具体的违规动作。

于是连续动作 $\cap$ 可证明方向合规 $\cap$ COLREGs 这个三重交集是空的。本文用投影式安全盾把它填上：规则状态机给出合规方向的半平面，与单步无碰约束、动作箱一起构成安全动作集，二次规划把策略的连续指令投影到该集合上最近的点。关键在于**可枚举**这一前提可以被**可投影**替代，而投影解满足硬约束是构造式的，与训练无关。策略以安全盾在环的方式训练，因而会适应投影带来的修正。

这类工作的难点不只在机制本身，还在于界定清楚所证明的内容。安全强化学习文献中“provable”一词覆盖的作用域并不总与读者的默认预期一致，因此本文的第二项工作是把可证明层逐条分档，每一档附完整假设与作用域限制，并写明哪些部分没有被证明。

贡献。

1. 连续动作空间中的投影式 COLREGs 安全盾（第 4.2 节）。合规方向作为硬区间约束进入二次规划，故每一个投影可行的让路步的方向合规由构造成立，不依赖训练结果、不受种子方差影响。
2. 一个分级的安全性陈述（第 4.4 节）。远场单步无碰为严格结论，每一让路步的方向合规由构造成立，紧急迫近不可避给出只漏报不误报的充分条件证书；在此之上证明该证书定义的可清障集在理想模型下控制不变，并据此设计后备机动的终端约束——该路径的闭环验证尚未完成。
3. 一个把机制逐级拆开的实验设计（第 5.1 节）。9 种配置构成一条连通的单变量递进序列，相邻两级只改一个变量，其中两跳带有不可分割的伴随变量并在表注中列出；另行构造真冲突算例，用以激活并检验只在极端态势下才启用的兜底链与终端约束。

2. Related Work

2.1 海事避碰与 COLREGs 合规

规则合规的研究最早集中在模型驱动的方法上。速度障碍法用相对速度锥判断碰撞危险并选出规避速度，后被纳入 COLREGs 的让路语义 (Kuwata et al. 2014) 并推广到一般的船舶会遇 (Huang et al. 2019)；模型预测控制在有限预测时域上评估各候选机动的碰撞危险与合规度并择优 (Johansen et al. 2016)，其分支航向变体经过海上实测 (Eriksen et al. 2019) 与全尺度验证 (Kufalor et al. 2020)，更早的协议式方法则把规则写成船间可协商的行为约定 (Benjamin et al. 2006)。近期这条线转向控制障碍函数与凸优化 (Lee et al. 2025; Patil et al. 2026)，多建立在标准船舶操纵模型之上 (Fossen 2011)。它们的保证来自显式约束，但控制律由手工设计，不含从数据中学到的策略。

深度强化学习出现后，避碰策略开始从数据中学习 (Sarhadi et al. 2022)。多数工作把操纵指令离散化，如以有限档舵角在受限水域完成多船避碰 (Shen et al. 2019)，或面向多船生成合规的规避时机与路径 (Zhao and Roh 2019; Chun et al. 2021)；离散化便于优化，代价是控制精度受网格分辨率限制。另一类保留连续控制，把 COLREGs 写成随方位与距离衰减的软性惩罚 (Meyer et al. 2020)，或做成可调的风险门控 (Heiberg et al. 2022)，亦有工作在欠驱动无人艇上验证简洁的强化学习避障 (Cheng and Zhang 2018)。这类工作多以近端策略优化 (Schulman et al. 2017) 为主干，可用有界的 Beta 分布 (Chou et al. 2017) 参数化连续动作以避开高斯策略在动作边界处的截断偏差。它们保住了控制精度，但合规只由奖励诱导，无法排除任何一个具体的违规动作。

TABLE 1 相关工作在四个维度上的定位

代表工作	动作空间	合规施加方式	逐步硬保证	含学习
(Kuwata et al. 2014)	连续	速度障碍几何构造	几何充分条件	—
(Johansen et al. 2016)	离散分支	代价函数择优	—	—
(Lee et al. 2025; Patil et al. 2026)	连续	控制障碍函数 / 凸优化	状态量	—
(Meyer et al. 2020)	连续	软性奖励	—	✓
(Heiberg et al. 2022)	连续	软性奖励 + 风险门控	—	✓
(Müller et al. 2026)	连续	软性奖励 + 证伪训练	—	✓
(Alshiekh et al. 2018)	离散	动作屏蔽	状态量	✓
(Dalal et al. 2018)	连续	线性化后投影	状态量	✓
(Vaaler et al. 2024)	连续	预测式安全滤波	仅碰撞	✓
(Krasowski and Althoff 2024)	离散 (49 点)	动作屏蔽	方向合规	✓
本文	连续	投影 (二次规划)	方向合规	✓

表注。“逐步硬保证”指该方法在**每一个决策步**上能排除掉哪一类动作，而非期望意义下的约束满足；前三行为非学习方法。本文与 (Krasowski and Althoff 2024) 只差动作空间一列。

2.2 安全强化学习与可证明合规

安全强化学习 (García and Fernández 2015) 研究如何为学习策略附加硬性保证，以形式化方法给出保证的一支已有系统的梳理与基准比较 (Krasowski et al. 2023)。把安全写成约束马尔可夫决策过程并以拉格朗日方法求解是常见路线，但它保证的是期望意义下的约束满足，仍不能排除任何一个具体的违规动作。动作屏蔽在离散动作上按时序逻辑

1 规范剔除不安全动作 (Alshiekh et al. 2018), 其可实现形式已被推广到连续动作空间, 但
 2 针对通用任务、未涉及海事规则 (Kim et al. 2024)。在连续控制上, 控制障碍函数的二次
 3 规划 (Ames et al. 2019) 与预测式安全滤波 (Wabersich and Zeilinger 2021) 提供逐步硬保证
 4 , 后者也被接到海事强化学习之上, 但只约束碰撞、不含 COLREGs 的方向条款 (Vaaler et
 5 al. 2024)。与本文机制最接近的是安全层方法, 它把约束在当前状态处线性化, 再把策略
 6 动作解析地投影到由此得到的线性半空间上 (Dalal et al. 2018); 本文的投影与之同源, 新
 7 增的部分是把让路条款的方向性编码为动作平面上的半平面, 使被强制的对象由状态约束
 8 变为规则合规。

9 表 1 汇总了上述工作在四个维度上的定位, 由此可见一处结构性空缺。海事场景
 10 中规则合规的硬保证此前只在离散动作空间上实现过 (Krasowski and Althoff 2024), 该工
 11 作也提供了本文使用的场景库与状态机阈值, 并把连续动作下的动作投影列为未来方向
 12 (Kochdumper et al. 2023); 沿该方向的后续工作虽转入连续动作, 却以软性奖励逼近合规
 13 , 没有给出硬保证 (Müller et al. 2026)。本文在连续控制上给出方向合规的构造式保证,
 14 并以 zonotope 加二次规划投影 (Markgraf et al. 2026) 替代多项式 zonotope 表示以降低单步
 15 求解开销。

16 方向约束会在紧急与近域收紧可行动作集, 可能损失终端效率, 本文因此用势函
 17 数型塑形帮助策略追回效率。势函数型塑形不改变最优策略集 (Ng et al. 1999), 但朴素
 18 的距离型塑形容易停在目标附近 (Trott et al. 2019), 单一连续势也难以根治 (Müller and
 19 Kudenko 2025), 故本文改用线性核并把真正到达设为终端条件 (De Lellis et al. 2024)。安
 20 全盾对性能与终端行为的影响另有专门研究, 训练中纳入滤波并惩罚修正量可提升样本效
 21 率 (Pizarro Bejarano et al. 2025), 足够宽松的滤波不损渐近最优 (Oh et al. 2025), 而安全
 22 项与目标项对冲会造成目标前停滞 (Grover et al. 2022)。

23 3. Problem Formulation and Environment Modeling

24 3.1 运动学模型

25 全文所用记号汇总于表 2。角度一律折算到 $(-\pi, \pi]$, 并约定右舷为正、左舷为负
 26 , 故转艏率 $\omega < 0$ 表示右转。

27 受控船舶建模为受偏航约束的质点, 状态 $s = [p_x, p_y, \theta, v]^\top \in \mathbb{R}^4$, 以纵向加速度 a
 28 与转艏率 ω 为控制输入:

$$\dot{s} = [v \cos \theta, v \sin \theta, \omega, a]^\top, \quad u = [a, \omega]^\top, \quad (1)$$

29 控制受箱约束 $|a| \leq a_{\max}$ 、 $|\omega| \leq \omega_{\max}$, 航速受 $0 \leq v \leq v_{\max}$ 限制, 决策以零阶保持方
 30 式每 Δt 施加一次。航速界在整个决策步积分完成之后才施加, 故步内航速可短暂超出
 31 $v_{\max}$; 单步位移界因此必须计入步内加速, 取 $v_{\max} \Delta t + \frac{1}{2} a_{\max} \Delta t^2$, 步末航速上界 v_{bnd} 由
 32 $v_{\max} + a_{\max} \Delta t$ 给出。安全盾内部用于验证后备机动的积分则在积分过程中即施加饱和, 是
 33 更保守的模型; 全文凡涉及单步位移界的推导一律取前者。

34 选择这一模型层级出于两点考虑。其一, COLREGs 的让路条款规定的正是航向与
 35 航速的变化, 而式 (1) 把两者直接作为控制输入, 规则因而可以不经中间变量地写成对 u
 36 的约束, 这是本文全部安全机制得以落在动作空间里的前提。其二, 更精细的水动力模型
 37 会引入依船而异、难以辨识的系数, 使规则约束与船型参数纠缠, 反而削弱结论的普适性
 38 。本文亦不建模风、流、浪等环境扰动。

39 建模对象与占据表示。我们以一条大型集装箱船为对象, 船长 175 m、船宽
 40 25.4 m。纵向加速度上限取 0.24 m/s^2 , 转艏率上限取 0.03 rad/s , 航速上限取 9.5 m/s

TABLE 2 符号表

符号	含义	符号	含义	符号	含义
s	本船状态向量	ρ	会遇态势 (ρ_0 – ρ_5)	θ, v	艏向、航速
$U_{\text{colregs}}(\rho)$	规则允许的控制集	$u = (a, \omega)$	控制 (加速度, 转艏率)	$U_{\text{cf}}(s)$	无碰撞约束集
a, ω	纵向加速度、转艏率	U_{box}	执行器物理量程箱	Δt	决策周期
$U_{\text{safe}}(s, \rho)$	安全动作集	$a_{\text{max}}, \omega_{\text{max}}$	执行器量程上限	$\Pi_{U_{\text{safe}}}$	向 U_{safe} 的欧氏投影
$a_{\text{op}}, \omega_{\text{op}}$	策略动作箱半宽	$u_{\text{policy}}, u_{\text{safe}}$	策略输出、执行控制	v_{max}	航速上限
Δ_{lt}	明显转向阈值	v_{bnd}	步内航速上界	Δ_{nt}	直航容差角
$\oplus$	Minkowski 和	T_M	机动段时长	$\text{disk}(r)$	半径 r 的闭圆盘
ω_{turn}	合规转艏率下确界	$R_{\text{circ}}, r_{\text{insc}}$	外接圆、内切圆半径	$\varepsilon_a, \varepsilon_\omega$	直航保速、保向容差
O	他船占据	T_h, T_{pred}	碰撞可能、紧急预测时域	d	两船中心距
$R_{\text{box}}(t)$	可达中心过近似集	p_e, p_m	本船/他船中心位置	A_{clr}	可清障集
$v_{\text{obs}, \text{max}}$	他船速度上界 (设)	γ	折扣因子	K	回合步数上限
α, β	Beta 分布形状参数	Φ	势函数 (塑形)	r	单步回报
Δ_{ho}	前扇区半角/对遇带	Δ_{sd}	舷侧扇区外边界	Δ_{ot}	追越带半角
T_{react}	反应时域 (状态机)	r_m	他船膨胀半径 (判态势)	v_ε	速度集半宽
C_m	碰撞锥	V_e	本船速度集	R_m	他船占据圆半径 (含裕)
d_{safe}	无碰撞所需中心距	u_{nom}	线性化基点	p_{nom}	标称落点
J	落点对控制的雅可比	n, δ	分离方向、分离距离	g, h	无碰撞约束系数与右端
A, b	安全集约束矩阵与右端	a_{eff}	速度矢量变化率上界	$B_{\text{lon}}, L_{\text{lat}}$	可达集纵/横向半轴
a_{st}	紧急 stern 模式加速度	d_{ah}	紧急 ahead 目标距离	$\Delta_{\text{ah}}, \Delta_{\text{st}}$	紧急 ahead/stern 判角
ℓ_m	他船船长 (逐场景)	$L \times W$	船体尺度		

1 ; 决策周期取 10 s, 单个回合最多 170 步, 合 1700 s。船体外接圆半径为 88.4 m, 内切
2 圆半径为 12.7 m, 步末航速上界因而为 11.9 m/s。该转艏率上限折合仅约 1.7°/s, 一次
3 20° 的明显转向需十余秒才能完成, **慢于一个决策周期**; 这一“操纵慢于决策”的特征既
4 是安全约束必须前瞻的原因, 也是后文递归可行性得以成立的几何基础。船体占据用矩形
5 表示, 并按用途取两个圆近似。**外接圆** $\text{disk}(R_{\text{circ}})$ 过近似船体, 用于构造“一定不碰”的
6 充分条件; **内切圆** $\text{disk}(r_{\text{insc}})$ 欠近似船体, 用于构造“一定会碰”的充分条件。两个方向
7 各取一个圆, 是两侧结论都单侧保守的关键。他船同样以矩形占据表示, 需要外推时取恒
8 速外推, 该假设的代价在第 4.4 节逐条标注。

9 3.2 观测与动作空间

10 观测为 27 维实向量, 含受控船状态 4 维 (航速、艏向、纵向加速度、转艏率);
11 目标相关 5 维 (距离、剩余步数、艏向与目标朝向区间之差、纵向偏差、横向偏差) 加 1
12 维“是否已在目标框外”的指示位; 交通态势 12 维, 即前/左/右/后四个方位扇区各取
13 该扇区内最近他船的三个量 (距离、相对方位、相邻两个决策步之间的距离增量, 该增量
14 以米为单位、未除以 Δt) ; 终止相关 5 维 (超时、出界、停住、碰撞、到达)。观测层
15 输出原始物理量, 归一化在训练包装层完成。以扇区为单位组织交通信息, 使观测维数不
16 随他船数目改变; 但这只解决了维数问题——本文部署的安全盾按单他船实现, 遇到多于
17 一艘他船时显式报错而非降级运行, 因此多他船既未训练也未评估。

18 动作为二维连续量 $u = (a, \omega)$, 此处需要区分两个箱。策略的动作空间是较窄的**常**
19 **规操作箱** $\{|a| \leq a_{\text{op}}\} \cap \{|\omega| \leq \omega_{\text{op}}\}$, 两轴半宽分别取 0.048 m/s² 与 0.018 rad/s, 恰等于
20 对标工作所用 7 × 7 量化网格的张成范围, 使两种动作空间的控制权限相同、仅分辨率不
21 同; **执行器物理量程箱** $U_{\text{box}} = \{|a| \leq a_{\text{max}}\} \cap \{|\omega| \leq \omega_{\text{max}}\}$ 更宽, 只留给安全盾与紧急控制

器。放宽是必要的。安全盾必须能在需要时动用超出策略权限的操纵能力，否则一旦策略的窄箱与无碰撞约束不相容，本来可解的局面会被误判为不可行。其代价是安全盾实际施加的控制可以落在策略动作箱之外，这一点在观测中如实回传，并在统计动作饱和率时按各自的箱分别计算。

3.3 问题表述

我们考虑开阔水域的双船会遇，并作如下假设：

- (A1) 开阔水域，无航道分隔、无静态障碍、无岸线约束；
- (A2) 场景中有一条受控船与一条他船，均为机动船；
- (A3) 受控船动力学由式 (1) 描述，控制以 Δt 为周期零阶保持；
- (A4) 他船当前状态无量测误差地可得；
- (A5) 会遇初始时刻不存在任何已生效的让路义务。

假设 (A2) 不是为简化而作的让步，而是 COLREGs 本身的适用边界。该规则集是成对制定的，当三船以上同时相遇、且各自的义务互相冲突时（例如对一条船须保向保速、对另一条须避让），公约本身并未规定如何取舍。多他船情形下各结论如何合成、以及在何处必然失效，见第 4.4 节。

令 ρ_t 为 t 时刻的会遇态势， $U_{\text{colregs}}(\rho_t) \subseteq \mathbb{R}^2$ 为该态势下规则允许的控制集合（第 4.1 节给出其形式）， $U_{\text{cf}}(s_t)$ 为无碰撞约束集，所求为一个策略

$$\pi: S \rightarrow \mathbb{R}^2 \quad \text{使得} \quad u_t \in U_{\text{colregs}}(\rho_t) \cap U_{\text{cf}}(s_t) \quad \forall t. \quad (2)$$

式 (2) 与“把合规写进奖励”有本质区别。它要求**每一步执行的动作**都落在集合内，而非要求某个期望值达到最优。

当动作集有限时，式 (2) 有一个直接解法，即枚举全部动作、逐个检验、屏蔽不合规者。这条路要求动作可枚举，因而与连续控制不相容，而船舶的舵与推进本是连续量，量化会同时带来抖动与精度损失。本文的核心思路是把“可枚举”这一前提替换为“可投影”。让路条款在动作空间中恰好表现为半平面约束（第 4.1 节），无碰撞条件可写成线性不等式（第 4.2 节），故式 (2) 的可行集是二维空间中若干半平面与一个矩形之交，为凸多边形；向凸集的投影存在且唯一，可由一个规模极小的二次规划求得。

4. Methodology

本节给出投影式安全盾的构造。我们先把 COLREGs 让路条款形式化为动作空间中的集合约束（第 4.1 节），据此构造安全动作集与投影算子（第 4.2 节）；随后说明策略如何在带盾环境中学习（第 4.3 节）；最后分析该机制能够严格保证什么、不能保证什么（第 4.4 节）。

4.1 COLREGs 让路条款在动作空间中的形式化

4.1.1 会遇态势的谓词化

我们把会遇态势形式化为一组关于两船相对几何的谓词，并由此定义每类态势下规则允许的控制集；谓词的结构与阈值遵循海事规则的时序逻辑形式化 (Krasowski and




Figure 1 方法总览。27 维观测经策略网络给出期望控制 u_{policy} ，其输出分布为支撑有界的 Beta 分布。规则状态机把当前会遇判入六类态势，安全动作集 U_{safe} 由执行器量程、合规方向半平面与单步无碰约束求交而成，二次规划把 u_{policy} 投影为 u_{safe} 后送入环境。该投影并入环境转移，故安全盾位于训练回路之内。两条旁路互斥，紧急态直接交紧急控制器（ u_{em} ），其余态势仅在 $U_{safe} = \emptyset$ 时兜底（ u_{fb} ）。右下角为动作平面上三个约束集的示意。

- 1 Althoff 2021)。本文在此之上明确给出碰撞可能性谓词中的膨胀半径与速度集半宽，对让
- 2 路态入口作对称化处理（第 4.3.4 节），并把整组谓词接到连续动作的约束集上。
- 3 规则状态机把当前会遇归入六类，

$$\rho \in \{\rho_0 \text{ 无冲突}, \rho_1 \text{ 直航}, \rho_2 \text{ 对遇}, \rho_3 \text{ 交叉}, \rho_4 \text{ 追越}, \rho_5 \text{ 紧急}\},$$

- 4 判定由三组谓词合取而成。第一组是方位扇区，按公约的舷灯分界把他船相对本船的方位
- 5 划入前、左、右、后四区，前扇区半角取 5° ，舷侧扇区外边界取 112.5° 。第二组是航向
- 6 关系，区分两船航向近反平行、近同向，以及他船朝向偏左与偏右，追越航向带半角取
- 7 67.5° 。第三组是碰撞可能性，要求本船速度集与他船碰撞锥相交，且两船相对速度足以
- 8 在检查时域内消耗掉当前中心距；碰撞锥以本船位置为顶点，对按膨胀半径放大的他船占
- 9 据作外切，再沿他船速度平移得到。膨胀半径按他船真实船长取其三倍，速度集半宽取
- 10 1 m/s ，检查时域取 420 s ，前两个取值在所沿用的文献中未明确给出，此处一并写明。
- 11 三组谓词合成四类有义务的态势，

$$\begin{aligned} \rho_2 \text{ 对遇: } & \text{CP} \wedge \text{Fr}(s_e, s_m) \wedge \text{Ap}, \\ \rho_3 \text{ 交叉: } & \text{CP} \wedge \text{Ri}(s_e, s_m) \wedge \text{TI}, \\ \rho_4 \text{ 追越: } & \text{CP} \wedge \text{Be}(s_m, s_e) \wedge (v_e > v_m) \wedge \text{Sd}, \\ \rho_1 \text{ 直航: } & [\text{CP} \wedge \text{Le}(s_e, s_m) \wedge \text{Tr}] \vee \rho_4(s_m, s_e), \end{aligned} \quad (3)$$

- 12 其余情形归入 ρ_0 。追越与“本船被追越”两支都需交换两船参数，因为追越要求本船位
- 13 于他船的后扇区。四个谓词在几何上可能同时成立，故按上式的书写次序取优先。
- 14 状态机的转移由持续性条件触发。从无冲突态进入让路态，要求某个让路谓词当前
- 15 尚未成立、却在长度为 60 s 的反应窗内逐个决策步恒速外推后持续成立。其中“当前尚未
- 1 成立”这一合取项是必要的，它把“即将持续成立”与“已经成立”区分开，但也带来一

2 处不对称, 详见第 4.3.4 节。紧急态另由一个更强的集合预测判据进入, 预测时域取 180 s
3 。

4 **合规动作集。** 每一类态势对应一个显式的控制约束集,

$$U_{\text{colregs}}(\rho) = \begin{cases} U_{\text{box}}, & \rho = \rho_0, \\ \{|a| \leq \varepsilon_a\} \cap \{|\omega| \leq \varepsilon_\omega\}, & \rho = \rho_1, \\ \{\omega \leq -\omega_{\text{turn}}\}, & \rho \in \{\rho_2, \rho_3\}, \\ \{\omega \leq -\omega_{\text{turn}}\} \text{ 或 } \{\omega \geq +\omega_{\text{turn}}\}, & \rho = \rho_4, \\ U_{\text{box}}, & \rho = \rho_5, \end{cases} \quad (4)$$

5 两个动作箱的区分见第 3.2 节。对遇与交叉要求向右转, 追越允许择一侧转向, 直航要求
6 保向保速, 因而全部落在控制量平面上的半平面或区间形式。这正是后文能以投影替代枚
7 举的原因。

8 **“足够明显”的量化。** 公约要求让路动作的幅度大到能被对方及时察觉。把“明
9 显”量化为在机动时段内航向改变不少于给定阈值, 机动时段取 40 s、航向阈值取 20°,
10 即得

$$\omega_{\text{turn}} = \frac{\Delta_{\text{lt}}}{T_M} = \frac{20^\circ}{40 \text{ s}} \approx 0.008727 \text{ rad/s}. \quad (5)$$

11 它是合规转艏率的下确界, 任何幅度不小于它的转向都合规, 且该界不可再降。

12 由此得到一个可以直接算出来的结构性差异。若动作空间被量化为 7×7 的 49
13 点网格, 转艏轴取值为 0、 ± 0.006 、 ± 0.012 与 ± 0.018 rad/s (量化动作空间另设第 50
14 个动作, 它不是网格点, 而是紧急态下由紧急控制器在线算出的状态相关动作), 则
15 0.006 rad/s 那一档在 40 s 内只转过 13.75° , 不足 20° , 网格上最小的合规档位因而是
16 0.012 rad/s, 比该下确界高出 37.5%。需要限定的是, 这一比例是本文所复现的这一网格
17 的性质, 而非动作离散化的固有性质, 更细的网格可以缩小差距, 代价是动作数与屏蔽开
18 销的增长。也就是说, 量化动作空间每执行一次合规让路, 转艏幅度都必须超出规则要求
19 约三成七, 代价是多余的航向偏离与额外的舵动作。连续动作可以精确取到该下确界, 这
20 一优势与训练过程无关, 纯由动作空间的分辨率决定。

21 4.2 安全动作集与投影

22 4.2.1 单步无碰撞约束

23 对当前状态与他船占据, 我们要求施加的控制在下一个决策步末不致使两船体相交
24 。该条件直接写出是非凸的, 故取一个保守的凸内近似, 构造分三步。先把他船在一个决
25 策步之后的占据外近似为圆盘, 圆心取恒速外推、半径已含安全裕度, 本船以外接圆过近
26 似, 于是“两船体不交”的一个充分条件是两圆心距不小于两半径之和 d_{safe} 。再取分离
27 方向 n 为由他船指向本船标称落点的单位向量、 δ 为该距离, 其中标称落点由裁剪进动作
28 箱的策略输出算得。最后把落点沿控制作一阶展开, $p_e(u) \approx p_{\text{nom}} + J(u - u_{\text{nom}})$, 并要求
29 落点位于分离超平面的安全侧, 即得一条关于控制的线性不等式

$$\underbrace{-n^\top J u}_{g^\top} \leq \underbrace{-(d_{\text{safe}} - \delta + n^\top J u_{\text{nom}})}_h, \quad U_{\text{cf}}(s) = \{u : g^\top u \leq h\}. \quad (6)$$

30 一阶展开本身既非内近似也非外近似, 其余项符号随曲率变化, 故仅由式 (6) 并不
1 能直接断言保守, 使该断言成立的是安全距离中预留的裕度。叠加裕度后, 无碰撞约束实

2 际施加在约 590–840 m 的中心距上，按本场景库的他船尺寸实算中位约 714 m，而两船真
 3 正接触所需的距离要小得多。裕度因此吸收了线性化残差，代价是约束偏紧，会拒绝一些
 4 实际安全的控制。

5 4.2.2 安全动作集与投影算子

6 安全动作集取三者之交

$$U_{\text{safe}}(s, \rho) = U_{\text{box}} \cap U_{\text{colregs}}(\rho) \cap U_{\text{cf}}(s), \quad (7)$$

7 它是 $\mathbb{R}^2$ 中的凸多边形。给定策略给出的期望控制，实际执行的控制取其在该集合上的欧
 8 氏投影

$$u_{\text{safe}} = \Pi_{U_{\text{safe}}}(u_{\text{policy}}) = \arg \min_{u \in U_{\text{safe}}} \|u - u_{\text{policy}}\|_2^2. \quad (8)$$

9 可行集是若干半平面之交，可统一写成 $U_{\text{safe}} = \{u : Au \leq b\}$ ，其中前四行为动作箱、第五
 10 行为合规方向半平面、第六行为式 (6) 的无碰撞约束。这是一个两变量、至多六条约束的
 11 二次规划，规模极小，可在每个决策步在线求解。算法 1 给出整层的执行次序。

Algorithm 1 投影式安全盾的单步执行

Require: 本船状态 s 、他船状态、策略输出 u_{policy}

Ensure: 实际执行的控制 u_{safe}

- 1: $\rho \leftarrow$ 规则状态机判定的会遇态势
 - 2: **if** $\rho = \rho_5$ **then** ▷ 紧急态自成一路，不构造约束、不求解
 - 3: **return** 紧急控制器输出
 - 4: $U_{\text{colregs}} \leftarrow$ 由 ρ 按式 (4) 取用
 - 5: $U_{\text{cf}} \leftarrow$ 由式 (6) 线性化得到
 - 6: $U_{\text{safe}} \leftarrow U_{\text{box}} \cap U_{\text{colregs}} \cap U_{\text{cf}}$
 - 7: **if** $U_{\text{safe}} \neq \emptyset$ **then**
 - 8: **return** $\Pi_{U_{\text{safe}}}(u_{\text{policy}})$ ▷ 式 (8) 的二次规划
 - 9: **return** 兜底控制 ▷ 依次为退化、放松方向约束、碰撞风险最小化
-

12 4.2.3 安全动作集为空时的兜底

13 安全动作集为空时投影无解，此时须由一条不提供保证的替代规则给出控制，本文
 14 称之为兜底。兜底的处置按态势分支，而非按一条固定优先级依次尝试，可分为两条互斥
 15 的通道。

16 **紧急态通道。** 紧急态自成一路，不构造无碰撞约束、也不求解式 (8)，而是直接交
 17 给紧急控制器。该控制器是一个有状态的三模式几何律，生命周期对应一次紧急事件：正
 18 前方近反向会遇时跟踪一个由初始快照确定的横向固定目标点，后方扇区且纵向加速可解
 19 除紧急时在反应窗内直线加速脱离，其余情形跟踪一个随他船移动的目标点；三者经同一
 20 位置跟踪律换算为控制量。该控制器**不提供任何保证**，作用是在已无合规可行解时给出确
 21 定行为，并由性质 3 的证书判定该局面是否本就不可能。

22 **其余态势的兜底。** 非紧急态只在安全动作集为空时兜底，先判退化情形：若线性
 23 化给不出可用的分离方向（本船标称落点与他船膨胀占据的圆心重合），返回箱内投影；
 24 否则依次尝试放松方向约束与最小化碰撞风险。占据仅仅已经相交并不触发退化。后两支
 25 都在执行器物理量程上求解并整块丢弃合规约束，故转艏率可超出策略动作箱，统计动作
 1 饱和率时按各自的箱分别计算。

2 这些分支在实现上必需，但在本文使用的公开基准上几乎不发生——实测该基准中
3 本船若保持航向航速，与他船的最近中心距中位数约 1300 m，安全动作集基本不会为空
4 。为使它们得到检验，我们另行构造真冲突算例，结果见第 5.6 节。

5 4.3 策略学习

6 4.3.1 带盾的马尔可夫决策过程

7 我们不把安全盾放在策略之后作为事后纠正，而是把式 (8) 并入环境的转移。策略
8 输出 u_{policy} ，环境施加 u_{safe} 并返回相应的后继状态与回报，即策略面对的是复合转移

$$s_{t+1} \sim P(\cdot | s_t, \Pi_{U_{\text{safe}}(s_t, \rho_t)}(u_t)), \quad u_t \sim \pi(\cdot | s_t), \quad (9)$$

9 而非事后滤波所对应的 $P(\cdot | s_t, u_t)$ 。这样策略学习到的是经过投影之后的转移，因而会主
10 动适应投影的存在，而不必在训练结束后再与一个陌生的滤波器磨合。

11 4.3.2 回报函数

12 回报由五项相加而成，其结构与 (Krasowski and Althoff 2024) 一致以保证可比，另
13 有三处偏离在本节末声明。

$$r = r_{\text{sparse}} + r_{\text{goal}} + r_{\text{velocity}} + r_{\text{deviate}} + r_{\text{colregs}}, \quad (10)$$

14 系数取值见表 3。终止稀疏项在回合终止时按到达、超时、原地停住与碰撞四类事件给出
15 ，并对每一个进入紧急控制的决策步给固定惩罚。趋近项为稠密的向目标位移奖励，取相
16 邻两步到目标距离之差。航速项对航速落在巡航区间 $[2.5, 8.0]$ m/s 之外的部分按偏离量线
17 性惩罚；偏航项惩罚偏离起点至目标参考线的横向距离，并在 2000 m 处饱和。软性合规
18 项为随距离衰减的合规惩罚，它只在软奖励对照组与离散动作屏蔽配置上启用，本文全部
19 连续动作配置一律置零，因为这些配置的合规由式 (4) 的硬约束承担。

20 三处偏离需要显式声明。其一，趋近项取上述差分方向；按另一种常见写法趋近目
21 标反而得到负回报，与奖励趋近目标的意图相悖，我们采用物理上一致的写法。其二，软
22 性合规项的原始参数是在约 150 m 的作用尺度上标定的，而本任务的场景尺度约 8000 m
23 ，直接代入会使其指数项发散，故将他船径向速度按其速度上界归一化，并对指数项施加
24 上界钳制。其三，紧急态的解除判据含三项合取，即他船落在本船后 $\pm 90^\circ$ 、两船艏向单
25 位向量点积不为正，以及中心距不小于 $2L$ ；第三项在原始设定中字面写作距离不大于该
26 阈值，与其自身注文所述的距离足够大相悖，我们判为笔误并按物理语义取不小于。该判
27 据决定紧急态的驻留时长，因而影响紧急控制步的占比，故一并声明。

28 4.3.3 有界动作分布

29 连续策略通常输出无界高斯分布并在送入环境前裁剪到动作箱。这一组合与式 (8)
30 相冲突，两条原因都出在裁剪本身。其一，常见实现把裁剪后的动作作用于环境、却把裁剪
31 前的动作作用于策略梯度，于是一旦分布均值移出动作箱，再往外移动不改变任何回报，梯
32 度进入平高原，任何以动作平顺性为目标的惩罚项都失去着力点。其二，高斯分布的微分
33 熵没有上界，而熵正则项的系数是常数，于是标准差存在一条只涨不跌的通道，把越来越
34 多的采样推到箱外，加剧前一个问题。

35 我们改用支撑为闭区间的 Beta 分布。动作因此按构造不可能越箱，裁剪退化为恒
36 等映射，上述两条通道同时封闭，平顺性惩罚处处可微，且 Beta 的熵有上界。网络对每
1 个控制轴输出两个实数，形状参数与执行动作由

$$\alpha = \text{softplus}(\tilde{\alpha}) + 1, \quad \beta = \text{softplus}(\tilde{\beta}) + 1, \quad u = u_{\text{lo}} + (u_{\text{hi}} - u_{\text{lo}})z, \quad z \sim \text{Beta}(\alpha, \beta) \quad (11)$$

2 给出，评估时取确定性动作，即以众数代替采样。该参数化使两个形状参数严格大于 1，
 3 这一约束不可省。形状参数小于 1 时 Beta 呈 U 形、密度在两端发散，等价于一个数学形
 4 式的 bang-bang 控制；更关键的是此时分布的众数落在区间端点，而区间内部的驻点是密
 5 度的极小值，由于评估一律取众数，这会静默污染每一个上报数字，且在聚合指标上无从
 6 察觉。需要说明的是，该约束只保证分布单峰且端点密度有限，并不阻止策略选择接近饱
 7 和的动作，真正起作用的是支撑落在箱内与熵有上界这两条。

8 4.3.4 让路态入口的对称化

9 状态机中由无冲突进入让路态原本只由持续性条件触发，而由直航态进入让路态另
 10 有一条即时条件。我们补上对称的一支，即持续性条件未命中时，再检查即时条件是否已
 11 成立，成立即进入让路态。该改动使让路义务的识别时机在两条入口上一致，代价是它改
 12 变安全盾实际施加的动作，因此训练与评估必须在同一设置下进行。这一改动的必要性可
 13 以在专门构造的算例上直接看到。若一次会遇在**初始时刻**就已满足让路谓词，则持续性条
 14 件中“当前尚未成立”这一必要合取项恒不成立，持续性条件永远不会触发，该会遇因而
 15 始终不被识别为让路态。我们在一组这样的真冲突算例上实测。仅用持续性入口时让路态
 16 决策步为 0，补上即时支之后为 201 步。该测量取自合成的对抗算例，用于说明机制差异
 17 ，不与主结果表并列。

18 4.3.5 训练配置

19 训练超参见表 3。除熵正则系数与有界动作分布外，其余强化学习超参一律取库默
 20 认值、未作调整，离散与连续两类配置在这些值上逐项相同，故超参不构成两类配置之间
 21 的差异来源。观测与回报的滑动归一化不是可选项，不做时式 (10) 中大尺度的趋近项会
 22 把策略推向原地停船的退化解。

23 完整配置另含四项塑形，全部仅作用于连续动作策略，即三项势函数型塑形与一项
 24 动作增量惩罚。后者惩罚相邻两个决策步之间策略指令的变化量，按动作箱各轴半宽归一
 25 化后取平方和，因此**同时作用于加速度轴与转艏轴**。四项一并启用或一并关闭，未逐项拆
 26 开做消融，故只能报这一组塑形共同带来的变化。**由此产生一条贯穿全文的限制**，转艏增
 27 量、油门增量与 jerk 三项指标只能在同样启用该惩罚的两组之间比较，否则分不清差异来
 1 自控制器还是训练目标。

TABLE 3 回报函数与训练超参

类别	符号	含义	取值
回报函数	c_{goal}	到达（正）	+50
	$c_{\text{time}}, c_{\text{area}}$	超时 / 出界	-25, -5
	$c_{\text{stop}}, c_{\text{coll}}$	原地停住 / 碰撞	-40, -50
	c_{em}	每一步紧急控制	-0.5
	$c_{\text{reach}}, c_v, c_{\text{dev}}$	趋近 / 速度 / 偏航	1.5, -2.0, -0.001
	—	塑形权重（进门/进带/保速/动作增量）	200, 200, 20, 1.0
强化学习	—	塑形半径（进门/进带/保速）	500/80/400 m
	—	策略/价值网络	多层感知机, 2 层 $\times$ 64
	—	熵正则系数（常数）	0.01

表注。未列出的强化学习超参（折扣 0.99、学习率 3×10^{-4} 、采样步数 2048、批大小 64、GAE 折扣 0.95、裁剪范围 0.2）全部为库默认值。四项塑形仅用于连续动作策略。

2 4.4 安全性保证与作用域

3 本节说明该机制能够严格保证什么。四条性质按同一格式给出，即陈述、假设、证
4 明要点与作用域，作用域一栏写明该性质没有覆盖的情形。完整推导见补充材料。

5 **性质 1** (远场单步无碰). 设本船与单个他船的中心距为 d 。若

$$d \geq d_{\text{safe}} + v_{\text{obs,max}} \Delta t + \rho_{\text{ego}}, \quad (12)$$

6 则一个决策步之后两船以外接圆保守占据必不相交，其中 d_{safe} 为两船外接圆半径之和，
7 ρ_{ego} 为本船单步最大位移。

8 **假设**。单他船；他船速度不超过 9.5 m/s，该上界不由式 (1) 约束、须独立给出，全库
9 2000 个场景实测最大值为 7.10 m/s；他船步内恒速。

10 **证明要点**。三角不等式，步后中心距不小于 d 减去两船各自的单步位移上界，故不小于
11 d_{safe} 。

12 **作用域**。三角不等式与方向无关，故对遇即最坏情形。代入本场景库的常数后阈值约
13 764 m。它是单步充分条件，既非前向不变性，也不覆盖近场。

14 **性质 2** (每一让路步的方向合规). 在被状态机判为让路态势、且投影二次规划可行的每一
15 个决策步上，实际执行的 u_{safe} 必落在式 (4) 的合规方向半平面内。

16 **假设**。单他船；状态机判定正确。后者继承碰撞可能性谓词的一处保守偏差，该谓词以
17 中心距为准，对速度接近的尾随会遇存在漏判区间。

18 **证明要点**。合规半平面以硬区间约束进入二次规划，投影解必然满足它。该结论由构造
19 成立，与训练结果和随机种子无关。

20 **作用域**。不覆盖紧急态，其判据在结构上旁路合规约束；也不覆盖安全动作集为空而转
21 入兜底的步。

22 **性质 3** (碰撞不可避的保守判据). 设单个恒速他船， $R_{\text{box}}(t)$ 为本船可达中心的过近似集，
23 $O(t)$ 为他船船体矩形。若

$$\exists t^* \in [0, T]: R_{\text{box}}(t^*) \subseteq (O(t^*) \oplus \text{disk}(r_{\text{insc}})), \quad (13)$$

24 则碰撞不可避，任何可行控制序列都会在 t^* 与该他船相撞。

25 **假设**。单个恒速他船；他船船体尺寸不得高估，传入大于真实值的船宽会使判据失去可
26 靠性；有限时域 120 s 上取 241 个等距时刻求值。

27 **证明要点**。速度矢量变化率有界，二重积分给出 R_{box} 的两个半轴，故它过近似真可达中
28 心；内切圆欠近似船体；可达中心整体落入膨胀后的他船占据时，任何控制都无法避开。

29 **作用域**。该判据可靠但不完备，即只漏报不误报，不触发并不意味着可避；它是末端分
30 类器而非早预警，也不覆盖机动他船。20,000 个随机场景与 735 个精选场景上零假阳，
31 包络硬化后追加 1500 例模糊测试仍为零假阳。

32 **性质 4** (可清障集的控制不变性，暂定). 称控制序列为状态 s 的已认证逃逸，若它逐步可
33 执行、尾段恒速直行、且沿途与他船的距离经可靠证书判定为不减；记全部具有已认证逃
34 逸的状态之集为可清障集 A_{clr} 。对每个 $s \in A_{\text{clr}}$ ，施加其逃逸序列的首个控制一个决策步
1 后所得 s' 仍属于 A_{clr} 。

2 **假设。** 单个恒速他船； A_{clr} 为真实可清障集的内近似；证书要求尾段**恒速**，仅航向不变
3 不足以保证距离函数的凸性。

4 **证明要点。** 施加首个控制之后，原序列的其余部分就是同一条已通过证书的物理轨迹的
5 后半段，因而仍是新状态的已认证逃逸。合规版本另需首步落在合规半平面内。

6 **作用域。** **暂定。** 控制不变性已证、证书经长时域模糊测试为零假阳、终端约束模块已单
7 测，但把该约束接进部署中的安全盾并在训练所得策略上验证闭环尚未完成。故本文只声
8 明“已证可清障集不变、并据此设计了终端约束”，不声明“已实现前向不变的安全盾”
9 。

10 综合起来，本文可辩护的核心结论是，在连续控制上同时取得 COLREGs 让路条款
11 的方向合规保证，并配以远场单步无碰的严格结论与紧急迫近不可避的可靠证书。该结论
12 的作用域限于单个恒速他船、让路态势且投影可行的决策步；紧急态与三支兜底不在其内
13 。

14 **兜底行为的实证边界。** 当投影在紧急态不可行时，判据在结构上旁路方向约束，兜
15 底控制器最小化碰撞风险。这是经验兜底，不是保证。在一个专门逼出紧急支的对抗性纯
16 几何基线上，我们观察到的碰撞全部发生在归类为紧急控制的步上，即“最后手段尝试并
17 失败”，且都落在性质 1 的适用域（远场、非紧急、单步）之外。它们不是对头条主张的
18 反例，但坐实了紧急态不是保证。此处按来源分类的碰撞计数留待正式实验重评后填入（
19 见第 5.6 节，【待填】）。

20 5. Experiments

21 5.1 场景库与对照配置

22 实验在 CommonOcean 基准 (Krasowski and Althoff 2022) 的双船会遇场景库上进行
23 ，共 2000 个场景。每个场景规定受控船的初始位姿与航速、他船的初始状态与既定航迹
24 、以及受控船的目标区域（含位置门、朝向门与时限）；会遇几何程序化生成，覆盖不同
25 的相对方位、航向交角与接近速率。他船船长 200–300 m，回合上限 170 个决策步。

26 按状态机的几何类型谓词对全库分类，交叉与对遇两类占满全库，**追越场景数为零**
27 ，官方测试集中交叉 395 个、对遇 205 个。式 (4) 的追越一支因而无法在本场景库上得到
28 实证检验，结论中如实列出。

29 场景库的官方划分为训练 1400 与测试 600。我们把官方训练侧再切为 1300 个训练
30 场景与 100 个验证场景，验证集只用于训练期监控与存档选取，测试集在训练与调参全程
31 不被访问。训练集与测试集零交集，经独立复算核验，故评估样本量即为 600。本文此前
32 的探索性实验使用过一个较小的场景子集，其样本量与此处不同，两套样本量下的数值不
33 可放入同一张表。

34 表 4 列出九种配置。它们构成一条连通的单变量递进序列。相邻两级之间只改动一
35 个变量，因此每一个机制的贡献都能单独读出来。

36 **⑤⑥这对配置的适用条件。** 无盾的连续动作配置只能采用极简配置（无界高斯 / 非
37 对称让路入口 / 零塑形），因为让无盾配置启用连续专属塑形会造成相对离散无盾基线的
38 不对称，使归因失效。而无界高斯正是那个会把大量采样推到动作箱边界之外的形态。在
39 探索期的四配置重评上（小规模场景池，非本文正式实验的评估设置），我们实测无界高
40 斯策略有约 73% 的决策步紧贴动作箱边界。因此，“安全盾在连续动作空间中带来多少
41 收益”这一倍数，是在连续动作最差的形态下测得的。同理，由③到⑤所反映的“把动作
1 空间由离散换为连续本身带来多少收益”可能为负；该值应视为一个保守的下界。

TABLE 4 九种配置与单变量递进序列

#	配置	连续	投影盾	屏蔽	软奖励	塑形	有界分布	对称入口	相对上一级只改
①	完整方法	✓	✓	×	×	✓	✓	✓	由⑧或⑨各补一项
②	离散 + 屏蔽	×	×	✓	✓	×	—	×	动作屏蔽（相对④）
③	离散基线	×	×	×	×	×	—	—	序列的根
④	离散 + 软奖励	×	×	×	✓	×	—	—	软性合规项（相对③）
⑤	连续无盾	✓	×	×	×	×	×	×	动作空间（相对③）
⑥	连续有盾	✓	✓	×	×	×	×	×	安全盾（相对⑤）
⑦	消融基准	✓	✓	×	×	✓	×	×	连续专属塑形（相对⑥）
⑧	消融·仅有界分布	✓	✓	×	×	✓	✓	×	动作分布（相对⑦）
⑨	消融·仅对称入口	✓	✓	×	×	✓	×	✓	让路入口（相对⑦）

表注。✓ 为启用、× 为关闭、— 为该配置下不适用。三处不可分割的伴随变量：由③到⑤同时换掉动作空间与策略分布（无盾连续配置只有无界高斯这一种合法形态）；由⑥到⑦的连续专属塑形是四件一起开关的捆绑包；由⑦到⑧换分布必然带来初始探索尺度的差异（加速度轴约 2.5 倍）。这三级只能整体归因。

2 5.2 评价指标与实验方案

指标。 主指标为到达率、碰撞率、每局 COLREGs 违规数（拆为让路违规与直航违规）、紧急控制步占比与每局时长。另报控制质量（转艏增量、油门增量、jerk）、安全裕度（最近点中心距与净空）、安全盾行为（介入步数、兜底触发率、投影修正量）与单步求解耗时。各指标另按会遇类型拆分。各配置的回抱函数不同，故每局回报不跨配置比较。

违规如何计数。 违规数不取自安全盾的态势判定，而由一个独立于安全盾的离线评分器给出。评分器只看轨迹，逐步用裸态势谓词重判本船处于直航还是让路义务之下，直航违规按步计、让路违规按会遇计，规则见算法 2。评分器对本文方法与全部基线（包括不含状态机的几何控制器）使用同一套判据，因此比较是同条件的。该计数只在评估侧集成，训练期不采，故违规量只有每段评估的那 20 个点。

Algorithm 2 离线评分器的违规计数

Require: 一条轨迹的逐步位姿

Ensure: 直航违规数 n_{sd} 、让路违规数 n_{gw}

```

1:  $n_{sd}, n_{gw}, c \leftarrow 0, 0, 0$  ▷  $c$  为带符号累积航向变化
2: for 每个决策步  $t$  do
3:   用裸谓词重判本步义务
4:   if 直航义务 then
5:      $c \leftarrow c + \Delta\theta_t$ 
6:     if  $|c| \geq \Delta_{nt}$  then
7:        $n_{sd} \leftarrow n_{sd} + 1$ 
8:   else if 直航义务刚解除 then
9:      $c \leftarrow 0$  ▷ 义务期结束即清零
10: for 每一次让路会遇（从触发到解除） do
11:   if 全程未出现达到  $\Delta_{lt}$  的规定方向转向 then
12:      $n_{gw} \leftarrow n_{gw} + 1$  ▷ 让路按会遇计，不按步计

```

计数窗口与安全盾并不重合。 评分器累积的是一整段义务期内的航向变化，安全盾约束的却是单个机动时段内的变化，两者的窗口长短不同；此外紧急态与安全动作集为

2 空时的兜底都在结构上旁路合规约束。因此安全盾不保证违规计数为零，本文也不作此主
 3 张——特别地，性质 2 保证的是每一让路步的转向方向，并不蕴含让路违规计数为零。该
 4 错配的实际发生频率未作测量。

5 5.2.1 训练预算、种子与报数规则

6 每种配置以 8 颗随机种子各训练一条 run，每条 10,158,080 步、分 20 段，每段留
 7 一份存档并在验证集上评估一次。场景划分由一个独立的固定种子决定，故所有 run 看到
 8 同一批场景。本文的主统计工具是同种子配对比较，因此同一颗种子下的全部配置在同一
 9 台机器内训练，同一张表内的全部配置也同机同轮评完，以免机器成为混淆变量。

10 存档选取规则事先定死、不含可调参数：候选为全部 20 段，指标为验证集到达率
 11 取最高，平局取更早的段，全程不接触测试集。**该规则本身带偏倚，故必须两版并报。**验
 12 证集只有 100 个场景，到达率的二项标准误约 4 个点，在 20 个候选里取最大值期望上抬
 13 约 7.5 个点，比我们专门立规矩去防的跨机跨轮抖动（约 1.6 个点）还大四倍。因此最佳
 14 存档一版、末段存档一版同时报出。

15 配对检验为同种子配对符号检验，8 颗种子时双侧最小可达 $p = 2/2^8 = 0.0078$ ；
 16 误差棒为按种子重采样的自助法 95% 区间；收敛判据为验证集到达率不低于 50%，发散
 17 种子如实计入主表，并另报“仅收敛种子”一版。

18 5.3 主对照实验

TABLE 5 主表：九种配置的同条件对照（全部种子）。本表数值为暂用值，口径是验证集 100 场景的末段评估；官方测试集 600 的重评结果到手后整表替换。

配置	n	达标	到达% [CI]	碰撞%	违规/局	转舵 Δ	油门 Δ	紧急%
①本文方法	8	8/8	88.5 [81, 92]	0.00	0.49	0.0085	0.0193	2.56
②离散-有盾	8	6/8	92.5 [0, 96]	0.00	0.74	0.0124	0.0260	4.07
③基线	8	8/8	97.0 [96, 98]	3.00	2.52	0.0139	0.0210	0.00
④软奖励	8	7/8	96.5 [94, 98]	2.50	2.41	0.0139	0.0215	0.00
⑤连续-无盾	8	7/8	97.0 [94, 98]	2.50	4.06	0.0248	0.0134	0.00
⑥连续-有盾	8	5/8	78.5 [6, 88]	0.00	0.93	0.0213	0.0267	2.49
⑦消融·都不改	8	5/8	86.0 [3, 88]	0.00	1.09	0.0142	0.0109	3.84
⑧消融·只 Beta	8	7/8	86.0 [50, 91]	0.00	0.52	0.0087	0.0176	1.97
⑨消融·只对称	8	5/8	75.5 [0, 82]	0.00	0.77	0.0150	0.0143	3.02

表注。口径警示：本表现填的是验证集 100 场景、各种子末段的数值，不是标题所述的官方测试集 600 与最佳存档轮；重评后整表替换。配置⑤⑥使用无盾连续动作唯一合法的极简形态，故安全盾的收益是在该形态下测得的。转舵与油门增量两列不可跨动作空间解读为控制更平顺，理由见第 4.3.5 节。

19 表 5 另报“仅计收敛种子”的版本。发散种子会污染逐局平均，且污染方向因配置
 20 而异，故两版并报，关键差值为【待填】。逐种子原始值随表给出。

21 5.4 消融实验

22 四条消融配置构成完整的 2×2 （有界分布 $\times$ 让路入口），其余配置逐字相同、同
 23 种子配对，定量结果见图 3。换有界分布把转舵增量的中位数降低 39%（8 颗种子里 7 颗
 24 同向，配对 Wilcoxon 符号秩 $p = 0.016$ ），每局违规降低 53%（ $p = 0.016$ ）；只换让路
 1 入口不改转舵增量（+5%， $p = 0.38$ ），但同样把每局违规降低 30%。两项同开时转舵




Figure 2 安全—效率权衡。（a）横轴为到达率、纵轴为每局 COLREGs 违规数（对数轴），点为跨种子中位数，误差棒为按种子重采样的自助法 95% 区间，右下角为理想区；圆为连续动作、三角为离散动作，实心为带盾、空心为无盾。（b）碰撞率逐种子画出，一点一颗种子，短竖线为中位数。误差棒之所以宽，是因为每条臂都含发散种子，见第 5.2.1 节的“仅收敛种子”一版。本图为验证集 100 场景上的数值，与表 5 的官方测试集口径不同；违规为直航与让路之和，拆分值训练期不回传。三条外部几何基线不训练、无训练期产物，故不在本图内。




Figure 3 两项改进的贡献拆解（ 2×2 消融，同种子配对）。横轴为四条消融配置，纵轴依次为转艏增量、每局 COLREGs 违规与到达率。每点一颗种子，灰细线把同一颗种子的四个配置连起来，粗横线为中位数，误差棒为按种子重采样的自助法 95% 区间。本图为验证集 100 场景上的数值，与表 5 的官方测试集口径不同；违规为直航与让路之和。

2 增量与违规分别降低 40% 与 55%，与只换有界分布的一档在统计上分不开（ $p = 1.0$ 与
3 0.45）。两项改进因而分工明确，平顺度几乎全部来自有界动作分布，合规收益则两者都
4 有贡献。

5 转艏平顺度唯一站得住的读法就在这组对照里。四种配置开着同一个动作增量惩罚
6 ，故这一差异只能归因于有界动作分布，而非额外的奖励项；跨动作空间与离散基线比较
7 结构上不成立，因为我们罚了那个量、离散动作配置拿不到。由⑦到⑧这一级的不可分割
8 伴随（初始探索尺度在加速度轴上差约 2.5 倍）见表 4 表注 (3)。按第 5.2.1 节，本组同样
1 给出“仅收敛种子”一版。




Figure 4 样本效率与训练可靠性，横轴为训练步数。（a）四种主对照配置的验证集到达率，细线为单颗种子、粗线为跨种子中位数。（b）同种子配对，由消融·两项都不改到本文方法。（c）到达率达到收敛判据的种子数。（d）值函数可解释方差。离散安全基线尚有两颗种子在训练（分别跑到第 14、13 段），其中位线在末段由较少种子构成，逐种子细线的长度即为各自的实际进度。纵轴为 100 个验证场景上的数值，与表 5 的官方测试集口径不同。

2 5.5 训练可靠性与样本效率

图 4 取自训练期，用来回答两件不需要重评就能回答的事，即安全盾要不要付学习速度的代价、以及各配置有多大比例的种子能练成。

第一，代价是有的，但只体现在学习速度上。带盾的两条连续动作配置在前 4 百万步明显落后于无盾的离散基线，到达率要到 8 百万步才追上来（图 4a）。同一张图的 (b)(c) 两格给出对价，无盾配置在整段训练里稳定维持 2–4% 的碰撞率与每局 2.4 次以上的违规，而带盾配置的碰撞率贴着零线、违规稳定在每局 0.5 次附近。安全盾把风险从结果里移走的同时，也把探索空间收窄了，学习变慢是这一收窄的直接后果。

第二，可靠性上带盾配置分化很大，而本文方法是最稳的。按事先声明的收敛判据（验证集到达率达到 50%），本文方法 8 颗种子全部练成，是全部带盾配置里唯一做到的；同为带盾的消融配置分别只练成 5–7 颗，离散安全基线为 6 颗（图 4d）。两项改进因而不只改善了终点数值，也降低了训练本身失败的概率。发散种子按第 5.2.1 节的规则如实计入，并另报“仅收敛种子”一版。

一个必须说明的反例。在 48 个带盾 run 中，47 个在验证集上的碰撞率恰为零，另有 1 个不为零。这与第 4.4 节的作用域一致，本文的构造式保证覆盖的是远场单步无碰与让路步的转向方向，并不覆盖紧急态与安全动作集为空时的兜底，因此零碰撞是观测结果而非保证。




Figure 5 安全盾的行为随训练演化，取自训练期遥测。（a）本文方法中每一步控制由哪一支产生（对数纵轴）。（b）动作饱和度，转艏轴与加速度轴分开，有界分布、无界高斯与离散网格叠于同图；离散网格的动作上界恰等于连续动作箱半宽，故两者共用同一条打满判据。（c）投影修正量，按动作箱半宽归一化。（d）会遇态势占比（对数纵轴）；直航态 ρ_4 在本场景库上几乎不触发，逐段中位数为零，故其曲线贴在零线上。本图为训练期采集，与表 5 的评估口径不同。

2 5.6 安全盾行为

紧急通道是本方法唯一不提供保证的一支，因此需要单独刻画它被用到的频率与后果。训练末期每一步控制的归口为投影 93.6%、紧急控制 6.2%、三支兜底（放松、碰撞风险最小化、退化）合计 0.22%（图 5a）；评估侧的紧急控制步占比为 2.6%，低于离散安全基线的 4.1%。兜底之所以罕见，是因为它只在安全动作集为空时才被启用，而这在非紧急态下很少发生。碰撞按控制来源分类的分布为【待填】。若碰撞全部落在紧急控制一类，则说明碰撞发生在“最后手段已被启用并失败”的步上，而这些步按定义落在性质 1 的适用域（远场、非紧急、单步）之外，这不构成对性质 1 的反例，但坐实了紧急态只是经验兜底。投影修正量按动作箱半宽归一化后，训练末期的中位数为 0.082、四分位区间 $[0.065, 0.102]$ ，即策略输出与规则要求之间的差距长期稳定在动作量程的一成以内，且随训练单调收窄（图 5c）。只换让路入口的消融配置修正量最大 0.093、只换有界分布的最小 0.066，与图 3 的转艏增量排序一致。该量的完整分布（第 95 百分位 / 最大值 / 零修正比例）为【待填】。

15 5.7 外部基线对照

三条不需要训练的几何避碰控制器在同一评估管线、同一测试集与同一样本量下运行，作为与学习无关的参照（表 6）。这组对照要回答的不是学习方法是否更强，而是几

【图 6（同一场景 × 四种方法的轨迹）——需逐局轨迹产物，只在评估侧生成，待重评占位——数据到手后替换】

Figure 6 同一场景下四种方法的轨迹对比（场景 T-【待填】，种子 s【待填】）。本船轨迹按会遇态势着色，他船轨迹为灰色，圆点间隔一个决策步；虚线圆为性质 1 的远场阈值。本图为定性插图，不承担任何定量声明；场景为人工挑选，种子集合（s0/s1/s2）在跑之前已声明。

- 2 何方法在哪些维度上本来就够用。
- 3 答案把可辩护的主张收窄到一个维度。碰撞率不能区分两类方法，控制障碍函数滤
- 4 波器在本测试集上同为 0.00%；到达率与平顺度两列则分别受终端约束类型与控制量程档
- 5 位支配，均不支持有利于本文的解读（表注 2 与表注 4）。真正的差别在 COLREGs 违规
- 6 ，且几乎全部来自直航违规——这些控制器只以不碰为目标，在规则要求保向保速的时段
- 7 里仍在持续机动。违规由独立于安全盾的评分器按裸态势谓词判定，因此该比较是同条件
- 1 的。本文相对几何方法的结论只落在这一维度上，具体差值为【待填】。

TABLE 6 外部几何基线对照（不训练、无种子；官方测试集 $N = 600$ ）

方法	控制量程	到达%	碰撞%	COLREGs 违规 / 局			转艏 Δ	jerk
				合计	让路	直航		
控制障碍函数	策略量程	70.17	0.00	4.95	0.47	4.48	0.00242	0.171
	同上 + 裕度	69.83	0.00	4.49	0.45	4.04	0.00235	0.167
	物理满量程	69.33	0.00	6.48	0.52	5.97	0.00058	0.050
PD 控制器	策略量程	58.83	18.00	9.79	0.44	9.35	0.00492	0.310
	物理满量程	57.67	16.67	8.10	0.63	7.47	0.00032	0.040
速度障碍	策略量程 + 裕度	57.00	0.00	8.20	0.50	7.70	0.00425	0.279
	物理满量程	42.67	0.00	8.06	0.68	7.38	0.00128	0.071
①本文方法	策略量程	(引表 5)						

表注。三条基线不训练、无种子，参数按各自最好的配置报，调参集与本表评估集零交集。控制量程两档：“策略量程”与本文策略同权限（ $\pm 0.048/\pm 0.018$ ），“物理满量程”为 $\pm 0.24/\pm 0.03$ ，同报两档以排除权限差异这一混淆。到达率不等于于避碰能力——几何控制器的标称律不含终端对准环节，位置命中率达 96.8%–99.7% 却卡在终端朝向门之外。

2 6. Discussion

3 6.1 从统计性合规到逐步合规

4 软奖励只能影响策略的期望行为，不能排除任何一个具体动作，而屏蔽与投影都能
5 ，区别在于屏蔽需要一个可枚举的动作集合。本文的结论是，在连续动作空间里，“可枚
6 举”这一前提可以用“可投影”替代。合规方向恰好是一个半平面，投影到半平面与动作
7 箱的交集上是一个二维二次规划。

8 6.2 投影替代枚举的收益与代价

9 这一替代的收益与代价都可以直接量度，结果见图 7。

10 收益在合规转向的精细度上。合规要求机动时段内航向改变不少于阈值，换算出转
11 艏率的下确界 ω_{turn} ；连续动作能精确取到该下确界，而任何有限网格只能取到不小于它
12 的最近格点，因而必然过转。本文所复现的 7×7 网格取到的最小合规转艏率比下确界高
13 37.5%。

14 但这一差距并不随网格加密而单调缩小。过转量取决于网格步长与 ω_{turn} 的整除关
15 系，而非步长本身，图 7a 中 5×5 只过转 3.1%、 7×7 反而过转 37.5%。因此“把网格
16 调细就能逼近连续”这一常见说法在本任务上不成立；能精确取到下确界的只有连续动作
17 加投影。

18 代价在单步计算上，且方向与直觉相反。图 7b 显示，枚举并屏蔽 $K \times K$ 个动作的
19 耗时虽随 K^2 增长，但即使 $K = 121$ （14,641 个动作）仍显著低于一次投影二次规划的耗
20 时。投影不是更省算力的做法，它的理由是能力而非速度，即在连续动作集上枚举本身无
21 从谈起，而投影既可行又能精确落在约束边界上。部署时的单步求解耗时按评估侧统一机
22 器另报（【待填】）。

23 油门轴的分辨率差异（离散只有 7 档）同样是结构性的，但它不能被直接读成油门
24 增量指标上的优势，因为该指标同时受动作增量惩罚影响，而该惩罚只在连续动作配置中
25 启用；可归因的比较只在同样启用该惩罚的连续配置之间成立。到达率一侧则不确定，由
26 ③到⑤这一级可能为负（表 4 表注 1）。

27 6.3 两项改进为何是连续动作空间特有的

28 量化动作空间不存在动作被裁到箱外的情形，也不存在微分熵无上界的通道。这两
29 个问题是把 COLREGs 安全盾迁入连续动作空间之后才出现的。因此本文的消融不是对两
30 个超参的调节，而是对迁移过程中新出现的两处缺陷的修补。

31 6.4 对自主船舶投入营运的意义

32 把合规做成可投影的硬约束，改变的不只是策略的行为，还有这一层能被如何审查
33 。当合规由训练诱导时，验证只能是统计性的，即在若干场景上抽样、报告违规频次，而
34 结论随策略版本变动；当合规由约束构造成立时，验证对象变成约束本身，即状态机的态
35 势判定是否正确、半平面的方向是否与条款一致、投影是否落在可行集内。这三件事都可
36 以逐步检查，且与训练结果无关。对型式认可与事故复盘而言，后者是更可操作的形态。
37 审查者不需要复现训练过程，只需检查每一个决策步的约束是否被满足。

38 同样值得指出的是，该机制不要求替换既有的控制系统。它接受任意来源的期望控
1 制并输出最近的合规控制，因而可以作为一层独立的合规校验层，叠加在已有的自动舵或




Figure 7 投影替代枚举的收益与代价。（a） $K \times K$ 网格能取到的最小合规转艏率比下确界 ω_{turn} 高出的比例，由网格步长与 ω_{turn} 的整除关系决定，不随 K 单调下降；连续动作加投影恰好取到下确界（红线）。（b）单个决策步的耗时，枚举屏蔽随 K^2 增长，投影与 K 无关。（a）为精确算术，（b）为单机实测，只用于比较随 K 的增长关系，不是论文报数用的部署耗时。

- 2 路径跟踪控制之上。其在线开销为每步一个两变量、至多六条约束的二次规划，不需要专
- 3 用加速硬件，这使它在现有船载计算平台上部署是现实的。

4 6.5 与控制理论侧安全滤波器的关系

- 5 反应式控制障碍函数滤波器在 10 s 零阶保持下没有递归可行性证明。本文的可清
- 6 障集给出了一条路径（性质 4），但该结论仍为暂定，闭环集成与官方评估流程复算尚未
- 7 完成，故本文只把它作为设计方向陈述，不作为已兑现的保证。

8 7. Conclusions

- 9 COLREGs 的让路条款要求船舶朝规定的一侧转向，这使合规无法用最终有没有撞
- 10 上来验证。既有工作要么以离散动作加屏蔽换取可证的合规，要么以连续控制加软性奖励
- 11 换取控制精度。本文指出这一取舍并非必然：让路条款在控制量平面上恰好构成一个半平
- 12 面，而“逐个枚举并屏蔽”这一前提可以由“向凸集投影”替代。据此我们把投影式安全
- 13 盾落到海事 COLREGs 的连续控制上，使每一个投影可行的让路步的方向合规由构造成立
- 14 ，不依赖训练结果，也不受随机种子影响。凡是能写成动作空间中凸约束的行为规范都可
- 15 循同一路径迁移。

- 16 结论的边界如下。安全盾提供的保证不含无碰撞，性质 4 仍为暂定；方向合规成立
- 17 于每一个投影可行的让路步而非每一步，紧急态在结构上旁路该约束，实测每局违规数非
- 18 零（【待填】）。性质 1、3、4 均建立在他船恒速外推之上，机动他船会使保证失效。
- 19 到达率与平顺度都不作为效能主张，后者因动作增量惩罚只在连续配置中启用而不可跨动
- 20 作空间归因。报数上有最佳存档选择与跨机跨轮抖动两个已知偏倚，故主表两版并报且强
- 21 制同机同轮评估。规则覆盖上，本文实现第 13–17 条的方向要求与直航保向保速，未实现
- 22 直航船的自行避碰义务；追越一支虽已实现，本场景库无样本，未获实证检验。离散基线
- 23 为重新实现，其种子脆弱性归因于本文的复现。

- 1 后续工作包括把后备机动的终端约束接进部署中的安全盾并验证闭环、把方向合规

- 2 推广到多他船并给出冲突消解规则，以及把远场判据实现为 $O(1)$ 的提前退出。

3 Acknowledgements

4 作者感谢 CommonOcean 基准与 (Krasowski and Althoff 2024) 公开的场景库与规则
5 形式化，它们构成本文实验的基础。本文在代码实现、文档整理、参考文献格式整理与稿
6 件起草环节使用了生成式语言模型 Claude (Anthropic)。全部方法设计、评价方式与数
7 据结论均由作者核定并复核，作者对全文内容的准确性负全部责任。

8 Author Contributions

9 研究构思与方法设计：Weiyu Tang、Jie Xue；软件实现与实验执行：Weiyu Tang
10 ；形式化分析与可证明层推导：Weiyu Tang；数据整理与结果分析：Weiyu Tang、
11 Peijie Yang、Qianbing Li；稿件起草：Weiyu Tang；稿件审阅与修改：全体作者；研究
12 监督与经费支持：Jie Xue。全体作者均已审阅并认可本文的最终版本。

13 Conflict of Interest

14 作者声明本研究、署名及发表不存在潜在利益冲突。

15 Funding

16 【待填】

17 References

- 18 Alshiekh, Mohammed, Roderick Bloem, Rüdiger Ehlers, Bettina Könighofer, Scott Niekum, and
19 Ufuk Topcu. 2018. “Safe Reinforcement Learning via Shielding.” In *Proceedings of the*
20 *AAAI Conference on Artificial Intelligence*.
21 Ames, Aaron D., Samuel Coogan, Magnus Egerstedt, Gennaro Notomista, Koushil Sreenath, and
22 Paulo Tabuada. 2019. “Control Barrier Functions: Theory and Applications.” In *Euro-*
23 *pean Control Conference (ECC)*, 3420–3431.
24 Benjamin, Michael R., John J. Leonard, Joseph A. Curcio, and Paul M. Newman. 2006. “A
25 Method for Protocol-Based Collision Avoidance Between Autonomous Marine Surface
26 Craft.” *Journal of Field Robotics* 23 (5): 333–346.
27 Cheng, Yin, and Weidong Zhang. 2018. “Concise Deep Reinforcement Learning Obstacle Avoid-
28 ance for Underactuated Unmanned Marine Vessels.” *Neurocomputing* 272: 63–73.
29 Chou, Po-Wei, Daniel Maturana, and Sebastian Scherer. 2017. “Improving Stochastic Policy
30 Gradients in Continuous Control with Deep Reinforcement Learning Using the Beta Dis-
31 tribution.” In *Proceedings of the International Conference on Machine Learning (ICML)*.
32 Chun, D.-H., M.-I. Roh, H.-W. Lee, J. Ha, and D. Yu. 2021. “Deep Reinforcement Learning-
33 Based Collision Avoidance for an Autonomous Ship.” *Ocean Engineering* 234: 109216.
1 Dalal, Gal, Krishnamurthy Dvijotham, Matej Vecerik, Todd Hester, Cosmin Paduraru, and Yuval

- 2 Tassa. 2018. “Safe Exploration in Continuous Action Spaces.” arXiv:1801.08757.
- 3 De Lellis, Francesco, Marco Coraggio, Giovanni Russo, Mirco Musolesi, and Mario di Bernardo.
- 4 2024. “Guaranteeing Control Requirements via Reward Shaping in Reinforcement Learn-
- 5 ing.” *IEEE Transactions on Control Systems Technology*. arXiv:2311.10026.
- 6 Eriksen, Bjørn-Olav H., Morten Breivik, Erik F. Wilthil, Andreas L. Flåten, and Edmund F.
- 7 Brekke. 2019. “The Branching-Course Model Predictive Control Algorithm for Maritime
- 8 Collision Avoidance.” *Journal of Field Robotics* 36.
- 9 Fossen, Thor I. 2011. *Handbook of Marine Craft Hydrodynamics and Motion Control*. Chich-
- 10 ester: John Wiley & Sons.
- 11 García, Javier, and Fernando Fernández. 2015. “A Comprehensive Survey on Safe Reinforce-
- 12 ment Learning.” *Journal of Machine Learning Research* 16: 1437–1480.
- 13 Grover, Jaskaran, Changliu Liu, and Katia Sycara. 2023. “The Before, During, and After of
- 14 Multi-Robot Deadlock.” *International Journal of Robotics Research*. arXiv:2206.01781.
- 15 Heiberg, Amalie, Thomas Nakken Larsen, Eivind Meyer, Adil Rasheed, Omer San, and Dami-
- 16 ano Varagnolo. 2022. “Risk-Based Implementation of COLREGs for Autonomous
- 17 Surface Vehicles Using Deep Reinforcement Learning.” *Neural Networks* 152: 17–33.
- 18 arXiv:2112.00115.
- 19 Huang, Yamin, Linying Chen, and P. H. A. J. van Gelder. 2019. “Generalized Velocity Obstacle
- 20 Algorithm for Preventing Ship Collisions at Sea.” *Ocean Engineering* 173: 142–156.
- 21 International Maritime Organization (IMO). 1972. *Convention on the International Regulations*
- 22 *for Preventing Collisions at Sea (COLREGs)*. London: IMO.
- 23 Johansen, Tor A., Tristan Perez, and Andrea Cristofaro. 2016. “Ship Collision Avoidance and
- 24 COLREGS Compliance Using Simulation-Based Control Behavior Selection with Pre-
- 25 dictive Hazard Assessment.” *IEEE Transactions on Intelligent Transportation Systems* 17
- 26 (12): 3407–3422.
- 27 Kim, Kyungmin, Davide Corsi, Andoni Rodríguez, JB Lanier, Benjamí Parellada, Pierre Baldi,
- 28 César Sánchez, and Roy Fox. 2024. “Realizable Continuous-Space Shields for Safe Rein-
- 29 forcement Learning.” arXiv:2410.02038.
- 30 Kochdumper, Niklas, Hanna Krasowski, Xiao Wang, Stanley Bak, and Matthias Althoff. 2023.
- 31 “Provably Safe Reinforcement Learning via Action Projection Using Reachability Analy-
- 32 sis and Polynomial Zonotopes.” *IEEE Open Journal of Control Systems* 2.
- 33 Krasowski, Hanna, and Matthias Althoff. 2021. “Temporal Logic Formalization of Marine Traf-
- 34 fic Rules.” In *Proceedings of the IEEE Intelligent Vehicles Symposium (IV)*, 186–192.
- 35 DOI: 10.1109/IV48863.2021.9575685.
- 36 Krasowski, Hanna, and Matthias Althoff. 2022. “CommonOcean: Composable Bench-
- 37 marks for Motion Planning on Oceans.” In *Proceedings of the IEEE Interna-*
- 38 *tional Conference on Intelligent Transportation Systems (ITSC)*, 1676–1682. DOI:
- 39 10.1109/ITSC55140.2022.9921925.
- 40 Krasowski, Hanna, and Matthias Althoff. 2024. “Provable Traffic Rule Compliance in Safe Re-
- 41 inforcement Learning on the Open Sea.” *IEEE Transactions on Intelligent Vehicles* 9
- 42 (12): 7617–7634. arXiv:2402.08502.
- 43 Krasowski, Hanna, Jakob Thumm, Marlon Müller, Lukas Schäfer, Xiao Wang, and Matthias Al-
- 44 thoff. 2023. “Provably Safe Reinforcement Learning: Conceptual Analysis, Survey, and
- 45 Benchmarking.” *Transactions on Machine Learning Research*. arXiv:2205.06750.
- 1 Kufoalor, D. K. M., Tor A. Johansen, Edmund F. Brekke, A. Hepsø, and K. Trnka. 2020. “Au-

- 2 autonomous Maritime Collision Avoidance: Field Verification of Autonomous Surface Ve-
- 3 hicle Behavior in Challenging Scenarios.” *Journal of Field Robotics* 37.
- 4 Kuwata, Yoshiaki, Michael T. Wolf, Dimitri Zarghitzky, and Terrance L. Huntsberger. 2014.
- 5 “Safe Maritime Autonomous Navigation with COLREGS, Using Velocity Obstacles.”
- 6 *IEEE Journal of Oceanic Engineering* 39 (1): 110–119.
- 7 Lee, Changyu, Jinwook Park, and Jinwhan Kim. 2025. “Efficient COLREGs-Compliant
- 8 Collision Avoidance Using Turning Circle-Based Control Barrier Function.”
- 9 arXiv:2504.19247.
- 10 Markgraf, Hannah, Shambhuraj Sawant, Hanna Krasowski, Lukas Schäfer, Sébastien Gros, and
- 11 Matthias Althoff. 2026. “Safe Reinforcement Learning Using Action Projection: Safe-
- 12 guard the Policy or the Environment?” *Transactions on Machine Learning Research*.
- 13 arXiv:2509.12833.
- 14 Meyer, Eivind, Amalie Heiberg, Adil Rasheed, and Omer San. 2020. “COLREG-Compliant Col-
- 15 lision Avoidance for Unmanned Surface Vehicle Using Deep Reinforcement Learning.”
- 16 *IEEE Access* 8. arXiv:2006.09540.
- 17 Müller, Henrik, and Daniel Kudenko. 2025. “Improving the Effectiveness of Potential-Based
- 18 Reward Shaping in Reinforcement Learning.” In *Proceedings of the International Con-*
- 19 *ference on Autonomous Agents and Multiagent Systems (AAMAS)*. arXiv:2502.01307.
- 20 Müller, Marlon, Florian Finkeldei, Hanna Krasowski, Murat Arcak, and Matthias Althoff. 2026.
- 21 “Falsification-Driven Reinforcement Learning for Maritime Motion Planning.” *Ocean*
- 22 *Engineering* 361: 125579. arXiv:2510.06970.
- 23 Ng, Andrew Y., Daishi Harada, and Stuart Russell. 1999. “Policy Invariance Under Reward
- 24 Transformations: Theory and Application to Reward Shaping.” In *Proceedings of the*
- 25 *International Conference on Machine Learning (ICML)*, 278–287.
- 26 Oh, Donggeon David, Duy P. Nguyen, Haimin Hu, and Jaime F. Fisac. 2025. “Provably Optimal
- 27 Reinforcement Learning under Safety Filtering.” arXiv:2510.18082.
- 28 Patil, Mayur S., Nataraj Sudharsan, Veneela Ammula, Jude Tomdio, Jin Wang, Michael Kei,
- 29 Sivakumar Rathinam, and Prabhakar R. Pagilla. 2026. “COLREGs Compliant Col-
- 30 lision Avoidance and Grounding Prevention for Autonomous Marine Navigation.”
- 31 arXiv:2603.02484.
- 32 Pizarro Bejarano, Federico, Lukas Brunke, and Angela P. Schoellig. 2025. “Safety Filtering
- 33 While Training: Improving the Performance and Sample Efficiency of Reinforcement
- 34 Learning Agents.” *IEEE Robotics and Automation Letters*. arXiv:2410.11671.
- 35 Raffin, Antonin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah
- 36 Dormann. 2021. “Stable-Baselines3: Reliable Reinforcement Learning Implementa-
- 37 tions.” *Journal of Machine Learning Research* 22 (268): 1–8.
- 38 Sarhadi, Pouria, Wasif Naeem, and Nikolaos Athanasopoulos. 2022. “A Survey of Recent Ma-
- 39 chine Learning Solutions for Ship Collision Avoidance and Mission Planning.” *IFAC-*
- 40 *PapersOnLine*. arXiv:2207.02767.
- 41 Schulman, John, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. 2016.
- 42 “High-Dimensional Continuous Control Using Generalized Advantage Estimation.” In
- 43 *International Conference on Learning Representations (ICLR)*.
- 44 Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. 2017. “Proxi-
- 45 mal Policy Optimization Algorithms.” arXiv:1707.06347.
- 1 Shen, Haiqing, Hirotada Hashimoto, Akihiko Matsuda, Yuuki Taniguchi, Daisuke Terada, and

- 2 Chen Guo. 2019. “Automatic Collision Avoidance of Multiple Ships Based on Deep Q-
3 Learning.” *Applied Ocean Research* 86: 268–288.
- 4 Trott, Alexander, Stephan Zheng, Caiming Xiong, and Richard Socher. 2019. “Keeping Your
5 Distance: Solving Sparse Reward Tasks Using Self-Balancing Shaped Rewards.” In *Ad-
6 vances in Neural Information Processing Systems (NeurIPS)*.
- 7 Vaaler, Aksel, Svein Jostein Husa, Daniel Menges, Thomas Nakken Larsen, and Adil Rasheed.
8 2024. “Modular Control Architecture for Safe Marine Navigation: Reinforcement Learn-
9 ing and Predictive Safety Filters.” arXiv:2312.01855.
- 10 Wabersich, Kim P., and Melanie N. Zeilinger. 2021. “A Predictive Safety Filter for Learning-
11 Based Control of Constrained Nonlinear Dynamical Systems.” *Automatica* 129: 109597.
- 12 Zhao, Luman, and Myung-Il Roh. 2019. “COLREGs-Compliant Multiship Collision Avoidance
697 Based on Deep Reinforcement Learning.” *Ocean Engineering* 191: 106436.