

1 连续动作空间下基于投影式安全盾的可证明 COLREGs 方向合规无人船避碰

2 **Weiyu Tang**

3 Graduate Research Assistant

4 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

5 School of Naval Architecture, Ocean & Civil Engineering

6 Shanghai Jiao Tong University, Shanghai, 200240, China

7 Email: weiyutang@sjtu.edu.cn

8 **Jie Xue, Ph.D.***

9 Assistant Research Professor

10 State Key Laboratory of Ocean Engineering

11 School of Naval Architecture, Ocean and Civil Engineering

12 Shanghai Jiao Tong University, Shanghai, 200240, China

13 Email: j.xue@sjtu.edu.cn

14 **Peijie Yang**

15 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

16 School of Naval Architecture, Ocean & Civil Engineering

17 Shanghai Jiao Tong University, Shanghai, 200240, China

18 Email: yangpeijie21@sjtu.edu.cn

19 **Qianbing Li**

20 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

21 School of Naval Architecture, Ocean & Civil Engineering

22 Shanghai Jiao Tong University, Shanghai, 200240, China

23 Email: qianbing_li@sjtu.edu.cn

24 Total Number of Pages: 【待填】

25 Submitted [Submission Date]

26 *Corresponding Author

1 Abstract

2 Objectives : 本文旨在为自主水面航行器的避碰控制建立一种在连续控制量上逐步成立的
3 《国际海上避碰规则》方向合规保证, 并界定其适用范围。该规则的让路条款具有方向性
4 : 未碰撞但从错误一侧通过的航迹仍属违规。

5 Methods : 我们把让路条款表述为控制量平面上的半平面约束, 与执行器量程及单步
6 无碰条件求交, 得到凸的安全控制集, 并以一个二维二次规划把策略输出投影到该集合的
7 最近可行点; 该投影并入环境转移, 使策略在训练中即适应修正。数据为公开的双船相遇
8 仿真场景库, 共 2000 个算例; 官方划分为 1400 训练 / 600 测试, 我们把官方训练侧再切
9 为 1300 训练与 100 验证。共设 9 种对照配置构成单变量递进序列, 每种以 8 个固定种子
10 训练。

11 Findings : 在投影可行的每一让路决策步上, 方向合规由硬约束构造式成立, 与训练
12 结果及随机种子无关; 转入兜底的步不在此列。测试集上每局违规次数为【待填】、碰撞
13 率为【待填】、到达率为【待填】; 到达率不作为效能主张。

14 Novelty : 据我们所知, 这是首个在连续控制量上实现该规则方向合规的投影式安全机
15 制, 并给出分级的保证陈述, 逐条附假设与边界, 且列出未被证明的部分。

16 Practical Applications : 该机制的合规判定不依赖训练结果, 可作为既有控制系统之上
17 的合规校验层, 用于功能验证与责任界定, 其保证只覆盖投影可行的让路步。在线计算量
18 为每步一个二维二次规划, 无需加速硬件即可实时运行。

1. Introduction

无人水面航行器正逐步进入与有人船共航的公共水域，其避碰行为必须遵守《国际海上避碰规则》（COLREGs）（IMO, 1972）。与陆上交通规则相比，COLREGs 有一个决定性的不同：它的让路条款是有方向性的。对遇态势中两船各自向右转向；交叉态势中让路船向右避让、直航船保向保速；追越态势中追越船负责让清。也就是说，一个动作即使在几何上避免了碰撞，若转向方向违反规则，仍然是违规的。一条从左侧绕过去、全程没有碰撞的轨迹，在海事上并不合格。

这一点使 COLREGs 合规无法用“最终有没有撞上”来验证，也使它成为安全强化学习中一个不太常见的问题类型：需要保证的不是一个状态量的界，而是每一步动作落在哪个方向的半平面里。现有工作沿两条路推进，各自让掉了一样关键的东西。

第一条路是离散动作加动作屏蔽。它把动作空间离散成有限网格，每一步先用规则状态机算出合规的动作子集，再屏蔽掉其余动作（Krasowski and Althoff, 2024），合规性因此可以证明：被屏蔽的动作根本不可能被选中，而这个保证既不依赖训练结果，也不受随机种子影响。它的代价是放弃了连续控制。真实的舵机与推进器本是连续量，离散网格一方面引入量化抖动，一方面把控制精度锁死在网格分辨率上。对本文的任务还有一处更具体的损失：COLREGs 要求让路转向足够明显，这在数学上是一个下确界，而网格往往取不到它，只能退到最近的档位，于是每一次合规让路都要比规则所需多转一些。

第二条路是连续动作加软性奖励。它保留连续控制，把 COLREGs 写成奖励函数里的一项惩罚（Meyer et al., 2020; Heiberg et al., 2022; Müller et al., 2026）。控制虽然连续了，保证却随之消失：奖励只能塑造策略的期望行为，并不能排除任何一个具体的违规动作，合规率因而随种子起伏，也随训练进程起伏。

于是连续动作 $\cap$ 可证明方向合规 $\cap$ COLREGs 这个三重交集是空的。本文用投影式安全盾把它填上：规则状态机给出合规方向的半平面，与单步无碰约束、动作箱一起构成安全动作集，二次规划把策略的连续指令投影到该集合上最近的点。关键在于可枚举这个前提可以被可投影替代。合规方向恰好是一个半平面，投影到半平面与箱的交集上是一个小规模二次规划，而投影解满足硬约束这件事是构造式的，与训练无关。策略以安全盾在环的方式训练，因而会观察并适应投影带来的修正。

我们同时认为，这类工作真正的难点不只是把机制搭起来，还在于诚实地说清这一层到底证明了什么。在安全强化学习的一些文献中，“provable”一词的实际作用域往往小于读者的预期。因此本文的第二项工作，是把可证明层逐条分档：有的是严格引理，有的构造式成立，有的只是保守的充分条件，还有的仍停留在设计、尚未经过闭环验证。每一档都附上完整的假设清单与作用域限制，并明确写出哪些部分没有被证明。

贡献。

1. 连续动作空间中的投影式 COLREGs 安全盾（“安全动作集与投影”一节）。合规方向作为硬区间约束进入二次规划，因此每一个投影可行的让路步的方向合规是构造式成立的，不依赖训练结果、不受种子方差影响。
2. 一个分级的可证明安全层（“安全性保证与作用域”一节）：远场单步无碰（严格可证，且多他船下是无损的合取推广）、每让路步方向合规（构造式）、紧急迫近不可避的可靠充分条件证书（替换掉此前只检查转向、会漏掉加减速逃逸的不可靠的判据）。我们进一步证明由该证书定义的可清障集是控制不变的，并据此设计后备机动终端约束。该结论仍为暂定，闭环接线与官方口径复算尚未完成，本文如实标注。
3. 一个把机制逐级拆开的实验设计（“Experimental Design”一节）：9 种配置构成一

条连通的单变量递进序列，相邻两级之间只改动一个变量，从离散基线一路走到完整方法；其中两跳带有不可分割的伴随变量，我们把这一点写在递进序列表的表注里，而不是藏进脚注。

4. 对边界的完整交代（“Results”一节与局限节）：包括少数种子的训练不稳定、超越态势在本基准上无法验证、以及我们不主张的那些东西。

我们不主张的。 不主张可证明无碰；不主张到达率优于离散基线；不主张覆盖机动他船或多船方向冲突；不主张比手工调参的几何控制器更平顺。

2. Related Work

避碰规则合规的研究最早集中在模型驱动的方法上。速度障碍法用相对速度锥判断碰撞危险并选出规避速度，后被纳入 COLREGs 的让路语义 (Kuwata et al., 2014)，并推广到更一般的船舶会遇 (Huang et al., 2019)。模型预测控制是另一条主线：在有限预测时域上评估各候选机动的碰撞危险与 COLREGs 合规度并择优执行 (Johansen et al., 2016)，其分支航向变体经过了海上实测 (Eriksen et al., 2019)，并在具挑战性的会遇场景中完成了全尺度验证 (Kufolalor et al., 2020)；更早的协议式方法把规则写成船间可协商的行为约定 (Benjamin et al., 2006)。近期这条线转向控制障碍函数与凸优化，用转向圆控制障碍函数表达让路机动 (Lee et al., 2025)，或用凸优化同时处理规则合规与防搁浅 (Patil et al., 2026)。这些方法多建立在标准船舶操纵模型之上 (Fossen, 2011)，其保证来自显式约束或规则编码，但控制律由手工设计，不含从数据中学到的策略。

随着深度强化学习的发展，避碰策略开始从数据中学习。一种常见做法是把 COLREGs 写成随方位与距离衰减的软性惩罚，在连续控制上训练出合规倾向 (Meyer et al., 2020)，或用碰撞风险度量把惩罚做成可调的风险门控 (Heiberg et al., 2022)；也有工作面向多船或单船生成合规的规避时机与路径 (Zhao and Roh, 2019; Chun et al., 2021)，以及在欠驱动无人艇上验证简洁的强化学习避障 (Cheng and Zhang, 2018)。这类工作多以近端策略优化 (Schulman et al., 2017) 为策略主干，可用有界的 Beta 分布 (Chou et al., 2017) 参数化连续动作，以避开高斯策略在动作边界处的截断偏差。它们保住了连续控制的精细度，但合规只由奖励诱导：奖励改变的是策略的期望行为，无法排除任何一个具体的违规动作，合规率因而随种子和训练进程波动。

在软奖励之外，安全强化学习 (García and Fernández, 2015) 研究如何为学习策略附加硬性保证。动作屏蔽在离散动作上按时序逻辑规范剔除不安全动作 (Alshiekh et al., 2018)，其可实现的形式已被推广到连续动作空间，但针对通用任务、未涉及海事规则 (Kim et al., 2024)。在连续控制上，控制障碍函数的二次规划 (Ames et al., 2019) 与预测式安全滤波 (Wabersich and Zeilinger, 2021) 以最小干预修正动作；后者也被接到海事强化学习之上，但只约束碰撞、不含 COLREGs 的方向条款 (Vaaler et al., 2024)。动作投影则借助可达性分析构造安全动作集：一种实现以多项式 zonotope 保证投影的安全性 (Kochdumper et al., 2023)，另一项工作比较了把投影盾并入环境转移与嵌入可微策略两种做法，并证明在策略梯度族（以广义优势估计一类算法为前提，(Schulman et al., 2016)）下两者的学习目标相同 (Markgraf et al., 2026)。这条线在连续动作上给出了对碰撞或状态约束的硬保证，但没有一项把 COLREGs 让路条款的方向性写进安全集。

最接近本文的是 (Krasowski and Althoff, 2024)。该工作把 COLREGs 形式化为时序逻辑谓词与状态机，在 49 个离散动作上以动作屏蔽实现可证明的规则合规；它既是本文复现的离散基线，也提供了本文使用的场景库与状态机阈值。作者在文中把连续动作空间下的动作投影列为未来方向，并指向基于可达性的投影 (Kochdumper et al., 2023)。沿这一

TABLE 1 符号表

符号	含义	符号	含义
s	本船状态向量	ρ	相遇态势 (ρ_0 – ρ_5)
θ, v	艏向、航速	$\mathcal{U}_{\text{colregs}}(\rho)$	规则允许的控制集
$u = (a, \omega)$	控制 (加速度、转艏率)	$\mathcal{U}_{\text{cf}}(s)$	无碰撞约束集
a, ω	纵向加速度、转艏率	$\mathcal{U}_{\text{box}}$	执行器物理量程箱
Δt	决策周期 (零阶保持)	$\mathcal{P}(s, \rho)$	安全动作集
$a_{\max}, \omega_{\max}$	执行器量程上限	$\Pi_{\mathcal{P}}$	向 $\mathcal{P}$ 的欧氏投影
$a_{\text{op}}, \omega_{\text{op}}$	策略动作箱半宽	$u_{\text{policy}}, u_{\text{safe}}$	策略输出、实际执行控制
$v_{\max}$	航速上限	Δ_{lt}	明显转向阈值 (航向)
v_{bnd}	步内航速上界	Δ_{nt}	直航容差角
$\oplus$	Minkowski 和	T_M	机动段时长
$\text{disk}(r)$	半径 r 的闭圆盘	ω_{turn}	合规转艏率下确界
$R_{\text{circ}}, r_{\text{insc}}$	外接圆、内切圆半径	$\varepsilon_a, \varepsilon_\omega$	直航保速、保向容差
$\mathcal{O}$	他船占据	T_h, T_{pred}	碰撞可能、紧急预测时域
d	两船中心距	$R_{\text{box}}(t)$	本船可达中心过近似集
p_e, p_m	本船、他船中心位置	A	可清障集
$v_{\text{obs}, \max}$	他船速度上界 (假设)	γ	折扣因子
K	回合步数上限	α, β	Beta 分布形状参数
Φ	势函数 (奖励塑形)	r	单步回报

1 方向，同组的后续工作转入连续动作，却以软性奖励结合证伪式训练来逼近合规，没有给
2 出硬保证 (Müller et al., 2026)。本文承接 (Krasowski and Althoff, 2024) 提出的方向，在连
3 续控制上给出方向合规的构造式保证，并以更轻的 zonotope 加二次规划投影 (Markgraf et
4 al., 2026) 替代较重的多项式 zonotope。
5 方向约束会在紧急与近域收紧可行动作集、可能损失终端效率，本文因此用势函数
6 型塑形帮助策略追回效率。势函数型塑形不改变最优策略集 (Ng et al., 1999)，但朴素的距
7 离型塑形容易停在目标附近 (Trott et al., 2019)，单一连续势也难以根治这一问题 (Müller
8 and Kudenko, 2025)，故本文改用线性核并把“真正到达”设为终端条件，与把控制指标
9 编入塑形并给出保证的做法一致 (De Lellis et al., 2024)。安全盾对性能与终端行为的影
10 响另有专门研究：训练中纳入滤波并惩罚修正量可提升样本效率 (Pizarro Bejarano et al.,
11 2025)，足够宽松的滤波不损渐近最优 (Oh et al., 2025)，而安全项与目标项对冲会造成目
12 标前停滞 (Grover et al., 2023)。本文据此设置与投影修正量成正比的动作混叠惩罚，并保
13 留反向证据：预测式安全滤波在某些海事设置下并不损失性能 (Vaaler et al., 2024)。

14 3. Problem Formulation

15 3.1 系统建模与记号

16 全文所用记号汇总于表 1。角度一律折算到 $(-\pi, \pi]$ 。本文约定右舷为正、左舷为负，故
17 转艏率 $\omega < 0$ 表示右转， $\omega > 0$ 表示左转。

18 **本船运动学模型。**我们把受控船舶建模为受偏航约束的质点，状态 $s =$
19 $[p_x, p_y, \theta, v]^\top \in \mathbb{R}^4$ ，以纵向加速度 a 与转艏率 ω 为控制输入：

$$\dot{s} = [v \cos \theta, v \sin \theta, \omega, a]^\top, \quad u = [a, \omega]^\top, \quad (1)$$

20 控制受箱约束 $|a| \leq a_{\max}$ 、 $|\omega| \leq \omega_{\max}$ ，航速受 $0 \leq v \leq v_{\max}$ 限制，决策以零阶保持方式

TABLE 2 模型与安全盾参数

类别	符号	含义	取值
船舶与运动学	$L \times W$	船体尺度	$175 \times 25.4 \text{ m}$
	$a_{\max}$	纵向加速度上限	0.24 m/s^2
	$\omega_{\max}$	转艏率上限	0.03 rad/s ($\approx 1.7^\circ/\text{s}$)
	$v_{\max}$	航速上限	9.5 m/s
	Δt	决策周期 (零阶保持)	10 s
	K	回合步数上限	170 ($= 1700 \text{ s}$)
	R_{circ}	外接圆半径 (过近似)	88.4 m
	r_{insc}	内切圆半径 (欠近似)	12.7 m
	v_{bnd}	步内航速上界	$v_{\max} + a_{\max}\Delta t = 11.9 \text{ m/s}$
安全盾	$a_{\text{op}}, \omega_{\text{op}}$	常规操作动作箱半宽	$0.048 \text{ m/s}^2, 0.018 \text{ rad/s}$
	Δ_{lt}	明显转向的航向阈值	20°
	T_M	机动段时长	40 s
	ω_{turn}	合规转艏率下确界	$\Delta_{\text{lt}}/T_M = 0.008727 \text{ rad/s}$
	$\varepsilon_a, \varepsilon_\omega$	直航态保速/保向容差	$0.016 \text{ m/s}^2, 0.004363 \text{ rad/s}$
	—	舷侧扇区半角	112.5°
	—	对遇航向带 / 追越判定角	$\pm 5^\circ / 67.5^\circ$
	T_h	碰撞可能性检查时域	420 s

表注。 ω_{turn} 是合规转艏率的下确界，其推导见式 (4)。常规操作动作箱的半宽恰等于量化网格的张成范围，使两种动作空间的控制权限相同、仅分辨率不同；物理满程 $\pm a_{\max}/\pm \omega_{\max}$ 只留给安全盾与紧急控制器，不属于策略权限。

1 每 Δt 施加一次。航速界的施加时机需要明确：环境按式 (1) 完成整个决策步的积分之后，
2 再把步末航速截入 $[0, v_{\max}]$ ，因此步内航速可短暂超出 $v_{\max}$ ，单步位移界必须把步内加速
3 算进去，取 $v_{\max}\Delta t + \frac{1}{2}a_{\max}\Delta t^2$ ；步末航速上界记为 $v_{\text{bnd}} = v_{\max} + a_{\max}\Delta t$ ，用于后备机动的
4 可达集包络（表 2）。安全盾内部用于验证后备机动的积分则在积分过程中即施加饱和，
5 是一个更保守的模型。全文凡涉及单步位移界的推导一律取前者。

6 选择这一模型层级是出于两点考虑。第一，COLREGs 的让路条款是对航向与航速
7 变化的规定，而式 (1) 恰好把这两者直接作为控制输入，因此规则可以不经中间变量地写
8 成对 u 的约束。这是本文全部安全机制得以落在动作空间里的前提。第二，更精细的水动
9 力模型会引入一批依船而异、难以辨识的系数，使规则约束与船型参数纠缠，反而削弱结
10 论的普适性。

11 **建模对象与占据表示。**我们以一条大型集装箱船为对象，其几何、操纵性能界与
12 决策周期见表 2。这一组数值刻画的是大型商船的典型量级，其中一点对全文都有影响：
13 转艏率上限折合仅约 $1.7^\circ/\text{s}$ ，意味着一次 20° 的明显转向需十余秒才能完成，慢于一个决
14 策周期。这一“操纵慢于决策”的特征既是安全约束必须前瞻的原因，也是后文递归可行
15 性得以成立的几何基础。

16 船体占据用矩形表示。我们同时用到它的两个圆近似，各有明确分工：外接圆
17 $\text{disk}(R_{\text{circ}})$ 过近似船体，用于构造“一定不碰”的充分条件（圆盘不交，因此船体不交）
18 ；内切圆 $\text{disk}(r_{\text{insc}})$ 欠近似船体，用于构造“一定会碰”的充分条件（内切圆与障碍相交
19 ，因此船体与障碍相交）。两个方向的判据各取一个圆，是保证两侧结论都单侧保守的关
20 键。

21 **他船与感知。**他船以其船体矩形占据表示。除特别声明外，在需要外推的场合我
22 们对他船取恒速外推；这一假设的代价在“安全性保证与作用域”一节逐条标注。他船的

1 当前状态视为可观测。

2 3.2 问题表述

3 我们考虑开阔水域的双船相遇，并作如下假设：

4 (A1) 开阔水域，无航道分隔、无静态障碍、无岸线约束；

5 (A2) 场景中有一条受控船与一条他船，均为机动船；

6 (A3) 受控船动力学由式 (1) 描述，控制以 Δt 为周期零阶保持；

7 (A4) 他船当前状态无量测误差地可得；

8 (A5) 相遇初始时刻不存在任何已生效的让路义务。

9 假设 (A2) 不是为了简化而作的让步，而是 COLREGs 本身的适用边界：该规则集
10 是成对制定的，当三船以上同时相遇、且各自的义务互相冲突时（例如对一条船须保向保
11 速、对另一条须避让），公约本身并未规定如何取舍。我们在“安全性保证与作用域”一
12 节给出多他船情形下各结论如何合成、以及在何处必然失效。

13 在此设定下，令 ρ_t 为 t 时刻的相遇态势， $\mathcal{U}_{\text{colregs}}(\rho_t) \subseteq \mathbb{R}^2$ 为该态势下规则允许的
14 控制集合（“COLREGs 让路条款在动作空间中的形式化”一节给出其显式形式）。我们
15 要求的策略是

$$\pi: \mathcal{S} \rightarrow \mathbb{R}^2 \quad \text{使得} \quad u_t \in \mathcal{U}_{\text{colregs}}(\rho_t) \cap \mathcal{U}_{\text{cf}}(s_t) \quad \forall t, \quad (2)$$

16 其中 $\mathcal{U}_{\text{cf}}$ 为无碰撞约束集。式 (2) 与“把合规写进奖励”有本质区别，它要求每一步执行
17 的动作都落在集合内，而非要求某个期望值达到最优。

18 当动作集有限时，式 (2) 有一个直接解法，即枚举全部动作、逐个检验、屏蔽不合
19 规者。这条路要求动作可枚举，因而与连续控制不相容；而船舶的舵与推进本是连续量，
20 量化会同时带来抖动与精度损失。本文的核心思路是把“可枚举”这一前提替换为“可投
21 影”。

22 我们将证明，COLREGs 的让路条款在动作空间中恰好表现为半平面约束（
23 “COLREGs 让路条款在动作空间中的形式化”一节），无碰撞条件可写成线性不等式（
24 “安全动作集与投影”一节），因此式 (2) 的可行集是二维空间中若干半平面与一个矩形
25 之交，是一个凸多边形。向凸集的投影存在且唯一，可由一个规模极小的二次规划求得。
26 这样，“逐步满足约束”便从枚举问题变成投影问题，从而可直接用于连续动作。

27 4. Methodology

28 本节给出投影式安全盾的构造。我们先把 COLREGs 让路条款形式化为动作空间中的集合
29 约束（“COLREGs 让路条款在动作空间中的形式化”一节），据此构造安全动作集与投
30 影算子（“安全动作集与投影”一节）；随后说明策略如何在带盾环境中学习（“策略学
31 习”一节）；最后分析该机制能够严格保证什么、不能保证什么（“安全性保证与作用
32 域”一节）。

33 4.1 COLREGs 让路条款在动作空间中的形式化

34 相遇态势。我们用一个规则状态机把当前相遇归入六类：

【图 1（两格：a 系统框图·b 动作平面几何）占位——数据到手后替换】

Figure 1 方法总览。（a）系统框图。27 维观测经策略网络给出期望控制 $u_{\text{policy}} = (a, \omega)$ ；策略的输出分布是支撑为闭区间的 Beta 分布，故采样动作按构造落在动作箱内（对比：无界高斯须裁剪，裁剪切断策略梯度；且高斯的微分熵无上界，与常数熵系数配合会持续推大标准差——这两条缺陷 Beta 分布同时封闭）。规则状态机把当前相遇判入六类态势 ρ_0 – ρ_5 ，让路三类另给出规则要求的转向一侧。安全动作集 $\mathcal{P}$ 由执行器量程、合规方向半平面与单步无碰约束求交而成，二次规划把 u_{policy} 投影为 u_{safe} 后送入环境。该投影并入环境转移，即安全盾在训练回路之内（图中回流箭头），策略因而在训练过程中即适应投影的存在，而非训练结束后再与滤波器磨合。安全动作集为空或不构造的处置按态势分支：紧急态 ρ_5 走独立通道，直接交紧急控制器（该态不构造无碰约束、不求解二次规划）； ρ_0 – ρ_4 仅在安全动作集为空时降级——先判占据几何退化（返回箱内投影），否则依次尝试放松方向约束与最小化碰撞风险。两条通道互斥。实线深色框为可严格保证的模块，虚线浅色框为经验模块。（b）动作平面 (a, ω) 上的几何，按策略动作箱的尺度绘制（安全盾的二次规划实际求解于更大的执行器物理量程箱）。横线为合规方向约束的边界 $\omega = -\omega_{\text{turn}}$ ，其下方为合规半平面；斜线为单步无碰的线性约束；两者与动作箱之交即 $\mathcal{P}$ （深色填充）。空心点为 7×7 量化网格。期望控制落在 $\mathcal{P}$ 外时被投影到最近的可行点，箭头长度即投影修正量。连续动作能精确取到 ω_{turn} 这一合规下确界；量化网格上最近的合规档位为 0.012 rad/s ，比该下确界高出 37.5% 。

$\rho \in \{\rho_0 \text{ 无冲突}, \rho_1 \text{ 直航}, \rho_2 \text{ 对遇}, \rho_3 \text{ 交叉}, \rho_4 \text{ 追越}, \rho_5 \text{ 紧急}\}.$

- 1 判定依据是相对方位所落的扇区（舷侧扇区各 112.5° ）、两船航向之差（对遇带 $\pm 5^\circ$ ，
- 2 追越判定 67.5° ）以及在 420 s 时域内是否存在碰撞可能。让路态势（ ρ_2, ρ_3, ρ_4 ）同时确
- 3 定规则要求的转向一侧。
- 4 **紧急态的进入与解除。** 上述扇区与航向判据，连同 420 s 时域内的碰撞可能性，决
- 5 定 ρ_0 – ρ_4 的归属；紧急态 ρ_5 的进入则另用一个更强的集合预测判据，二者机制不同。取
- 6 预测时域 $T_{\text{pred}} = 180 \text{ s}$ ，以决策步长 Δt 采样区间。在每个区间上，他船以点质量可达集外
- 7 近似为一个圆盘：圆心取其恒速外推 $p_m + v_{mt}$ ，半径为随时间增长的可达半径加他船外接
- 8 圆；本船取保向保速动作 $u_{\text{keep}} = (0, 0)$ 下的占据，并以其在区间两端位形的凸包保守覆盖
- 9 整段。只要存在一个采样区间使这两个占据集相交，当前相遇即判为紧急。该判据对两侧
- 10 占据集都作外近似，因而是单侧保守的：它可能偏早进入紧急，却不会漏掉时域内真正会
- 11 发生的紧急。进入 ρ_5 后，状态机将其维持到解除判据成立——他船落到本船后方、两船

- 1 航向相互背离、且中心距足够大三者同时满足（该解除判据的精确形式及其对原文一处笔
2 误的更正，见后文对既有设定的偏离声明）——因此 ρ_5 会贯穿整个紧急机动，不随单步
3 预测的起伏反复切换。

4 **合规动作集。** 每一类态势对应一个显式的控制约束集：

$$\mathcal{U}_{\text{colregs}}(\rho) = \begin{cases} \mathcal{U}_{\text{box}}, & \rho = \rho_0, \\ \{|a| \leq \varepsilon_a\} \cap \{|\omega| \leq \varepsilon_\omega\}, & \rho = \rho_1, \\ \{\omega \leq -\omega_{\text{turn}}\}, & \rho \in \{\rho_2, \rho_3\}, \\ \{\omega \leq -\omega_{\text{turn}}\} \text{ 或 } \{\omega \geq +\omega_{\text{turn}}\}, & \rho = \rho_4, \\ \mathcal{U}_{\text{box}}, & \rho = \rho_5, \end{cases} \quad (3)$$

- 5 其中 $\mathcal{U}_{\text{box}} = \{|a| \leq a_{\text{max}}\} \cap \{|\omega| \leq \omega_{\text{max}}\}$ 是执行器物理量程构成的动作箱。这里需要区分
6 两个箱：策略的动作空间是较窄的常规操作箱 $\{|a| \leq a_{\text{op}}\} \cap \{|\omega| \leq \omega_{\text{op}}\}$ （与量化网格的张
7 成范围相同，见表 2 表注），而安全盾的投影与兜底一律在物理量程箱上求解。这样安排
8 是必要的：安全盾必须能够在需要时动用超出策略权限的操纵能力，否则一旦策略的窄箱
9 与无碰撞约束不相容，本来可解的局面会被误判为不可行。其代价是安全盾实际施加的
10 控制可以落在策略动作箱之外——这一点在观测中如实回传（见“策略学习”一节），并
11 在报数时按控制来源分类。三类约束的语义分别是：直航态须保向保速，故容差取小量
12 $\varepsilon_a = 0.016 \text{ m/s}^2$ 、 $\varepsilon_\omega = 0.004363 \text{ rad/s}$ ；对遇与交叉态须向右转且幅度足够明显；追越态
13 的让清一侧由相对几何确定，可左可右。紧急态 ρ_5 不施加方向约束，其处置见“安全动
14 作集与投影”一节末段。这是本方法保证覆盖不到的部分，我们在“安全性保证与作用
15 域”一节明确划出边界。

- 16 **“足够明显”的量化及其下确界性质。** 公约要求让路动作幅度大到能被对方及时
17 察觉。把“明显”量化为在机动时间 T_M 内航向改变不少于 Δ_{lt} ，即得阈值

$$\omega_{\text{turn}} = \frac{\Delta_{\text{lt}}}{T_M} = \frac{20^\circ}{40 \text{ s}} \approx 0.008727 \text{ rad/s}. \quad (4)$$

- 18 ω_{turn} 是合规转艏率的下确界：任何 $|\omega| \geq \omega_{\text{turn}}$ 的转向都合规，且该界不可再降。
19 这一性质带来一个可以直接算出来的结构性差异。若动作空间被量化为 $7 \times 7 = 49$
20 点的网格（转艏轴取值 $\{0, \pm 0.006, \pm 0.012, \pm 0.018\} \text{ rad/s}$ ；量化动作空间另设第 50 个动
21 作，它不是网格点，而是一个由紧急控制器在线算出的状态相关动作，紧急态下动作屏蔽
22 只保留这一个动作），则由于 $0.006 \times 40 \text{ s} = 13.75^\circ < 20^\circ$ 不满足要求，网格上最小的合规
23 档位是 0.012 rad/s ，比下确界高出 37.5%。也就是说，量化动作空间每执行一次合规让
24 路，转艏幅度都必须超出规则要求约三成七，代价是多余的航向偏离与额外的舵动作。连
25 续动作可以精确取到式 (4) 的界，这一优势与训练过程无关，纯由动作空间的分辨率决定
26 （图 1b）。

27 4.2 安全动作集与投影

- 28 **无碰撞约束。** 对当前状态 s 与他船占据 $\mathcal{O}$ ，我们要求施加的控制在下一个决策步末不致
29 使两船体相交。直接写出该条件是非凸的；我们取一个保守的凸内近似：在本船与他船占
30 据之间取分离超平面，将“下一步落点位于该超平面安全侧”作为约束，并对落点关于 u
31 做一阶展开，得到线性不等式集 $\mathcal{U}_{\text{cf}}(s)$ 。保守性的方向是单侧的： $\mathcal{U}_{\text{cf}}$ 内的控制一定满足
32 原条件，反之不然。

安全动作集与投影。安全动作集取三者之交

$$\mathcal{P}(s, \rho) = \mathcal{U}_{\text{box}} \cap \mathcal{U}_{\text{colregs}}(\rho) \cap \mathcal{U}_{\text{cf}}(s), \quad (5)$$

它是 $\mathbb{R}^2$ 中的凸多边形。给定策略给出的期望控制 u_{policy} ，实际执行的控制取其在 $\mathcal{P}$ 上的欧氏投影

$$u_{\text{safe}} = \Pi_{\mathcal{P}}(u_{\text{policy}}) = \arg \min_{u \in \mathcal{P}} \|u - u_{\text{policy}}\|_2^2. \quad (6)$$

式 (6) 是一个两变量、约束数为个位数的二次规划，其解存在且唯一。我们把 $\|u_{\text{safe}} - u_{\text{policy}}\|$ 记为投影修正量，它度量策略输出与规则要求之间的差距，并在实验中作为一项诊断指标上报。

不可行时的处置。 安全动作集为空时投影无解，此时须由一条不提供保证的替代规则给出控制，本文称之为兜底。兜底的处置按态势分支，而非按一条固定优先级依次尝试。紧急态 ρ_5 是一条独立通道：该态不构造无碰撞约束、不求解式 (6)，直接交给紧急控制器（一个基于位置跟踪的三模式几何律）。其余态势（ ρ_0 - ρ_4 ）只在 $\mathcal{P} = \emptyset$ 时降级，且先判一种退化：若线性化给不出可用的分离方向——本船标称落点与他船膨胀占据的圆心重合，或本船在该分离方向上没有控制权限（近零速时落点对转艏率的雅可比降秩）——则直接返回箱内投影占位（记为“退化”），此时不再求解任何二次规划；否则先放松方向约束、只保留动作箱与无碰撞约束求解（记为“放松”），仍不可行才改解一个最小化最坏碰撞侵入量的软约束二次规划（记为“碰撞风险最小化”）。须注意两点：占据仅仅已经相交不会触发退化，那种情形照常走放松与碰撞风险最小化；而放松与碰撞风险最小化都在执行器物理量程上求解并整块丢弃合规约束，故转艏率可达 ω_{max} 。因此紧急控制器与后三支是互斥的：前者只出现在 ρ_5 ，后三支只出现在 ρ_0 - ρ_4 。这一支是经验性的，不提供任何保证；我们不试图掩盖这一点，而是在“安全性保证与作用域”一节给它配一个可判定的边界：一个保守判据，用来识别“碰撞在物理上已不可避”的状态，从而把这段黑箱的适用范围明确出来。

4.3 策略学习

带约束的环境。 我们不把安全盾放在策略之后作为事后纠正，而是把式 (6) 并入环境的转移：策略输出 u_{policy} ，环境施加 u_{safe} 并返回相应的后继状态与回报。这样策略学习到的是经过投影之后的转移，因而会主动适应投影的存在，而不必在训练结束后再与一个陌生的滤波器磨合。

观测空间。 观测为 27 维实向量：受控船状态 4 维（航速、艏向、纵向加速度、转艏率）；目标相关 5 维（距离、剩余步数、艏向与目标朝向区间之差、纵向偏差、横向偏差）加 1 维“是否已在目标框外”的指示位；交通态势 12 维，即前 / 左 / 右 / 后四个方位扇区各取该扇区内最近他船的三个量（距离、相对方位、相邻两个决策步之间的距离增量；该增量以米为单位、未除以 Δt ）；终止相关 5 维（超时、出界、停住、碰撞、到达）。观测层输出原始物理量，归一化在训练包装层完成。以扇区为单位组织交通信息，使观测维数不随他船数目改变。须说明的是，这只解决了观测的维数问题：本文部署的安全盾按单他船实现，遇到多于一艘他船时显式报错而非降级运行，因此多他船既未训练也未评估。

回报函数。 回报由五项相加而成，

$$r = r_{\text{sparse}} + r_{\text{goal}} + r_{\text{velocity}} + r_{\text{deviate}} + r_{\text{colregs}}, \quad (7)$$

各项定义如下，系数取值见表 3。

- 终止稀疏项 r_{sparse} 在回合终止时按事件给出，到达为 c_{goal} 、超时为 c_{time} 、原地停住为 c_{stop} 、碰撞为 c_{coll} ，并对每一个进入紧急控制的决策步给固定惩罚 c_{em} 。它另含一个“驶出航行区”事件 c_{area} ，但本基准场景不带航行区边界，该事件与其观测位在本文全部实验中恒不触发，列出仅为完整交代实现。
- 趋近项为稠密的向目标位移奖励，

$$r_{\text{goal}} = c_{\text{reach}}(\|p_{t-1} - p_g\| - \|p_t - p_g\|), \quad (8)$$

其中 p_g 为目标位置。

- 航速项 r_{velocity} 对航速落在巡航区间 $[2.5, 8.0]$ m/s 之外的部分按偏离量线性惩罚。
- 偏航项 r_{deviate} 惩罚偏离起点至目标参考线的横向距离，并在 2000 m 处饱和。
- 软性合规项 r_{colregs} 为随距离衰减的合规惩罚，其中他船径向速度按其速度上界 10.0 m/s 归一化、指数项施加上限钳制。它只在软性奖励对照组与离散动作屏蔽配置上启用（后者忠实复现 (Krasowski and Althoff, 2024) 的原始设定，该工作在动作屏蔽之外保留了这一惩罚项），无盾基线与本文全部连续动作配置一律置零，因为本文方法的合规由式 (3) 的硬约束承担。各配置取值见表 5。

相对 (Krasowski and Althoff, 2024) 的公开设定，本文有三处偏离，需要显式声明。其一，趋近项 r_{goal} 取上式的差分方向。按另一种常见写法，趋近目标反而得到负回报，与“奖励趋近目标”的意图相悖，我们采用物理上一致的写法。其二，软性合规项 r_{colregs} 的原始参数是在约 150 m 的作用尺度上标定的，而本任务的场景尺度约 8000 m，直接代入会使其指数项发散，故我们将他船径向速度按其速度上界归一化，并对指数项施加上限钳制。其三，紧急态的解除判据含三项合取，即他船落在本船后 $\pm 90^\circ$ 、两船艏向单位向量点积不为正（即航向夹角不小于 90° ），以及中心距不小于 $2L$ 。第三项在原文中字样写作“距离不大于该阈值”，与其自身注文所述的“距离足够大”相悖，我们判为笔误并按物理语义取不小于。该判据决定紧急态的驻留时长，因而影响紧急控制步的占比，故一并声明。

有界动作分布。连续策略通常输出无界高斯分布并在送入环境前裁剪到动作箱。这一组合与式 (6) 相冲突，原因有两点，都与“裁剪”这一操作本身有关。其一，常见实现把裁剪后的动作作用于环境、却把裁剪前的动作作用于策略梯度，于是一旦分布的均值移出动作箱，再往外移动不改变任何回报，梯度进入高原，任何以动作平顺性为目标的惩罚项都失去着力点。其二，高斯分布的微分熵为 $\sum_i \log \sigma_i + \text{const}$ ，没有上限，而熵正则项的系数是常数，于是标准差存在一条“只涨不跌”的通道，把越来越多的采样推到箱外，加剧前一个问题。

我们改用支撑为闭区间的 Beta 分布。动作因此按构造不可能越箱，裁剪退化为恒等映射，上述两条通道同时封闭；平顺性惩罚处处可微，且 Beta 的熵有上限（在均匀分布处取得）。我们额外要求两个形状参数均严格大于 1（由网络输出经 softplus 再加一得到，故恒大于 1）。这一约束不可省。当形状参数小于 1 时 Beta 呈 U 形，密度在两端发散，等价于一个数学形式的 bang-bang 控制；更关键的是此时分布的众数落在区间端点，而区间内部的驻点是密度的极小值，由于评估一律使用确定性动作（取众数），这会静默地污染每一个上报数字，且在聚合指标上无从察觉。需要说明的是，该约束只保证分布单峰且端点密度有限，并不阻止策略选择接近饱和的动作；真正起作用的是“支撑落在箱内”与“熵有上限”这两条。

TABLE 3 回报函数与训练超参

类别	符号	含义	取值
回报函数	c_{goal}	到达（正）	+50
	$c_{\text{time}}, c_{\text{area}}$	超时 / 出界	-25, -5
	$c_{\text{stop}}, c_{\text{coll}}$	原地停住 / 碰撞	-40, -50
	c_{em}	每一步紧急控制	-0.5
	$c_{\text{reach}}, c_v, c_{\text{dev}}$	趋近 / 速度 / 偏航	1.5, -2.0, -0.001
	—	塑形权重（进门/进带/保速/动作增量）	200, 200, 20, 1.0
	—	塑形半径（进门/进带/保速）	500/80/400 m
强化学习	—	策略/价值网络	多层感知机, 2层 $\times$ 64
	—	并行环境数	8
	γ	折扣因子	0.99
	—	熵正则系数（常数）	0.01
	—	学习率	3×10^{-4}
	—	采样步数 / 批大小	2048 / 64
	—	更新迭代轮数	10
	—	GAE 折扣 λ	0.95
	—	裁剪范围	0.2
	—	价值损失系数	0.5
	—	梯度裁剪范数上限	0.5
	—	优势归一化	是
	—	观测/回报归一化	滑动归一化, 观测裁剪至 $\pm 10\sigma$

表注。强化学习超参除熵正则系数（0.01）外均为 stable-baselines3 2.3.2 的默认取值、未作调整，离散（MaskablePPO）与连续（PPO）两类配置在这些值上逐项相同。塑形四项仅用于连续动作策略；终端保速势的目标航速取 4 m/s。

1 让路态入口的对称化。状态机中“无冲突 $\rightarrow$ 让路”这一转移原本只由持续性条件
2 触发，而“直航 $\rightarrow$ 让路”另有一条即时条件。我们补上对称的一支：持续性条件未命中
3 时，再检查即时条件是否已成立，成立即进入让路态。该改动使让路义务的识别时机在两
4 条入口上一致，代价是它改变安全盾实际施加的动作，因此训练与评估必须在同一设置下
5 进行。

6 训练配置。训练超参见表 3。除熵正则系数（取 0.01）与有界动作分布外，其
7 余强化学习超参一律取 stable-baselines3 2.3.2 的默认值、未作调整，其具体数值已列入
8 表 3；离散与连续两类配置在这些值上逐项相同（我们已核对），故它们不构成两类配置
9 之间的差异来源。观测与回报的滑动归一化不是可选项，不做时式 (7) 中大尺度的趋近项
10 会把策略推向“原地停船”的退化解。完整配方另含四项塑形，全部仅作用于连续动作策
11 略，即三项势函数型塑形（进门势、横向进带势、终端保速势）与一项动作增量惩罚，其
12 权重与半径见表 3。动作增量惩罚需明确其形式与作用范围，它惩罚相邻两个决策步之间
13 策略指令的变化量，按策略动作箱各轴的半宽（ $a_{\text{op}}, \omega_{\text{op}}$ ，非物理量程）归一化后取平方
14 和，因此同时作用于加速度轴与转艏轴，而不只作用于转艏；它也不是势函数，不具备势
15 函数型塑形的策略不变性。

16 这四项塑形是一并启用或一并关闭的，本文未逐项拆开做消融，因此关于它们的结论只能
17 表述为“这一组塑形共同带来多少变化”。又由于其中的动作增量惩罚同时作用于两个控
18 制轴，凡涉及转艏增量、油门增量与 $jerk$ 这三项指标的比较，都必须在同样启用该惩罚的
19 两组之间进行，否则差异分不清是控制器带来的还是训练目标带来的。这一点在实验部分
20 再次强调，也限定了后文关于平顺度的全部结论。

4.4 安全性保证与作用域

前几节给出的是机制的构造；本节分析该机制能够严格保证什么。我们把结论按强度分档，逐条给出完整假设与作用域边界，并明确写出哪些性质没有被证明。全文中“证明”一律指严格引理；存在性级与经验级结论均逐条标注。受篇幅所限，此处给出陈述与证明要点；四条性质的完整推导可向通讯作者索取。四条性质的保证强度、验证状态与作用域边界汇总于表 4。

远场：一步之内一定不碰。

性质 1 (远场单步无碰). 设本船与单个他船的中心位置分别为 p_e, p_m ，中心距 $d = \|p_e - p_m\|$ 。若

$$d \geq d_{\text{safe}} + v_{\text{obs,max}}\Delta t + \rho_{\text{ego}}, \quad (9)$$

则一个决策步之后，两船（以外接圆保守占据）必不相交。其中 $d_{\text{safe}} = R_{\text{circ,ego}} + R_{\text{circ,obs}}$ ， $\rho_{\text{ego}} = v_{\text{max}}\Delta t + \frac{1}{2}a_{\text{max}}\Delta t^2$ 为本船单步最大位移。

代入常数如下。本船外接圆 $R_{\text{circ,ego}} = 88.4 \text{ m}$ 。他船的船体尺寸随场景而变（本场库实测他船船长为 200–300 m），其宽度也不进入状态，故我们不按单个场景的真实尺寸、而取一个对全库单侧保守的固定占据半径，即以本船参考船长 $L = 175 \text{ m}$ 的正方形外接为基准、叠加 $2L$ 的安全裕度， $R_{\text{circ,obs}} = \frac{1}{2}\sqrt{2}L + 2L = 123.74 + 350 = 473.74 \text{ m}$ 。该值远大于库中最大他船（船长 300 m）的真实外接半径（约 151 m），故对全库他船单侧保守。于是 $d_{\text{safe}} = 562.16 \text{ m}$ ， $\rho_{\text{ego}} = 107.0 \text{ m}$ ， $v_{\text{obs,max}}\Delta t = 95 \text{ m}$ ，阈值 = 764.16 m（工程取 $\sim 780 \text{ m}$ 留裕度）。

假设。 (A1) 单他船（多他船须对每个 i 分别满足）；(A2) 他船速度 $\leq 9.5 \text{ m/s}$ ，式 (1) 只约束受控船的航速，故他船的速度上界必须作为独立假设显式给出。我们在全库上实测：2000 个基准场景、342,000 个障碍状态，最大值 7.10 m/s，零个超过 9.5（裕度约 2.4 m/s）；若换成航速更高的真实 AIS 数据，阈值须相应抬高。(A3) 本船步末 $v \leq v_{\text{max}}$ （环境裁剪保证）；(A4) 他船步内近似恒速；(A5) 外接圆保守占据。

证明。 由三角不等式， $d_{\text{next}} \geq d - \|\Delta p_e\| - \|\Delta p_m\| \geq d - \rho_{\text{ego}} - v_{\text{obs,max}}\Delta t \geq d_{\text{safe}}$ ，两外接圆不交，故两船体不交。□

作用域。 三角不等式与方向无关，故对遇已是真正的最坏情形，几何上没有缺口。这是整个可证明层最稳的一块。它是单步充分条件，不是不变性，也不是近场保证；目前尚未实现为提前退出的快路径。

让路：每一步的方向都合规。

性质 2 (每一让路步的方向合规). 在被状态机判为让路态势 ($\rho \in \{\rho_2, \rho_3, \rho_4\}$)、且投影二次规划可行（未进入兜底）的每一个决策步上，实际执行的 u_{safe} 必落在式 (3) 所定义的合规方向半平面内。

证明。 合规半平面以硬区间约束进入二次规划，故投影解必然满足它。该结论是构造式的，不依赖任何额外引理。□

假设与作用域。 (B1) 单他船；(B2) 状态机分类正确（继承约 12.6% 的分类差与并列判定的已知缺口）；(B3) 二次规划可行；(B4) 作用域 = 让路态势的相遇。让路触发率约 13–16%（探索期 933 场景池实测，非本文正式报数池的 600），且这是经过碰撞可能性闸之后的相遇（回合）级比率，而非几何类型的占比——后者按几何谓词分类时交叉与对遇占满全库；两者不可混读；直航违规才按步计。

作用域限制。 本性质不覆盖紧急态（其判据在结构上旁路合规约束）。紧急态在探索期的 933 场景池上占冲突步的 55–60%，但该判据是一个过触发的保守大筐（在专门逼出紧急支的对抗基线上，其中 97.6% 事后并非真正不可避），故该比例只应读作“判据触发率”，不应读作“真实迫近比例”，也不覆盖放松、最小碰撞风险与退化三支兜底（它们都丢掉半平面）。因此本文的合规陈述只到“每一让路步的方向合规”这一层，并不覆盖全部决策步；实测每局违规数非零。

紧急：给黑箱划一条可判定的边界。

紧急控制器是经验性的最后手段。我们不主张它能避碰；相反，我们给出一个可靠（sound）的充分条件（所谓可靠，指该判据只会漏报、不会误报），用以判定“碰撞在物理上已不可避”，从而把这个黑箱变成一条可判定的边界。它替换掉此前一版只检查转向逃逸、因而会漏掉加减速逃逸的不可靠的判据。

性质 3 (碰撞不可避的保守判据). 设单个恒速他船。定义本船可达中心过近似集 $R_{\text{box}}(t)$ （艏向系矩形，中心取恒速外推），纵向半轴 $B_{\text{lon}}(t) = \frac{1}{2}a_{\text{eff}}t^2$ ，横向半轴 $L_{\text{lat}}(t)$ ，其中 $a_{\text{eff}} = \sqrt{a_{\text{max}}^2 + (v_{\text{bnd}}\omega_{\text{max}})^2}$ 、 $v_{\text{bnd}} = 11.9 \text{ m/s}$ ，且

$$L_{\text{lat}}(t) = \begin{cases} \frac{v_{\text{bnd}}}{\omega_{\text{max}}} (1 - \cos \omega_{\text{max}} t), & \omega_{\text{max}} t \leq \pi/2, \\ \frac{v_{\text{bnd}}}{\omega_{\text{max}}} + v_{\text{bnd}} \left(t - \frac{\pi}{2\omega_{\text{max}}} \right), & \text{否则}. \end{cases} \quad (10)$$

设 $O(t)$ 为他船船体矩形。若

$$\exists t^* \in [0, T]: R_{\text{box}}(t^*) \subseteq (O(t^*) \oplus \text{disk}(r_{\text{insc,ego}} = 12.7 \text{ m})), \quad (11)$$

则碰撞不可避：任何可行控制序列都会在 t^* 与该他船相撞。

证明要点（三步）. (i) R_{box} 过近似真可达中心。速度矢量变化率 $\|d\mathbf{v}/dt\| = \sqrt{a^2 + (v\omega)^2} \leq a_{\text{eff}}$ ，二重积分给出纵向界，横向偏移由 $\int_0^t v_{\text{bnd}} \sin(\omega_{\text{max}} s) ds = L_{\text{lat}}(t)$ 界住；(ii) 内切盘欠近似船体；(iii) 若可达中心全部落在 $O(t^*)$ 的 12.7 m 膨胀内，则本船内切盘（ $\subseteq$ 船体）与他船体相交 = 碰撞，且这对所有可达位置成立。□

假设。 (C1) 单个恒速他船；(C2) 他船船体尺寸不得高估——判据以他船船体矩形作欠近似，若调用方传入大于真实值的船宽，判据将不再可靠（会出现假阳）；(C3) 判据形如“ $\exists t \in [0, T]$ ”，在有限时域 $T = 120 \text{ s}$ 上以 241 个等距时刻求值。存在型判据在时间网格上求值只会漏掉网格间的成立时刻，不会凭空成立，故离散化本身不损可靠性，只损完备性；包络的单侧硬化保证的是另一件事——每个采样时刻上的可达集过近似与船体欠近似；(C4) 内切圆欠近似本船船体，可达中心过近似集覆盖真可达集。

验证。 六路对抗审计（20,000 随机 + 735 精选场景，含三段 bang-bang 逃逸搜索与精确船体碰撞几何）零真假阳；把包络硬化之后，基准集加 1500 例模糊测试仍 0 假阳、且判据非空（触发于 $t^* \leq 7 \text{ s}$ ）。

覆盖范围。 本判据是可靠的（单侧保守的充分条件）。不是早预警（它是末端分类器，不是规划代价）；不完备（不触发 $\neq$ 可避）；不覆盖多障碍（逐对可避不能合成）；不覆盖机动他船（必须恒速）。本判据是紧急层的一个分类器，不构成全系统的无碰撞保证。

关于多他船。 本文的实证范围是双船相遇（假设 (A1)），故不展开多他船的推广。仅指出一点作用域事实：碰撞自由在数学上是对全部他船的合取，因此上述“一定不碰”型的

充分条件按逐目标合取即可保守推广；但方向合规无法这样推广。若两条他船要求相反的让路一侧，两个半平面的交为空，该步只能落入兜底并记为一次违规。这不是本方法的缺陷，而是 COLREGs 自身的边界：它是成对制定的规则集，对多船冲突情形并未给出规范。相应的实证检验需要多他船场景数据，见局限一节。

从单步到递归可行（暂定结论）。

性质 1-2 都是单步保证。单步无碰不自带递归可行性：一个此刻安全的状态，可能没有任何安全的后续。这也是反应式控制障碍函数滤波器在 $\Delta t = 10$ s 这样长的零阶保持下所缺的东西。我们的升级思路如下。

可清障集 A 。固定单个恒速他船。称有限控制序列 m 是状态 s 的已认证直尾逃逸，若：(i) 它可执行。每段边界落在决策步边界上，因而 m 是逐步恒定控制的序列；(ii) 尾段恒速直行（ $\omega = 0$ 且 $a = 0$ ）；(iii) 一个可靠的 Lipschitz 净空证书在证书时域 $[0, H]$ 上给出船体距离 > 0 ，且已过最近点并留有裕度。定义 $A := \{s : \exists \text{ 已认证直尾逃逸}\}$ 。

辅助结论。若尾段恒速直行且他船恒速，则两个朝向固定、以恒定相对速度平移的矩形之间的距离函数 $g(t)$ 是凸的；因此一旦过了最近点开始增长，便对所有更晚的 t 持续增长。

可靠性要点。凸性要求尾段恒速，仅 $\omega = 0$ 不够。加速的直行尾段路径对 t 非仿射， g 未必凸；故证书同时要求 $a = 0$ 。该证书是充分条件：可靠，但保守，会拒绝一些其实安全的逃逸。

性质 4 (可清障集的控制不变性，暂定)。对每个 $s \in A$ 及其已认证逃逸 $m = (u_0, u_1, \dots)$ ，施加 u_0 一个决策步后得到 s' ，其尾 $m' = (u_1, u_2, \dots)$ 仍是 s' 的已认证直尾逃逸。因为它就是同一条已通过可靠性证书的物理轨迹的后半段。故 $s' \in A$ ，即 A 是控制不变的。据此，“后继仍在 A 内”这一终端约束（实现为对一条具体后备机动的 $O(1)$ 重认证）在设计上可使带盾闭环在 A 上递归可行。

合规版本 $A \cap \mathcal{U}_{\text{colregs}}$ 。盾必须选一个合规的第一步。设合规后备为“向规定一侧转 t_1 秒、然后直行”。情形 1（ $t_1 > \Delta t$ ）：尾段仍以合规转向开头、仍已认证，故 $s' \in A \cap \mathcal{U}_{\text{colregs}}$ 。这一情形已证。情形 2（ $t_1 \leq \Delta t$ ）：尾段第一步是直行，需从 s' 重新找合规逃逸，一般性证明尚缺。在盾的真实让路状态分布上，情形 2 未曾出现（175 m 级船体、转艏率约 $1.7^\circ/\text{s}$ ，任何合规的清障转向都必然长于一个决策步）。

暂定与作用域。(0) 终端约束只在让路后继上认证 A 归属；降级为无冲突的后继平凡安全，直航后继由式 (3) 的保向保速硬约束承担（构造式成立，但受本节所述累积口径错配的限制，未立为独立性质），远场时另有性质 1；紧急后继落回经验兜底。(i) 单恒速他船；多他船更弱（ $A = \bigcap_i A_i$ ，逐目标的可行域可能互相冲突）。(ii) A 由有限机动族加保守证书判定，是真可清障集的内近似。在真实让路分布上，可清障状态里每一个都存在 COLREGs 合规的已认证脱离机动（三种态势的条件率均为 100%）；唯一的缺口是交叉态势中约 2.9% 的状态本身即不可清障（任何方向都无法清出净空）而落入兜底。上述比率取自带盾回放中的让路状态，非对抗性分布，另见本性质作用域第 (iv) 条。这是可清障性的边界，并非合规与安全之间的冲突。(iii) 终端约束模块已实现并通过单元测试，接入部署中的盾并验证闭环仍待完成；上述比率来自高精度本地积分器，官方口径复算待补。(iv) 这些让路状态取自表现良好的带盾回放，故比率刻画的是可清障集的几何，不是对抗性迫近冲突下的性能。

我们能辩护的头条主张（挂满假设）：连续动作 $\cap$ 可证明方向合规 $\cap$ COLREGs（此前空白的三重交集），加上远场单步可证明安全与紧急迫近不可避的可靠性证书。我们不主张：裸的可证明无碰、完整可证明覆盖、机动他船、多船方向冲突。

兜底行为的实证边界。当投影在紧急态不可行时，判据在结构上旁路方向约束，兜

TABLE 4 可证明安全层：保证、状态与诚实作用域

保证	状态	作用域与限制
远场单步无碰（性质 1）	已证（初等引理；多他船合取不额外保守）	$d \geq \sim 780 \text{ m}$ ；他船恒速； $\forall i$ 合取；每个 $v_{\text{obs}} \leq 9.5 \text{ m/s}$ ；单步，非不变性；尚未实现提前退出
每让路步方向合规（性质 2）	构造式成立（作用域受限）	让路相遇（约 13–16%，探索期场景池实测、相遇级非逐步级）；不含紧急态与兜底；多他船下随 N 下降；方向冲突 $\rightarrow$ 兜底（COLREGs 成对性边界）；合规陈述只到让路步一层
紧急迫近不可避证书（性质 3）	可靠充分条件（ $>20,000$ 对抗场景 0 假阳）	仅迫近；他船恒速； $\exists i$ 可合成、可避性不可合成；不完备、非早预警；是分类器不是系统保证
可清障集 A 的控制不变性（性质 4，暂定）	暂定： A 的控制不变性已证、证书可靠（长时域模糊 0 假阳）；终端约束模块已单测；闭环接线与官方口径复算待补	单恒速他船； A 是内近似；可清障态中合规已认证脱离机动的条件存在率三态均 100%（带盾回放的让路状态，非对抗分布）；唯一缺口是交叉态约 2.9% 的状态本身即不可清障 $\rightarrow$ 兜底（非合规冲突）； $A \cap \mathcal{Z}_{\text{colregs}}$ 的不变性仅情形 1 已证

表注。性质 1 与性质 3 的数学作用域可按目标逐一合取地推广到多他船（碰撞自由是对全部他船的合取），性质 2 不能（方向要求相反时两个半平面的交为空）。但本文部署的安全盾按单他船实现，遇到多于一艘他船时显式报错，故上述推广未经实现，也没有多他船的实验数据支撑。表中凡提“多他船”一律只指数学作用域。

- 1 底控制器最小化碰撞风险。这是经验兜底，不是保证。在一个专门逼出紧急支的对抗性纯
- 2 几何基线上，我们观察到的碰撞全部发生在归类为紧急控制的步上，即“最后手段尝试并
- 3 失败”，且都落在性质 1 的适用域（远场、非紧急、单步）之外。它们不是对头条主张的
- 4 反例，但坐实了紧急态不是保证。此处按来源分类的碰撞计数留待正式实验重评后填入（
- 5 见“盾的行为随训练的演化”一节，【待填】）。

6 5. Experimental Design

7 5.1 场景库

8 **场景来源与构成。**实验在 CommonOcean 的双船相遇场景库上进行，共 2000 个场景。每

9 个场景规定受控船的初始位姿与航速、他船的初始状态与其既定航迹、以及受控船的目标

10 区域（含位置门、朝向门与时限）。场景的相遇几何是程序化生成的，覆盖不同的相对方

11 位、航向交角与接近速率；受控船为前述 175 m 级机动船，他船为场景库给定的机动船（

12 船长 200–300 m）。回合上限为 170 个决策步，折合 1700 s。

13 **相遇类型分布。**按状态机的几何类型谓词（不含 420 s 碰撞可能性这道闸）对全库

14 分类的结果是：交叉与对遇两类占满全库，追越场景数为零。这一点对本文的作用域有直

15 接影响：式 (3) 中 ρ_4 一支虽已实现并可被单元测试触发，但无法在本场景库上得到实证检

16 验，我们在局限一节如实列出。就官方测试集 600 个场景而言，交叉 395 个、对遇 205 个

17 。

18 **划分。**场景库的官方划分为训练 1400 / 测试 600。我们把官方训练侧再切为 1300

19 个训练场景与 100 个验证场景（其中训练侧对遇 468、交叉 832；验证侧对遇 36、交叉

20 64）。验证集只用于训练期监控与存档选取，测试集在训练与调参全程不被访问。

21 **报数分母。**由于全部训练均在官方 1300 上进行，而该集合与官方测试 600 零交集

TABLE 5 九种配置的配方与单变量递进序列

#	配置	动作空间	合规施加方式	塑形	分布	让路入口	相对上一级只改
①	完整方法	连续	投影盾	全	Beta	对称	由⑧或⑨各补一项
②	离散 + 屏蔽	离散	动作屏蔽 + 软奖励	零	—	原设定	动作屏蔽（相对④）
③	离散基线	离散	无	零	—	—	—（序列的根）
④	离散 + 软奖励	离散	软性合规项	零	—	—	软性合规项（相对③）
⑤	连续无盾	连续	无	零	高斯	原设定	动作空间（相对③）
⑥	连续有盾	连续	投影盾	零	高斯	原设定	安全盾（相对⑤）
⑦	消融基准	连续	投影盾	全	高斯	原设定	连续专属塑形（相对⑥）
⑧	消融：仅有界分布	连续	投影盾	全	Beta	原设定	动作分布（相对⑦）
⑨	消融：仅对称入口	连续	投影盾	全	高斯	对称	让路入口（相对⑦）

表注（三条限定必须与本表同处出现）。 (1) ③ → ⑤这一级不是纯单变量：环境层与奖励层是干净的（我们做过逐值比对，差为 0），两个算法的默认超参也已逐字核对、完全相同；但算法类（带屏蔽的 PPO vs. 普通 PPO）、策略族（49 类别分布 vs. 2 维连续分布）、熵系数的语义（离散熵与微分熵不是同一个量）三者是“换动作空间”不可分割的伴随。故这一级只能读作“动作空间及其必然伴随的贡献有多大”。 (2) ⑥ → ⑦的“连续专属塑形”是 4 件一起开的捆绑包（进门势 / 横向进带势 / 终端保速势 / 动作增量惩罚（两轴）），本次没有逐件拆开，因此只能写“这套组合贡献了 X”。 (3) ⑦ → ⑧换分布带一个必然伴随：两种分布的初始探索尺度在加速度轴上差约 2.5 倍。高斯的初始标准差是一个由较窄的转舵轴动作箱派生的标量（ $\sigma \approx 0.009$ ），两轴共用；加速度轴箱宽是转舵轴的 2.67 倍，故高斯在加速度轴上相对更窄（ $\sigma / \text{半宽} = 0.19$ vs. 转舵轴 0.50）；Beta 的初始形状按箱宽相对定义（ $\approx 0.48 \times \text{半宽}$ ，两轴相同）。这是换分布的必然伴随，不是接线错误。不存在“既换分布又保持初始探索尺度不变”的写法，因为高斯的尺度是绝对的、Beta 的是相对的。

- 1 ，测试集上不存在任何被训练过的场景，故报数分母即为 600。我们独立复核了这一划分
- 2 ：自行重跑同一划分并求交集，得训练 $\cap$ 测试 = 0、验证 $\cap$ 测试 = 0、训练 $\cup$ 验证 = 官
- 3 方训练 1400、训练 $\cap$ 验证 = 0。
- 4 本文此前的探索性实验使用过一个较小的场景子集，其训练场景与官方测试集有交集、须
- 5 剔除后才能报数，因而分母与此处不同。两套分母下的数值不可放入同一张表；正文如需
- 6 引用探索期结论，会标明其口径。

7 5.2 九种配置与八级单变量递进序列

8 表 5 列出九种配置。它们构成一条连通的单变量递进序列：相邻两级之间只改动一个变量

9 ，因此每一个机制的贡献都能单独读出来。

10 ⑤⑥这对配置的适用条件（须与安全盾收益这一数字同处出现）。代码守卫规定

11 无盾的连续动作配置只能用极简配方（无界高斯 / 非对称让路入口 / 零塑形），因为让无

12 盾配置启用连续专属塑形会造成相对离散无盾基线的不对称，使归因失效。而无界高斯正

13 是那个会把大量采样推到动作箱边界之外的形态：在探索期的四配置重评上（小规模场景

14 池，非本文正式报数口径），我们实测无界高斯策略有约 73% 的决策步紧贴动作箱边界

15 。因此，“安全盾在连续动作空间中带来多少收益”这一倍数，是在连续动作最差的形态

16 下测得的。同理，③ → ⑤的“把动作空间由离散换为连续本身带来多少收益”很可能是

17 负的；那是一个保守的下界，我们如实报告。

18 5.3 训练预算、种子与算力

19 每条 run 从零端到端训练 **10,158,080 步**（20 段 $\times$ 507,904），不用热启动；分段存档全程

20 开（每段留一份，因此 20 个存档候选）；训练期评估用那 100 个验证场景，曲线即验证

1 曲线。每条 run 用 8 个并行环境。
 2 种子集合 = $\{0, 1, 2, 3, 4, 5, 8, 9\}$ ，共 8 颗，分布在 4 台机器上（每台 2 颗、每台 6
 3 路并发）。种子取值预先固定并原样报告，逐种子原始值随主表给出。分机器的依据是种
 4 子而非配置：同种子配对比较是本文的主统计工具，因此同一颗种子下的全部配置必须落
 5 在同一台机器内，否则“机器”会成为混淆变量。评估另说：一张报数表里每种配置必须
 6 同一台机器、同一轮内评完。
 7 报数预算取所有 run 都达到的最小段数，同一张表全部配置同一个值，并报实际步
 8 数而非名义值。
 9 运行环境。全部训练与评估在服务器 CPU 上完成，未使用 GPU：单机 32 个
 10 vCPU（AMD EPYC 7T83，64 核处理器），内存 60 GB。不使用 GPU 是因为本文策略
 11 网络仅两层各 64 个神经元，其前向与反向的算术量远小于数据在主机与显存间往返的开
 12 销；真正占用算力的是环境仿真与每步的二次规划求解，二者均在 CPU 上执行。据此，
 13 每台机器的并发路数按内存上界而非核数确定：单条训练的常驻内存约 6 GB，故每台并
 14 发 6 路（约占内存的 60%），余量用于覆盖启动期与段末评估的瞬时峰值。这一配置同
 15 时说明本方法的算力门槛不高，便于在不具备加速硬件的条件下复现。
 16 单步求解耗时的口径。我们上报的单步求解耗时是单线程 CPU 墙钟，随机器而变
 17 ，须连同上述处理器型号与线程设置一并阅读；比较时看尾部分位（p95 与 p99）而非均
 18 值。他船不在感知窗内的决策步会短路、不进入二次规划，这些步不计入耗时分布，否则
 19 大量零值会稀释尾部。

20 5.4 指标

21 COLREGs 违规的计数口径。违规数不是由安全盾的态势判定给出的，而是由一个独立
 22 于安全盾的离线评分器给出，这一点必须先讲清楚，否则会被误读成“盾自己判自己”。
 23 评分器只看轨迹：对每一步用裸的态势谓词重新判定本船处于直航还是让路义务下，然后
 24 按两条规则计数。直航违规按步计：在一段连续的直航义务期内逐步重判，取该期内的带
 25 符号累积航向变化，某一步的累积量绝对值达到 $\Delta_{nt} = 10^\circ$ 即该步记一次（因此本船回正
 26 航向、把累积量拉回阈值以下的那些步不计）；直航义务解除时累积量清零。让路违规按
 27 相遇计：若一次让路相遇从触发到解除的全程都没有出现达到 $\Delta_{lt} = 20^\circ$ 的规定方向转向
 28 ，则该次相遇记一次。两者相加即每局违规数。因为评分器独立于安全盾，它对本文方法
 29 与对全部基线（包括不含状态机的几何控制器）使用同一套判据，可直接比较。

30 直航约束与该口径之间的一处结构性错配。式 (3) 中直航态的容差取 $\varepsilon_\omega =$
 31 $\Delta_{nt}/T_M = 0.004363 \text{ rad/s}$ ，即它约束的是单个 $T_M = 40 \text{ s}$ 窗内的航向变化不超过 10° 。而评
 32 分器累积的是整段直航义务期，该期可以远长于 T_M ：在容差上界处每个决策步累积 2.5°
 33 ，故连续 4 步之后累积量即达阈值。由于安全盾的容差带是闭的（允许恰取 $\pm\varepsilon_\omega$ ），而
 34 评分器在累积量达到 Δ_{nt} 时即计违规，两个口径在单个 T_M 窗的闭边界上就已经不一致：
 35 一段达到 40 s 的直航期，即使每一步都落在安全盾的约束内，也可能被记为违规。

36 非零直航违规的三个来源。上述容差错配只是其中之一，且不是最主要的一个。
 37 更基础的一层是义务窗与约束窗并不重合：评分器按裸态势谓词逐帧判定直航义务，而安
 38 全盾只在状态机判为 ρ_1 的决策步上施加 $\{|a| \leq \varepsilon_a\} \cap \{|\omega| \leq \varepsilon_\omega\}$ 。两者在两处系统性地错
 39 开。其一，紧急判据在状态机中优先于一切态势：一旦触发，该步的态势即为 ρ_5 ，安全
 40 盾不施加任何航向约束，而评分器的直航义务谓词不含任何紧急豁免，仍按义务计数。其
 41 二， ρ_1 下安全动作集为空时，“放松”与“碰撞风险最小化”两支兜底在执行器物理量
 42 程上求解并整块丢弃合规约束，转艏率可达 $\omega_{\max}$ ，单步航向变化即达 17.2° ，一步便越
 43 过 10° 阈值。此外，状态机的态势具有路径依赖（进入 ρ_5 后须满足独立的解除条件才退

出)，而评分器的谓词是逐帧瞬时的，这使两者的窗口边界进一步错开。

因此安全盾在结构上并不保证直航违规为零，本文也不作此主张。需要区分的是：容差侧的错配原则上可以消除——评分器累积的是带符号航向变化且义务期结束即清零，故可把固定的 ε_ω 换成累积预算式约束 $\omega \in [(-\Delta_{nt} - c)/\Delta t, (\Delta_{nt} - c)/\Delta t]$ （ c 为本期已累积量），该区间恒含 $\omega = 0$ 故永不为空、仍是逐轴区间故投影仍精确、且不会随期长把容差压到零；本文未采用该写法，因为正式实验的训练配方在报数前已冻结。真正不能由改约束消除的，是上述义务窗与约束窗的不重合——那是评分口径与安全盾作用域之间的边界。

主指标沿用 (Krasowski and Althoff, 2024) 的定义，以保证可比：到达率、碰撞率、每局 COLREGs 违规数、紧急控制步占比、每局时长；违规数进一步拆成让路违规与直航违规。控制质量：转艏增量（分总计 / 让路步 / 其他步）、油门增量、jerk、控制努力、次网格细调率、速度反转次数。安全裕度：最近点中心距 / 净空 / 发生时刻、最近点处航向误差与速度。盾的行为：介入步数、兜底触发率、投影修正量（均值 / p95 / 最大 / 零修正比例）。分型：按会遇类型拆全部指标、失败原因分型。实时性：单步求解耗时，分盾 / 策略 / 整步三层。

采集边界（决定了图能怎么画）。训练期每 507,904 步记录验证曲线；每个 rollout（16,384 步）记录策略与值函数损失、熵、KL、裁剪比例、可解释方差、每局回报，以及动作饱和率、舵反转率、盾介入率、盾改写量等行为量（转艏与加速度两轴分开记，盾改写量按箱半宽归一化后再合成，不做量纲直加）。训练期没有违规曲线。违规计数只在评估侧接线，因此违规只有那 20 个评估点。另外，各配置奖励口径不同，每局回报不可跨配置比较。

5.5 存档选取与两轮报数

选取规则先定死、不带任何旋钮：候选 = 全部 20 段；单一指标 = 验证集到达率，取最高；平局取更早的段。存档选取只使用验证集，不接触测试集；所有配置一视同仁。

必须两版都报：验证集 $N = 100$ ，到达率的二项标准误约 4 个点；在 20 个候选里取最大值，期望上抬约 7.5 个点，比我们专门立规矩去防的跨轮次抖动（约 1.6 个百分点）还大 4 倍多。故最佳存档一轮 + 末段存档一轮，两版都报并量化交代这个偏倚。

5.6 统计方法

主检验 = 同种子配对符号检验。8 颗种子时双侧最小可达 $p = 2/2^8 = 0.0078$ ，足以支撑“统计上可辨”的结论。区间用按种子重采样的自助法 95% 区间；碰撞用 Fisher 精确检验（碰撞是稀有事件，正态近似不适用）。全部自算，不调统计库，脚本随论文给出。

我们预先声明一条回退规则：若最终达标种子数降至 3–4 颗，主检验改为按测试场景配对（每种配置在每个测试场景上的逐局明细， $N = 600$ ），逐种子那一版降级为稳健性检查；换检验的唯一理由是算力受限，且逐场景配对不能替代逐种子回答训练可靠性这一问题——后者只能靠种子数， n 小即如实报告 n 小。

“达标种子数”这一列附判据定义：达标 = 严格到达率 $\geq 50\%$ ；发散（陷入原地打转）= 到达 $< 50\%$ 且末段每局时长 ≥ 1360 s（ $= 0.8 \times$ 回合上限）；训练不足 = 到达 $< 50\%$ 且末段每局时长 < 1360 s。并报过渡带（1100–1600 s）的条数，该区间内的归类本身不确定。（全库 100 条低到达 run 的实证：发散组落在 [1377, 1700]、训练不足组落在 [567, 1354]，阈值处不重叠，12% 落在过渡带。）

TABLE 6 主表：九种配置在官方测试集上的同口径对照（最佳存档轮·全部种子）

配置	n	达标	到达% [CI]	碰撞%	违规/局	转舵 Δ	油门 Δ	紧急%
①本文方法	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
②离散-有盾	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
③基线	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
④软奖励	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑤连续-无盾	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑥连续-有盾	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑦消融·都不改	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑧消融·只 Beta	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑨消融·只对称	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】

表注。官方测试集 600 个场景（与训练集零交集）。训练预算 10,158,080 步，用 100 个验证场景选最佳存档，全部配置同一规则。到达判据 = 官方 is_reached（位置 + 朝向 $\pm 9.74^\circ$ + 时限）。区间 = 按种子重采样的自助法 95% 区间；碰撞用 Fisher 精确检验。“达标”判据见“统计方法”。⑤⑥使用极简配方（无界高斯 / 非对称让路入口 / 零塑形）；该配方是无盾连续动作配置唯一合法的形态，故由⑤⑥得到的安全盾的收益是在连续动作最差形态下测得的。转舵增量、油门增量与 jerk 三列均不可跨动作空间读作“我们更平顺”：连续动作配置训练时开着直接惩罚控制增量的罚项，且该罚项同时作用于两个轴，离散动作配置结构上没有；正确读法见图 3。碰撞如实报，与对标的差异按 Fisher 检验陈述，不写“零碰撞”。

1 6. Results

2 6.1 主表：九种配置的同口径对照

3 表 6 另报“仅计达标种子”的版本：发散种子会污染逐局平均，且污染方向因配置而异，
4 故两版并报，关键差值为【待填】。逐种子原始值随表给出。

5 6.2 消融：两项改进各自贡献多少

6 四条消融配置构成完整的 2×2 （有界分布 $\times$ 让路入口），其余配方逐字相同、同种子配
7 对。定量结果见图 3：换有界分布把转舵增量降到【待填】（配对符号检验 $p =$ 【待填】
8 ），换让路入口把每局让路违规降到【待填】（ $p =$ 【待填】），两项改进同开为【待
9 填】。转舵平顺度唯一站得住的读法就在这组对照里：四种配置开着同一个动作增量惩罚
10 ，因此“⑧比⑦平顺 N 倍”只能归因于有界动作分布，而不是额外的奖励项；跨配置与
11 离散基线比较结构上不成立（我们罚了那个量、离散动作配置拿不到）。⑦ $\rightarrow$ ⑧这一级
12 的不可分割伴随（初始探索尺度在加速度轴上差约 2.5 倍）见表 5 表注 (3)。按“统计方
13 法”，本组同样给出“仅达标种子”一版。

【图 2（2×2：学习曲线/同种子配对差/达标种子数/值函数健康度）占位——数据到手后替换】

Figure 2 样本效率与训练可靠性。（a）九种配置在 100 个验证场景上的到达率学习曲线（每 507,904 步一个点，共 20 个点），实线为跨种子中位数、阴影为四分位距。（b）同种子配对的到达率差值（本文方法 – 对标离散动作配置），每条折线一颗种子；折线全部位于零线同侧即为一致优势。（c）“达标种子数”随训练步数的变化（判据见“统计方法”）。（d）值函数可解释方差随训练的变化，用于区分“还在爬”与“已经崩”。全部曲线取自训练期落盘的原始数值，未做任何平滑。

1 6.3 样本效率与训练可靠性

2 6.4 消融图

3 6.5 安全—效率权衡

4 6.6 盾的行为随训练的演化

5 6.7 轨迹定性对比

6 6.8 外部几何基线

7 我们把三条不需要训练的几何避碰控制器放在同一评估管线、同一测试集与同一分母上跑
8 一遍，作为与学习无关的参照（表 7）。这一组对照的作用不是证明学习方法更强，而是
9 回答一个更基本的问题：本文所报的差异中，哪些维度上几何方法本来就够用。

10 结果把可辩护的主张收窄到一个维度。控制障碍函数滤波器在本测试集上的碰撞率
11 为 0.00%，即在碰撞这一维度上它与本文方法打平；因此碰撞率不是能区分两类方法的指
12 标。到达率一列同样不能直接使用：几何控制器的标称控制律不含终端对准环节，其位置
13 命中率达 96.8%–99.7%，却卡在终端朝向门之外，这一列反映的是终端约束的类型差异
14 。平顺度一列则明确不利于本文：物理满量程档的转艏增量低至 0.00032–0.00058，这是
15 手工调参的几何控制器所能达到的量级；本文与之的比值待数据到手后填入（【待填】）
16 ，且无论结果如何都不作平顺度优势的主张。

17 真正的差别在 COLREGs 违规，且集中在一个具体成因上：两条已出数的基线，其
18 违规几乎全部是直航违规——控制障碍函数 4.49 次中的 4.04 次、PD 控制器 9.79 次中的
19 9.35 次（速度障碍一档待补，见表 7）。这些控制器只以“不碰”为目标，因此在规则要
20 求保向保速的时段里仍在持续机动。这与“指标”一节给出的计数口径一致：违规由独立
21 评分器按裸态势谓词判定，与是否装有安全盾无关，因此这一比较是同口径的。本文的对

【图 3（1×3：转舵增量 / 让路违规 / 到达率，同种子配对连线）占位——数据到手后替换】

Figure 3 两项改进的贡献拆解（ 2×2 消融，同种子配对）。横轴为四条消融配置，纵轴分别为转舵增量、每局让路违规与到达率。每个点为一颗种子，细线为同种子配对连线，粗线为中位数，误差棒为按种子重采样的自助法 95% 区间。转舵增量的改善应归因于有界动作分布，而非奖励塑形——四种配置开着同一个动作增量惩罚（不可分割的伴随见表 5 表注 (3)）。

1 照结论只能落在这一维度上：【待填】。

2 6.9 紧急兜底的实证刻画

3 紧急通道是本方法唯一不提供保证的一支，因此需要单独刻画它被用到的频率与后果。紧急控制步占全部决策步的【待填】； ρ_0 – ρ_4 上的三支兜底（放松、碰撞风险最小化、退化）合计触发率为【待填】。碰撞按控制来源分类的分布为【待填】：若碰撞全部落在紧急控制一类，则说明碰撞发生在“最后手段已被启用并失败”的步上，而这些步按定义落在性质 1 的适用域（远场、非紧急、单步）之外——这不构成对性质 1 的反例，但坐实了紧急态只是经验兜底。投影修正量的分布（均值 / 第 95 百分位 / 最大值 / 零修正比例）为【待填】，它度量策略输出与规则要求之间的差距。

10 7. Discussion

11 投影把“合规”从统计性质变成了逐步性质。软奖励只能影响策略的期望行为，不能排除任何一个具体动作；屏蔽与投影都能，区别在于屏蔽需要一个可枚举的动作集合。本文的结论是：在连续动作空间里，可枚举这个前提可以用可投影替代。合规方向恰好是一个半平面，投影到半平面与箱的交集上是一个小规模二次规划，实测单步耗时【待填】。

15 连续动作的红利落在哪里、不落在哪里。确定落在合规转向的精细度上：连续动作能精确取到 ω_{turn} 这一下确界，而 7×7 网格只能取到高出 37.5% 的档位，这一条纯由分辨率决定、与训练无关。油门轴的分辨率差异（离散只有 7 档）同样是结构性的，但它不能被直接读成油门增量指标上的优势：该指标同时受动作增量惩罚影响，而该惩罚只在连续动作配置中启用，因此两种动作空间之间的油门增量差异无法归因；可归因的比较只在同样启用该惩罚的连续配置之间成立。到达率则不一定，③ → ⑤这一级很可能是负的，我们照实报（表 5 表注 1）。

【图 4（安全—效率权衡图：到达率 $\times$ 违规，内嵌到达率 $\times$ 碰撞率）占位——数据到手后替换】

Figure 4 安全—效率权衡。横轴为到达率，纵轴为每局 COLREGs 违规数（对数轴），每个标记为一种配置，误差棒为按种子重采样的自助法 95% 区间；左上角为理想区。内嵌小图纵轴换为碰撞率。形状编码：圆 = 连续动作、三角 = 离散动作、方块 = 外部几何基线；实心为带盾（投影盾或动作屏蔽），空心为无盾。核心读法：离散动作屏蔽为拿到合规性付出的代价，与连续投影所付代价之比为【待填】。外部基线的到达率须按“外部几何基线”的限定阅读。

为什么“两项改进”是连续动作空间特有的问题。量化动作空间不存在动作被裁到箱外的情形，也不存在微分熵无上界的通道。这两个问题是把 COLREGs 安全盾迁入连续动作空间之后才出现的。因此本文的消融不是对两个超参的调节，而是对迁移过程中新出现的两处缺陷的修补。

与控制理论侧安全滤波器的关系。反应式控制障碍函数滤波器在 10 s 零阶保持下没有递归可行性证明；本文的可清障集给出了一条路径（性质 4），但该结论仍为暂定，闭环接线与官方口径复算尚未完成，故本文只把它作为设计方向陈述，不作为已兑现的保证。

7.1 局限

1. 可证明档 = 中。性质 3 的判据已被验证可靠，但覆盖不完整；性质 4 仍暂定。碰撞率按实测如实报告（【待填】），本文不作零碰撞主张，也不把安全盾简写为“可证明无碰撞”。
2. 合规是“每让路步”，不是“每步”。让路态势约占相遇的 13–16%（探索期场景池实测）；紧急态在结构上旁路合规约束；实测每局违规数非零（【待填】）。
3. 到达率不列为卖点。【待填】。若无统计上可辨的优势，如实写“与离散基线相当”。
4. 平顺度优势是有条件的。动作分辨率的差异是结构性的，但转艏增量、油门增量与 jerk 三项指标都受只在连续配置中启用的动作增量惩罚影响，因此跨动作空间的平顺度差异不可归因；可归因的比较只在同样启用该惩罚的配置之间成立，此时有界动作分布的贡献可由消融对照读出；本文不主张相对手工调参的几何控制器具有平顺度优势（表 7）。

【图 5（2×2：盾介入率/动作饱和率两轴/盾改写量/态势占比）占位——数据到手后替换】

Figure 5 盾的行为随训练演化（连续动作特有的证据）。（a）盾介入率随训练步数的变化（【待填】）。若该曲线下降，则表明策略在带盾训练下逐步学会自行产生落在安全动作集内的动作；本图只呈现曲线，该解读须由曲线本身支持。（b）动作饱和率随训练的变化，转艏轴与加速度轴分开画，并把有界分布配置、无界高斯配置与离散动作配置叠在同一张图上。离散网格的 $|\omega|$ 与 $|a|$ 上界恰好等于连续动作箱的半宽，因此两种动作空间共用同一条打满判据、可直接叠图；这是“有界连续动作 vs. 离散 7×7 网格”这一主张的直接证据。（c）投影修正量（按箱半宽归一化）的中位数与 p95 随训练收敛。（d）相遇态势占比随训练的变化，其中紧急态占比是性质 2 作用域的关键数字。

5. 少数种子的训练不稳定（【待填】）。这是训练不稳定，不是场景难度；奖励塑形对该问题是一条高置信度的经验死路（就我们试过的塑形族与系数而言），但不构成对约束型 MDP 或非 PBRs 终端目标的不可能性证明。
6. **COLREGs 覆盖边界与基准局限。**本文实现的是第 13–15 条（追越、对遇、交叉）与第 16 条（让路船的行动）的方向要求，以及第 17 条 (a)(i) 的直航保向保速。未实现的条款包括：第 17 条 (a)(ii)/(b)/(c)（直航船在让路船不采取行动时的自行避碰义务及其时机判定）、第 18 条（船舶间的责任等级）、第 19 条（能见度受限时的行动，本基准无能能见度建模）、第 9 条（狭水道）与第 10 条（分道通航制）——后两条需要航道几何，而本基准是开阔水域。官方场景库中没有追越场景，追越合规性在本基准上无法验证；基准是双船场景，多他船的方向冲突拿不到实测数据。
7. **他船模型与速度上界。**性质 1、3、4 都建立在他船恒速外推上，机动他船会使保证失效；他船速度上界是经验验证的（本基准全池最大 7.10 m/s），真实 AIS 数据更快时阈值须相应抬高。
8. **报数口径的两个已知偏倚。**最佳存档选择偏倚（期望上抬约 7.5 点，故两版并报）与跨机器跨轮次抖动（连续动作配置约 1.6 个百分点，故强制同一机器、同一轮次评估）。实时性数字随机器而变，只能同机同口径比较。
9. 离散基线是本文对 (Krasowski and Althoff, 2024) 的重新实现（其海事评估代码未公开），故离散动作配置的种子脆弱性归因于我们的复现，不归因于原作者；软奖励项相对原文有一处数值稳定性偏离，已在方法节声明。

【图6（同一场景 × 四种方法的轨迹）占位——数据到手后替换】

Figure 6 同一场景下四种方法的轨迹对比（场景 T-【待填】，种子 s【待填】）。本船轨迹按相遇态势着色（无冲突 / 直航 / 让路 / 紧急），他船轨迹为灰色，圆点间隔 10 s（一个决策步）；虚线圆为性质 1 的远场阈值（约 780 m）。按各方法的实际轨迹标注其在让路段的转向方向与幅度（【待填】）；选图时以能同时呈现“合规让路”与“无碰撞但方向违规”两类结果为准，具体场景与轨迹形态待数据到手后确定。本图是定性插图，不承担任何定量声明；场景为人工挑选，种子集合（s0/s1/s2）在跑之前已声明。

1 8. Conclusions

2 我们把投影式安全盾首次落到海事 COLREGs 的连续动作空间，填上了“连续动作 $\cap$ 可证
3 明方向合规 $\cap$ COLREGs”这个此前空白的三重交集，并精确刻画了这一层能证什么、不
4 能证什么：远场单步无碰严格可证、每让路步方向合规构造式成立、紧急迫近不可避有可
5 靠性证书；由该证书定义的可清障集的控制不变性已证，据此设计的递归可行性升级仍为
6 暂定。在官方场景库上，9 种配置构成的八级单变量递进序列把三组机制逐级拆开（【待
7 填】）。我们如实报告全部局限。
8 后续工作：把后备机动终端约束接进部署中的盾并验证闭环；构造让路密集 / 对抗
9 性场景源，使兜底与终端约束的价值可被真正检验；多他船的经验验证；把远场判据实现
10 为 $O(1)$ 提前退出以进一步压低单步耗时。

11 Acknowledgements

12 【待填】

13 Author Contributions

14 【待填】

15 Conflict of Interest

16 作者声明本研究、署名及发表不存在潜在利益冲突。

TABLE 7 外部几何基线对照（不训练、无种子；官方测试集 $N = 600$ ）

方法	控制量程	到达%	碰撞%	COLREGs 违规 / 局			转艏 Δ	jerk
				合计	让路	直航		
控制障碍函数	策略量程	70.17	0.00	4.95	0.47	4.48	0.00242	0.171
	同上 + 裕度	69.83	0.00	4.49	0.45	4.04	0.00235	0.167
	物理满量程	69.33	0.00	6.48	0.52	5.97	0.00058	0.050
PD 控制器	策略量程	58.83	18.00	9.79	0.44	9.35	0.00492	0.310
	物理满量程	57.67	16.67	8.10	0.63	7.47	0.00032	0.040
速度障碍	两档	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
①本文方法	策略量程							

(引表 6)

表注。（1）三条基线不训练、无随机种子，故不列种子统计；参数按各自最好的配置报，调参用官方训练集另抽的 100 例，与本表的报数池零交集。控制量程两档：“策略量程” = 与本文策略同权限的 $\pm 0.048 / \pm 0.018$ ，“物理满量程” = $\pm 0.24 / \pm 0.03$ ；同时报两档是为了排除“权限差异”这一混淆。（2）到达率不能直接读作避碰能力：几何控制器的标称律不含终端对准环节，它们的位置命中率达 96.8%–99.7%，却卡在终端朝向门之外，因此该列反映的是终端约束类型的差异。（3）违规数中直航违规占绝大多数（控制障碍函数 4.49 中的 4.04、PD 9.79 中的 9.35）：几何控制器“不撞”的代价是在规则要求保向保速时仍在机动。这是本文相对它们的差别所在，也说明碰撞率不是有效的区分维度——控制障碍函数在本基准上碰撞率为零。（4）平顺度一列不支持任何有利于本文的主张：物理满量程档的转艏增量低至 0.00032–0.00058。与本文的比值待正式实验数据到手后填入（【待填】）；无论结果如何，本文都不作平顺度优势的主张。可辩护的写法只有“平顺度相当，而违规更低”。（5）单局评估耗时（单线程墙钟）：控制障碍函数 0.18–0.19 s、PD 0.19 s、速度障碍 0.45 s。（6）三条基线走无盾路径、不推状态机，全部决策步都归在“无冲突”态势下，故本表不给出按态势拆分的转艏增量（让路步 / 其他步的拆分对它们无意义），只报合计；它们的违规数由离线态势评分器给出，与安全盾的态势判定无关，口径见“指标”一节。

1 Funding

2 【待填】

3 References

- 4 Alshiekh, Mohammed, Roderick Bloem, Rüdiger Ehlers, Bettina Könighofer, Scott Niekum, and
5 Ufuk Topcu. 2018. “Safe Reinforcement Learning via Shielding.” In *Proceedings of*
6 *the AAAI Conference on Artificial Intelligence*.
- 7 Ames, Aaron D., Samuel Coogan, Magnus Egerstedt, Gennaro Notomista, Koushil Sreenath, and
8 Paulo Tabuada. 2019. “Control Barrier Functions: Theory and Applications.” In *Eu-*
9 *ropean Control Conference (ECC)*, 3420–3431.
- 10 Benjamin, Michael R., John J. Leonard, Joseph A. Curcio, and Paul M. Newman. 2006. “A
11 Method for Protocol-Based Collision Avoidance Between Autonomous Marine Surface
12 Craft.” *Journal of Field Robotics* 23 (5): 333–346.
- 13 Cheng, Yin, and Weidong Zhang. 2018. “Concise Deep Reinforcement Learning Obstacle
14 Avoidance for Underactuated Unmanned Marine Vessels.” *Neurocomputing* 272: 63–
15 73.

- 1 Chou, Po-Wei, Daniel Maturana, and Sebastian Scherer. 2017. “Improving Stochastic Policy
2 Gradients in Continuous Control with Deep Reinforcement Learning Using the Beta
3 Distribution.” In *Proceedings of the International Conference on Machine Learning*
4 *(ICML)*.
- 5 Chun, D.-H., M.-I. Roh, H.-W. Lee, J. Ha, and D. Yu. 2021. “Deep Reinforcement Learning-
6 Based Collision Avoidance for an Autonomous Ship.” *Ocean Engineering* 234:
7 109216.
- 8 De Lellis, Francesco, Marco Coraggio, Giovanni Russo, Mirco Musolesi, and Mario di Bernardo.
9 2024. “Guaranteeing Control Requirements via Reward Shaping in Reinforcement
10 Learning.” *IEEE Transactions on Control Systems Technology*. arXiv:2311.10026.
- 11 Eriksen, Bjørn-Olav H., Morten Breivik, Erik F. Wilthil, Andreas L. Flåten, and Edmund F.
12 Brekke. 2019. “The Branching-Course Model Predictive Control Algorithm for Mar-
13 itime Collision Avoidance.” *Journal of Field Robotics* 36.
- 14 Fossen, Thor I. 2011. *Handbook of Marine Craft Hydrodynamics and Motion Control*. Chich-
15 ester: John Wiley & Sons.
- 16 García, Javier, and Fernando Fernández. 2015. “A Comprehensive Survey on Safe Reinforce-
17 ment Learning.” *Journal of Machine Learning Research* 16: 1437–1480.
- 18 Grover, Jaskaran, Changliu Liu, and Katia Sycara. 2023. “The Before, During, and Af-
19 ter of Multi-Robot Deadlock.” *International Journal of Robotics Research*.
20 arXiv:2206.01781.
- 21 Heiberg, Amalie, Thomas Nakken Larsen, Eivind Meyer, Adil Rasheed, Omer San, and Dami-
22 ano Varagnolo. 2022. “Risk-Based Implementation of COLREGs for Autonomous
23 Surface Vehicles Using Deep Reinforcement Learning.” *Neural Networks* 152: 17–33.
24 arXiv:2112.00115.
- 25 Huang, Yamin, Linying Chen, and P. H. A. J. van Gelder. 2019. “Generalized Velocity Obsta-
26 cle Algorithm for Preventing Ship Collisions at Sea.” *Ocean Engineering* 173: 142–
27 156.
- 28 International Maritime Organization (IMO). 1972. *Convention on the International Regulations*
29 *for Preventing Collisions at Sea (COLREGs)*. London: IMO.
- 30 Johansen, Tor A., Tristan Perez, and Andrea Cristofaro. 2016. “Ship Collision Avoidance and
31 COLREGS Compliance Using Simulation-Based Control Behavior Selection with Predic-
32 tive Hazard Assessment.” *IEEE Transactions on Intelligent Transportation Systems* 17
33 (12): 3407–3422.
- 34 Kim, Kyungmin, Davide Corsi, Andoni Rodríguez, JB Lanier, Benjamí Parellada, Pierre Baldi,
35 César Sánchez, and Roy Fox. 2024. “Realizable Continuous-Space Shields for Safe
36 Reinforcement Learning.” arXiv:2410.02038.
- 37 Kochdumper, Niklas, Hanna Krasowski, Xiao Wang, Stanley Bak, and Matthias Althoff. 2023. “
38 Provably Safe Reinforcement Learning via Action Projection Using Reachability Analysis
39 and Polynomial Zonotopes.” *IEEE Open Journal of Control Systems* 2.

- 1 Krasowski, Hanna, and Matthias Althoff. 2024. “Provable Traffic Rule Compliance in Safe Re-
2 inforcement Learning on the Open Sea.” *IEEE Transactions on Intelligent Vehicles* 9
3 (12): 7617–7634. arXiv:2402.08502.
- 4 Kufoalor, D. K. M., Tor A. Johansen, Edmund F. Brekke, A. Hepsø, and K. Trnka. 2020. “Au-
5 tonomous Maritime Collision Avoidance: Field Verification of Autonomous Surface Vehi-
6 cle Behavior in Challenging Scenarios.” *Journal of Field Robotics* 37.
- 7 Kuwata, Yoshiaki, Michael T. Wolf, Dimitri Zarghitzky, and Terrance L. Huntsberger. 2014. “
8 Safe Maritime Autonomous Navigation with COLREGS, Using Velocity Obstacles.”
9 *IEEE Journal of Oceanic Engineering* 39 (1): 110–119.
- 10 Lee, Changyu, Jinwook Park, and Jinwhan Kim. 2025. “Efficient COLREGs-Compliant
11 Collision Avoidance Using Turning Circle-Based Control Barrier Function.”
12 arXiv:2504.19247.
- 13 Markgraf, Hannah, Shambhuraj Sawant, Hanna Krasowski, Lukas Schäfer, Sébastien Gros, and
14 Matthias Althoff. 2026. “Safe Reinforcement Learning Using Action Projection: Safe-
15 guard the Policy or the Environment?” *Transactions on Machine Learning Research*.
16 arXiv:2509.12833.
- 17 Meyer, Eivind, Amalie Heiberg, Adil Rasheed, and Omer San. 2020. “COLREG-Compliant
18 Collision Avoidance for Unmanned Surface Vehicle Using Deep Reinforcement Learning.
19 ” *IEEE Access* 8. arXiv:2006.09540.
- 20 Müller, Henrik, and Daniel Kudenko. 2025. “Improving the Effectiveness of Potential-Based
21 Reward Shaping in Reinforcement Learning.” In *Proceedings of the International Con-
22 ference on Autonomous Agents and Multiagent Systems (AAMAS)*. arXiv:2502.01307.
- 23 Müller, Marlon, Florian Finkeldei, and Matthias Althoff. 2026. “Falsification-Driven Rein-
24 forcement Learning for Maritime Motion Planning.” *Ocean Engineering* 361: 125579.
25 arXiv:2510.06970.
- 26 Ng, Andrew Y., Daishi Harada, and Stuart Russell. 1999. “Policy Invariance Under Reward
27 Transformations: Theory and Application to Reward Shaping.” In *Proceedings of the
28 International Conference on Machine Learning (ICML)*, 278–287.
- 29 Oh, Donggeon David, Duy P. Nguyen, Haimin Hu, and Jaime F. Fisac. 2025. “Provably Opti-
30 mal Reinforcement Learning under Safety Filtering.” arXiv:2510.18082.
- 31 Patil, Mayur S., Nataraj Sudharsan, Veneela Ammula, Jude Tomdio, Jin Wang, Michael Kei,
32 Sivakumar Rathinam, and Prabhakar R. Pagilla. 2026. “COLREGs Compliant Col-
33 lision Avoidance and Grounding Prevention for Autonomous Marine Navigation.”
34 arXiv:2603.02484.
- 35 Pizarro Bejarano, Federico, Lukas Brunke, and Angela P. Schoellig. 2025. “Safety Filtering
36 While Training: Improving the Performance and Sample Efficiency of Reinforcement
37 Learning Agents.” *IEEE Robotics and Automation Letters*. arXiv:2410.11671.
- 38 Schulman, John, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. 2016. “
39 High-Dimensional Continuous Control Using Generalized Advantage Estimation.” In
40 *International Conference on Learning Representations (ICLR)*.

- 1 Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. 2017. “
2 Proximal Policy Optimization Algorithms.” arXiv:1707.06347.
- 3 Trott, Alexander, Stephan Zheng, Caiming Xiong, and Richard Socher. 2019. “Keeping Your
4 Distance: Solving Sparse Reward Tasks Using Self-Balancing Shaped Rewards.” In
5 *Advances in Neural Information Processing Systems (NeurIPS)*.
- 6 Vaaler, Aksel, Svein Jostein Husa, Daniel Menges, Thomas Nakken Larsen, and Adil Rasheed.
7 2024. “Modular Control Architecture for Safe Marine Navigation: Reinforcement
8 Learning and Predictive Safety Filters.” arXiv:2312.01855.
- 9 Wabersich, Kim P., and Melanie N. Zeilinger. 2021. “A Predictive Safety Filter for Learning-
10 Based Control of Constrained Nonlinear Dynamical Systems.” *Automatica* 129:
11 109597.
- 12 Zhao, Luman, and Myung-II Roh. 2019. “COLREGs-Compliant Multiship Collision Avoid-
13 ance Based on Deep Reinforcement Learning.” *Ocean Engineering* 191: 106436.