

1 连续动作空间下基于投影式安全盾的可证明 COLREGs 方向合规无人船避碰

2 **WeiYu Tang**

3 Graduate Research Assistant

4 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

5 School of Naval Architecture, Ocean and Civil Engineering

6 Shanghai Jiao Tong University, Shanghai, 200240, China

7 Email: weiyutang@sjtu.edu.cn

8 **Jie Xue, Ph.D.***

9 Assistant Research Professor

10 State Key Laboratory of Ocean Engineering

11 School of Naval Architecture, Ocean and Civil Engineering

12 Shanghai Jiao Tong University, Shanghai, 200240, China

13 Email: j.xue@sjtu.edu.cn

14 **Peijie Yang**

15 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

16 School of Naval Architecture, Ocean and Civil Engineering

17 Shanghai Jiao Tong University, Shanghai, 200240, China

18 Email: yangpeijie21@sjtu.edu.cn

19 **Qianbing Li**

20 Shanghai Key Laboratory for Digital Maintenance of Buildings and Infrastructure,

21 School of Naval Architecture, Ocean and Civil Engineering

22 Shanghai Jiao Tong University, Shanghai, 200240, China

23 Email: qianbing_li@sjtu.edu.cn

24 Total Number of Pages: 【待填】

25 Submitted [Submission Date]

26 *Corresponding Author

1 Abstract

2 Objectives : 本文旨在为自主水面航行器的避碰控制建立一种在连续控制量上逐步成
3 立的《国际海上避碰规则》方向合规保证,并界定其适用范围。该规则的让路条款具有方
4 向性:未碰撞但从错误一侧通过的航迹仍属违规。

5 Methods : 我们把让路条款表述为控制量平面上的半平面约束,与执行器量程及单步
6 无碰条件求交,得到凸的安全控制集,并以一个二维二次规划把策略输出投影到该集合的
7 最近可行点;该投影并入环境转移,使策略在训练中即适应修正。数据为公开的双船会遇
8 仿真场景库,共 2000 个算例;官方划分为 1400 训练 / 600 测试,我们把官方训练侧再切
9 为 1300 训练与 100 验证。共设 9 种对照配置构成单变量递进序列,每种以 8 个固定种子
10 训练。

11 Findings : 在投影可行的每一让路决策步上,方向合规由硬约束构造式成立,与训练
12 结果及随机种子无关;转入兜底的步不在此列。测试集上每局违规次数为【待填】、碰撞
13 率为【待填】、到达率为【待填】;到达率不作为效能主张。

14 Novelty : 据我们所知,这是首个在连续控制量上实现该规则方向合规的投影式安全
15 机制,并给出分级的保证陈述,逐条附假设与边界,且列出未被证明的部分。

16 Practical Applications : 该机制的合规判定不依赖训练结果,可作为既有控制系统之上
17 的合规校验层,用于功能验证与责任界定,其保证只覆盖投影可行的让路步。在线计算量
18 为每步一个二维二次规划,无需加速硬件即可实时运行。

19 Keywords : COLREGs 合规;安全强化学习;投影式安全盾;连续动作空间;二次规划
20 ;无人水面航行器

1. Introduction

两船在海上相遇，各自向右转向，安全交错而过。这一幕每天在全球航道上重复无数次，它之所以有效，靠的不是任何一方的临场判断，而是一套双方都遵守、并且都知道对方会遵守的规则。水路运输是国际贸易的主要承运方式，其通行秩序正建立在这种可预期性之上。

当船上没有人时，这种可预期性就成了一个必须被兑现的技术指标。随着国际海事组织推进面向自主船舶的规则框架，自主船与有人船在同一航道内混合航行已成为可预期的运行形态。此时一个与陆上自动驾驶颇为不同的要求浮现出来。海事责任认定不仅看是否发生碰撞，还要看船舶是否按规则行动。一次未发生碰撞、却从错误一侧通过的会遇，在事故调查中依然是违规操作，因为它破坏了对对方赖以决策的预期。这意味着，自主船舶的避碰行为必须是可被审查的规则合规，而不只是统计意义上的安全。

无人水面航行器正逐步进入与有人船共航的公共水域，其避碰行为必须遵守《国际海上避碰规则》（COLREGs）（IMO 1972）。与陆上交通规则相比，COLREGs 有一个决定性的不同，即它的让路条款具有方向性。对遇态势中两船各自向右转向（第 14 条），交叉态势中让路船向右避让、直航船保向保速（第 15、16、17 条），追越态势中追越船负责让清（第 13 条）（IMO 1972）。也就是说，一个动作即使在几何上避免了碰撞，若转向方向违反规则，仍然是违规的。一条从左侧绕过去、全程没有碰撞的轨迹，在海事上并不合格。

这一点使 COLREGs 合规无法用“最终有没有撞上”来验证，也使它成为安全强化学习中一类并不常见的问题，需要保证的不是一个状态量的界，而是每一步动作落在哪个方向的半平面里。现有工作沿两条路径推进，各自放弃了一项关键属性。

第一条路是离散动作加动作屏蔽。它把动作空间离散成有限网格，每一步先用规则状态机算出合规的动作子集，再屏蔽掉其余动作（Krasowski and Althoff 2024），合规性因此可以证明，被屏蔽的动作不可能被选中，而这个保证既不依赖训练结果，也不受随机种子影响。它的代价是放弃了连续控制。真实的舵机与推进器本是连续量，离散网格一方面引入量化抖动，一方面把控制精度锁死在网格分辨率上。对本文的任务还有一处更具体的损失。COLREGs 要求让路转向足够明显，这在数学上是一个下确界，而网格往往取不到它，只能退到最近的档位，于是每一次合规让路都要比规则所需多转一些。

第二条路是连续动作加软性奖励。它保留连续控制，把 COLREGs 写成奖励函数里的一项惩罚（Meyer et al. 2020; Heiberg et al. 2022; Müller et al. 2026）。控制虽然连续了，保证却随之消失。奖励只能塑造策略的期望行为，并不能排除任何一个具体的违规动作，合规率因而随种子起伏，也随训练进程起伏。

于是连续动作 $\cap$ 可证明方向合规 $\cap$ COLREGs 这个三重交集是空的。本文用投影式安全盾把它填上。规则状态机给出合规方向的半平面，与单步无碰约束、动作箱一起构成安全动作集，二次规划把策略的连续指令投影到该集合上最近的点。关键在于可枚举这个前提可以被可投影替代。合规方向恰好是一个半平面，投影到半平面与箱的交集上是一个小规模二次规划，而投影解满足硬约束这件事是构造式的，与训练无关。策略以安全盾在环的方式训练，因而会观察并适应投影带来的修正。

这类工作的难点不只在机制本身，还在于清晰界定所证明的内容。在安全强化学习文献中，“provable”一词覆盖的作用域并不总与读者的默认预期一致。因此本文的第二项工作，是把可证明层逐条分档。有的是严格引理，有的构造式成立，有的只是保守的充分条件，还有的仍停留在设计、尚未经过闭环验证。每一档都附上完整的假设清单与作用域限制，并明确写出哪些部分没有被证明。

贡献。

- 1 1. 连续动作空间中的投影式 COLREGs 安全盾（第 4.2 节）。合规方向作为硬区间约束
2 进入二次规划，因此每一个投影可行的让路步的方向合规是构造式成立的，不依赖
3 训练结果、不受种子方差影响。
- 4 2. 一个分级的安全性陈述（第 4.4 节）。我们把该层能提供的保证按强度逐条给出并
5 划定其作用域。远场单步无碰为严格结论，且对多他船可无损地按目标合取推广；
6 每一让路步的方向合规由构造成立；紧急迫近不可避免则给出一个只漏报、不误报的
7 充分条件证书，它取代了此前只检查转向、会漏掉加减速逃逸的判据。在此基础上
8 我们进一步给出一条通往递归可行性的路径，即证明由该证书定义的可清障集在理
9 想模型下是控制不变的，并据此设计后备机动的终端约束；该路径的闭环验证尚未
10 完成，第 4.4 节标注其状态。
- 11 3. 一个把机制逐级拆开的实验设计（第 5 节）：9 种配置构成一条连通的单变量递进
12 序列，相邻两级之间只改动一个变量，从离散基线一路走到完整方法；其中两跳带
13 有不可分割的伴随变量，这两处伴随变量在递进序列列表的表注中列出。
- 14 4. 一组针对机制本身的检验（第 5 节）。除公开基准外，我们另行构造真冲突算例，
15 用以激活并检验兜底链与终端约束，从而使这些只在极端态势下才会启用的分支获
16 得实证刻画，而不只停留在设计描述。

17 2. Related Work

18 2.1 海事避碰与 COLREGs 合规

19 避碰规则合规的研究最早集中在模型驱动的方法上。速度障碍法用相对速度锥判断
20 碰撞危险并选出规避速度，后被纳入 COLREGs 的让路语义 (Kuwata et al. 2014)，并推广
21 到更一般的船舶会遇 (Huang et al. 2019)。模型预测控制是另一条主线，它在有限预测时
22 域上评估各候选机动的碰撞危险与 COLREGs 合规度并择优执行 (Johansen et al. 2016)，
23 其分支航向变体经过了海上实测 (Eriksen et al. 2019)，并在具挑战性的会遇场景中完成了
24 全尺度验证 (Kufolalor et al. 2020)；更早的协议式方法把规则写成船间可协商的行为约定
25 (Benjamin et al. 2006)。近期这条线转向控制障碍函数与凸优化，用转向圆控制障碍函数
26 表达让路机动 (Lee et al. 2025)，或用凸优化同时处理规则合规与防搁浅 (Patil et al. 2026)
27 。这些方法多建立在标准船舶操纵模型之上 (Fossen 2011)，其保证来自显式约束或规则
28 编码，但控制律由手工设计，不含从数据中学到的策略。

29 随着深度强化学习的发展，避碰策略开始从数据中学习 (Sarhadi et al. 2022)。这条
30 线上的多数工作把操纵指令离散化，例如以有限档舵角为动作、用深度 Q 学习在受限水
31 域完成多船避碰 (Shen et al. 2019)，或面向多船生成合规的规避时机与路径 (Zhao and Roh
32 2019; Chun et al. 2021)。离散化便于优化，也贴近值函数方法的适用范围，代价是控制精
33 度受网格分辨率限制。另一类工作保留连续控制，把 COLREGs 写成随方位与距离衰减的
34 软性惩罚 (Meyer et al. 2020)，或用碰撞风险度量把惩罚做成可调的风险门控 (Heiberg et
35 al. 2022)，也有工作在欠驱动无人艇上验证简洁的强化学习避障 (Cheng and Zhang 2018)
36 。这类工作多以近端策略优化 (Schulman et al. 2017) 为策略主干，可用有界的 Beta 分布
37 (Chou et al. 2017) 参数化连续动作，以避开高斯策略在动作边界处的截断偏差。它们保住
38 了连续控制的精细度，但合规只由奖励诱导，奖励改变的是策略的期望行为，无法排除任
39 何一个具体的违规动作，合规率因而随种子和训练进程波动。

2.2 安全强化学习与可证明合规

在软奖励之外，安全强化学习 (García and Fernández 2015) 研究如何为学习策略附加硬性保证，其中以形式化方法给出保证的一支已有系统的梳理与基准比较 (Krasowski et al. 2023)。另一条常见路线是把安全写成约束马尔可夫决策过程并以拉格朗日方法求解，但它保证的是期望意义下的约束满足，仍不能排除任何一个具体的违规动作，与本文所需的逐步硬约束不是同一类保证。动作屏蔽在离散动作上按时序逻辑规范剔除不安全动作 (Alshiekh et al. 2018)，其可实现的形式已被推广到连续动作空间，但针对通用任务、未涉及海事规则 (Kim et al. 2024)。在连续控制上，控制障碍函数的二次规划 (Ames et al. 2019) 与预测式安全滤波 (Wabersich and Zeilinger 2021) 以最小干预修正动作；后者也被接到海事强化学习之上，但只约束碰撞、不含 COLREGs 的方向条款 (Vaaler et al. 2024)。与本文机制最接近的是安全层方法，它把约束在当前状态处线性化，再把策略动作解析地投影到由此得到的线性半空间上 (Dalal et al. 2018)；本文的投影与之同源，新增的部分是把 COLREGs 让路条款的方向性编码为动作平面上的半平面，使被强制的对象由状态约束变为规则合规。动作投影的另一条路线借助可达性分析构造安全动作集，一种实现以多项式 zonotope（带状凸集）保证投影的安全性 (Kochdumper et al. 2023)，另一项工作比较了把投影盾并入环境转移与嵌入可微策略两种做法，并证明在策略梯度族（以广义优势估计一类算法为前提，(Schulman et al. 2016)）下两者的学习目标相同 (Markgraf et al. 2026)。这条线在连续动作上给出了对碰撞或状态约束的硬保证，但据我们检索到的文献，没有一项把 COLREGs 让路条款的方向性写进安全集。

由此形成一处结构性的空缺。在海事场景中，规则合规的硬保证此前只在离散动作空间上实现过，其代表是把 COLREGs 形式化为时序逻辑谓词与状态机、并在 49 个离散动作上施加动作屏蔽的工作 (Krasowski and Althoff 2024)；该工作同时提供了本文使用的场景库与状态机阈值，也是本文复现的离散基线。作者在文中把连续动作空间下的动作投影列为未来方向，并指向基于可达性的投影 (Kochdumper et al. 2023)。沿这一方向的后续工作转入连续动作，却以软性奖励结合证伪式训练来逼近合规，没有给出硬保证 (Müller et al. 2026)。本文在连续控制上给出方向合规的构造式保证，并以 zonotope 加二次规划投影 (Markgraf et al. 2026) 替代多项式 zonotope 表示，以降低单步求解的计算量。

2.3 奖励塑形与安全盾的副作用

方向约束会在紧急与近域收紧可行动作集、可能损失终端效率，本文因此用势函数型塑形帮助策略追回效率。势函数型塑形不改变最优策略集 (Ng et al. 1999)，但朴素的距离型塑形容容易停在目标附近 (Trott et al. 2019)，单一连续势也难以根治这一问题 (Müller and Kudenko 2025)，故本文改用线性核并把“真正到达”设为终端条件，与把控制指标编入塑形并给出保证的做法一致 (De Lellis et al. 2024)。安全盾对性能与终端行为的影响另有专门研究，训练中纳入滤波并惩罚修正量可提升样本效率 (Pizarro Bejarano et al. 2025)，足够宽松的滤波不损渐近最优 (Oh et al. 2025)，而安全项与目标项对冲会造成目标前停滞 (Grover et al. 2023)。本文据此设置与投影修正量成正比的动作混叠惩罚，并保留反向证据，即预测式安全滤波在某些海事设置下并不损失性能 (Vaaler et al. 2024)。

3. Problem Formulation and Environment Modeling

3.1 运动学模型

全文所用记号汇总于表 1。角度一律折算到 $(-\pi, \pi]$ ，并约定右舷为正、左舷为负，故转艏率 $\omega < 0$ 表示右转。

TABLE 1 符号表

符号	含义	符号	含义	符号	含义
s	本船状态向量	ρ	会遇态势 (ρ_0 – ρ_5)	θ, v	艏向、航速
$U_{\text{colregs}}(\rho)$	规则允许的控制集	$u = (a, \omega)$	控制 (加速度, 转艏率)	$U_{\text{cf}}(s)$	无碰撞约束集
a, ω	纵向加速度、转艏率	U_{box}	执行器物理量程箱	Δt	决策周期
$U_{\text{safe}}(s, \rho)$	安全动作集	$a_{\text{max}}, \omega_{\text{max}}$	执行器量程上限	$\Pi_{U_{\text{safe}}}$	向 U_{safe} 的欧氏投影
$a_{\text{op}}, \omega_{\text{op}}$	策略动作箱半宽	$u_{\text{policy}}, u_{\text{safe}}$	策略输出、执行控制	v_{max}	航速上限
Δ_{lt}	明显转向阈值	v_{bnd}	步内航速上界	Δ_{nt}	直航容差角
$\oplus$	Minkowski 和	T_M	机动段时长	$\text{disk}(r)$	半径 r 的闭圆盘
ω_{turn}	合规转艏率下确界	$R_{\text{circ}}, r_{\text{insec}}$	外接圆、内切圆半径	$\varepsilon_a, \varepsilon_\omega$	直航保速、保向容差
O	他船占据	T_h, T_{pred}	碰撞可能、紧急预测时域	d	两船中心距
$R_{\text{box}}(t)$	可达中心过近似集	p_e, p_m	本船/他船中心位置	A_{clr}	可清障集
$v_{\text{obs, max}}$	他船速度上界 (设)	γ	折扣因子	K	回合步数上限
α, β	Beta 分布形状参数	Φ	势函数 (塑形)	r	单步回报
Δ_{ho}	前扇区半角/对遇带	Δ_{sd}	舷侧扇区外边界	Δ_{ot}	追越带半角
T_{react}	反应时域 (状态机)	r_m	他船膨胀半径 (判态势)	v_ε	速度集半宽
C_m	碰撞锥	V_e	本船速度集	R_m	他船占据圆半径 (含裕)
d_{safe}	无碰撞所需中心距	u_{nom}	线性化基点	p_{nom}	标称落点
J	落点对控制的雅可比	n, δ	分离方向、分离距离	g, h	无碰撞约束系数与右端
A, b	安全集约束矩阵与右端	a_{eff}	速度矢量变化率上界	$B_{\text{lon}}, L_{\text{lat}}$	可达集纵/横向半轴
a_{st}	紧急 stern 模式加速度	d_{ah}	紧急 ahead 目标距离	$\Delta_{\text{ah}}, \Delta_{\text{st}}$	紧急 ahead/stern 判角
ℓ_m	他船船长 (逐场景)	$L \times W$	船体尺度		

受控船舶建模为受偏航约束的质点，状态 $s = [p_x, p_y, \theta, v]^\top \in \mathbb{R}^4$ ，以纵向加速度 a 与转艏率 ω 为控制输入：

$$\dot{s} = [v \cos \theta, v \sin \theta, \omega, a]^\top, \quad u = [a, \omega]^\top, \quad (1)$$

控制受箱约束 $|a| \leq a_{\text{max}}$ 、 $|\omega| \leq \omega_{\text{max}}$ ，航速受 $0 \leq v \leq v_{\text{max}}$ 限制，决策以零阶保持方式每 Δt 施加一次。航速界在整个决策步积分完成之后才施加，故步内航速可短暂超出 v_{max} ；单步位移界因此必须计入步内加速，取 $v_{\text{max}} \Delta t + \frac{1}{2} a_{\text{max}} \Delta t^2$ ，步末航速上界 v_{bnd} 由 $v_{\text{max}} + a_{\text{max}} \Delta t$ 给出。安全盾内部用于验证后备机动的积分则在积分过程中即施加饱和，是更保守的模型；全文凡涉及单步位移界的推导一律取前者。

选择这一模型层级出于两点考虑。其一，COLREGs 的让路条款规定的正是航向与航速的变化，而式 (1) 把两者直接作为控制输入，规则因而可以不经中间变量地写成对 u 的约束，这是本文全部安全机制得以落在动作空间里的前提。其二，更精细的水动力模型会引入依船而异、难以辨识的系数，使规则约束与船型参数纠缠，反而削弱结论的普适性。本文亦不建模风、流、浪等环境扰动。

建模对象与占据表示。我们以一条大型集装箱船为对象，船长 175 m、船宽 25.4 m。纵向加速度上限取 0.24 m/s²，转艏率上限取 0.03 rad/s，航速上限取 9.5 m/s；决策周期取 10 s，单个回合最多 170 步，合 1700 s。船体外接圆半径为 88.4 m，内切

1 圆半径为 12.7 m，步末航速上界因而为 11.9 m/s。该转艏率上限折合仅约 $1.7^\circ/\text{s}$ ，一次
 2 20° 的明显转向需十余秒才能完成，慢于一个决策周期；这一“操纵慢于决策”的特征既
 3 是安全约束必须前瞻的原因，也是后文递归可行性得以成立的几何基础。船体占据用矩形
 4 表示，并按用途取两个圆近似。外接圆 $\text{disk}(R_{\text{circ}})$ 过近似船体，用于构造“一定不碰”的
 5 充分条件；内切圆 $\text{disk}(r_{\text{insc}})$ 欠近似船体，用于构造“一定会碰”的充分条件。两个方向
 6 各取一个圆，是两侧结论都单侧保守的关键。他船同样以矩形占据表示，需要外推时取恒
 7 速外推，该假设的代价在第 4.4 节逐条标注。

8 3.2 观测与动作空间

9 观测为 27 维实向量，含受控船状态 4 维（航速、艏向、纵向加速度、转艏率）；
 10 目标相关 5 维（距离、剩余步数、艏向与目标朝向区间之差、纵向偏差、横向偏差）加 1
 11 维“是否已在目标框外”的指示位；交通态势 12 维，即前 / 左 / 右 / 后四个方位扇区各取
 12 该扇区内最近他船的三个量（距离、相对方位、相邻两个决策步之间的距离增量，该增量
 13 以米为单位、未除以 Δt ）；终止相关 5 维（超时、出界、停住、碰撞、到达）。观测层
 14 输出原始物理量，归一化在训练包装层完成。以扇区为单位组织交通信息，使观测维数不
 15 随他船数目改变；但这只解决了维数问题——本文部署的安全盾按单他船实现，遇到多于
 16 一艘他船时显式报错而非降级运行，因此多他船既未训练也未评估。

17 动作为二维连续量 $u = (a, \omega)$ ，此处需要区分两个箱。策略的动作空间是较窄的常
 18 规操作箱 $\{|a| \leq a_{\text{op}}\} \cap \{|\omega| \leq \omega_{\text{op}}\}$ ，两轴半宽分别取 0.048 m/s^2 与 0.018 rad/s ，恰等于
 19 对标工作所用 7×7 量化网格的张成范围，使两种动作空间的控制权限相同、仅分辨率不
 20 同；执行器物理量程箱 $U_{\text{box}} = \{|a| \leq a_{\text{max}}\} \cap \{|\omega| \leq \omega_{\text{max}}\}$ 更宽，只留给安全盾与紧急控制
 21 器。放宽是必要的。安全盾必须能在需要时动用超出策略权限的操纵能力，否则一旦策略
 22 的窄箱与无碰撞约束不相容，本来可解的局面会被误判为不可行。其代价是安全盾实际施
 23 加的控制可以落在策略动作箱之外，这一点在观测中如实回传，并在统计动作饱和率时按
 24 各自的箱分别计算。

25 3.3 问题表述

26 我们考虑开阔水域的双船会遇，并作如下假设：

- 27 (A1) 开阔水域，无航道分隔、无静态障碍、无岸线约束；
- 28 (A2) 场景中有一条受控船与一条他船，均为机动船；
- 29 (A3) 受控船动力学由式 (1) 描述，控制以 Δt 为周期零阶保持；
- 30 (A4) 他船当前状态无量测误差地可得；
- 31 (A5) 会遇初始时刻不存在任何已生效的让路义务。

32 假设 (A2) 不是为简化而作的让步，而是 COLREGs 本身的适用边界。该规则集是
 33 成对制定的，当三船以上同时相遇、且各自的义务互相冲突时（例如对一条船须保向保速
 34 、对另一条须避让），公约本身并未规定如何取舍。多他船情形下各结论如何合成、以及
 35 在何处必然失效，见第 4.4 节。

36 令 ρ_t 为 t 时刻的会遇态势， $U_{\text{colregs}}(\rho_t) \subseteq \mathbb{R}^2$ 为该态势下规则允许的控制集合（
 37 第 4.1 节给出其形式）， $U_{\text{cf}}(s_t)$ 为无碰撞约束集，所求为一个策略

$$\pi : S \rightarrow \mathbb{R}^2 \quad \text{使得} \quad u_t \in U_{\text{colregs}}(\rho_t) \cap U_{\text{cf}}(s_t) \quad \forall t. \quad (2)$$




Figure 1 方法总览。27 维观测经策略网络给出期望控制 $u_{\text{policy}} = (a, \omega)$ ，其输出分布为支撑有界的 Beta 分布。规则状态机把当前会遇判入六类态势 ρ_0 – ρ_5 。安全动作集 $U_{\text{safe}} = U_{\text{box}} \cap U_{\text{colregs}}(\rho) \cap U_{\text{cf}}(s)$ 由执行器量程、合规方向半平面与单步无碰约束求交而成；二次规划把 u_{policy} 投影到 U_{safe} 内最近的可行点 u_{safe} 后送入环境。该投影并入环境转移，即安全盾位于训练回路之内，策略在训练过程中即适应投影的存在。两条旁路互斥：紧急态 ρ_5 直接交紧急控制器（ u_{em} ，该态不构造无碰约束、不求解二次规划）； ρ_0 – ρ_4 仅在 $U_{\text{safe}} = \emptyset$ 时兜底（ u_{fb} ）。右下角为动作平面 (a, ω) 上三个约束集的示意。

- 1 式 (2) 与“把合规写进奖励”有本质区别。它要求每一步执行的动作都落在集合内，而非
- 2 要求某个期望值达到最优。
- 3 当动作集有限时，式 (2) 有一个直接解法，即枚举全部动作、逐个检验、屏蔽不合
- 4 规者。这条路要求动作可枚举，因而与连续控制不相容，而船舶的舵与推进本是连续量，
- 5 量化会同时带来抖动与精度损失。本文的核心思路是把“可枚举”这一前提替换为“可投
- 6 影”。让路条款在动作空间中恰好表现为半平面约束（第 4.1 节），无碰撞条件可写成线
- 7 性不等式（第 4.2 节），故式 (2) 的可行集是二维空间中若干半平面与一个矩形之交，为
- 8 凸多边形；向凸集的投影存在且唯一，可由一个规模极小的二次规划求得。

9 4. Methodology

10 本节给出投影式安全盾的构造。我们先把 COLREGs 让路条款形式化为动作空间中

11 的集约束（第 4.1 节），据此构造安全动作集与投影算子（第 4.2 节）；随后说明策略

12 如何在带盾环境中学习（第 4.3 节）；最后分析该机制能够严格保证什么、不能保证什么

13 （第 4.4 节）。

14 4.1 COLREGs 让路条款在动作空间中的形式化

15 4.1.1 会遇态势的谓词化

16 谓词结构、阈值取值与判定优先序沿用 (Krasowski and Althoff 2021) 的时序逻辑形

17 式化及其在 (Krasowski and Althoff 2024) 中的实现。本文在此之上新增三项，即碰撞可能

18 性谓词中膨胀半径与速度集半宽的显式取值、让路态入口的对称化（第 4.3.4 节），以及

19 把这套谓词接到连续动作的约束集上。

1 规则状态机把当前会遇归入六类,

$$\rho \in \{\rho_0 \text{ 无冲突}, \rho_1 \text{ 直航}, \rho_2 \text{ 对遇}, \rho_3 \text{ 交叉}, \rho_4 \text{ 追越}, \rho_5 \text{ 紧急}\},$$

2 判定由三组谓词合取而成。第一组是方位扇区, 按公约的舷灯分界把他船相对本船的方位
3 划入前、左、右、后四区, 前扇区半角取 5° , 舷侧扇区外边界取 112.5° 。第二组是航向
4 关系, 区分两船航向近反平行、近同向, 以及他船朝向偏左与偏右, 追越航向带半角取
5 67.5° 。第三组是碰撞可能性, 要求本船速度集与他船碰撞锥相交, 且两船相对速度足以
6 在检查时域内消耗掉当前中心距; 碰撞锥以本船位置为顶点, 对按膨胀半径放大的他船占
7 据作外切, 再沿他船速度平移得到。膨胀半径按他船真实船长取其三倍, 速度集半宽取
8 1 m/s , 检查时域取 420 s , 前两个取值在所沿用的文献中未明确给出, 此处一并写明。

9 三组谓词合成四类有义务的态势,

$$\begin{aligned} \rho_2 \text{ 对遇: } & \text{CP} \wedge \text{Fr}(s_e, s_m) \wedge \text{Ap}, \\ \rho_3 \text{ 交叉: } & \text{CP} \wedge \text{Ri}(s_e, s_m) \wedge \text{Ti}, \\ \rho_4 \text{ 追越: } & \text{CP} \wedge \text{Be}(s_m, s_e) \wedge (v_e > v_m) \wedge \text{Sd}, \\ \rho_1 \text{ 直航: } & [\text{CP} \wedge \text{Le}(s_e, s_m) \wedge \text{Tr}] \vee \rho_4(s_m, s_e), \end{aligned} \quad (3)$$

10 其余情形归入 ρ_0 。追越与“本船被追越”两支都需交换两船参数, 因为追越要求本船位
11 于他船的后扇区。四个谓词在几何上可能同时成立, 故按上式的书写次序取优先。

12 状态机的转移由持续性条件触发。从无冲突态进入让路态, 要求某个让路谓词当前
13 尚未成立、却在长度为 60 s 的反应窗内逐个决策步恒速外推后持续成立。其中“当前尚未
14 成立”这一合取项是必要的, 它把“即将持续成立”与“已经成立”区分开, 但也带来一
15 处不对称, 详见第 4.3.4 节。紧急态另由一个更强的集合预测判据进入, 预测时域取 180 s
16 。

17 合规动作集。每一类态势对应一个显式的控制约束集,

$$U_{\text{colregs}}(\rho) = \begin{cases} U_{\text{box}}, & \rho = \rho_0, \\ \{|a| \leq \varepsilon_a\} \cap \{|\omega| \leq \varepsilon_\omega\}, & \rho = \rho_1, \\ \{\omega \leq -\omega_{\text{turn}}\}, & \rho \in \{\rho_2, \rho_3\}, \\ \{\omega \leq -\omega_{\text{turn}}\} \text{ 或 } \{\omega \geq +\omega_{\text{turn}}\}, & \rho = \rho_4, \\ U_{\text{box}}, & \rho = \rho_5, \end{cases} \quad (4)$$

18 两个动作箱的区分见第 3.2 节。对遇与交叉要求向右转, 追越允许择一侧转向, 直航要求
19 保向保速, 因而全部落在控制量平面上的半平面或区间形式。这正是后文能以投影替代枚
20 举的原因。

21 “足够明显”的量化。公约要求让路动作的幅度大到能被对方及时察觉。把“明
22 显”量化为在机动时段内航向改变不少于给定阈值, 机动时段取 40 s 、航向阈值取 20° ,
23 即得

$$\omega_{\text{turn}} = \frac{\Delta_{\text{lt}}}{T_M} = \frac{20^\circ}{40 \text{ s}} \approx 0.008727 \text{ rad/s}. \quad (5)$$

24 它是合规转艏率的下确界, 任何幅度不小于它的转向都合规, 且该界不可再降。

25 由此得到一个可以直接算出来的结构性差异。若动作空间被量化为 7×7 的 49
26 点网格, 转艏轴取值为 0 、 ± 0.006 、 ± 0.012 与 $\pm 0.018 \text{ rad/s}$ (量化动作空间另设第 50

1 个动作，它不是网格点，而是紧急态下由紧急控制器在线算出的状态相关动作），则
 2 0.006 rad/s 那一档在 40 s 内只转过 13.75°，不足 20°，网格上最小的合规档位因而是
 3 0.012 rad/s，比该下确界高出 37.5%。需要限定的是，这一比例是本文所复现的这一网格
 4 的性质，而非动作离散化的固有性质，更细的网格可以缩小差距，代价是动作数与屏蔽开
 5 销的增长。也就是说，量化动作空间每执行一次合规让路，转艏幅度都必须超出规则要求
 6 约三成七，代价是多余的航向偏离与额外的舵动作。连续动作可以精确取到该下确界，这
 7 一优势与训练过程无关，纯由动作空间的分辨率决定。

8 4.2 安全动作集与投影

9 4.2.1 单步无碰撞约束

10 对当前状态 s 与他船占据 O ，我们要求施加的控制在下一个决策步末不致使两船体
 11 相交。直接写出该条件是非凸的，故取一个保守的凸内近似，其构造分三步。

12 把他船在一个决策步之后的占据外近似为圆盘，圆心 p_m^+ 取恒速外推、半径 R_m 已
 13 含安全裕度，本船以外接圆过近似，于是“两船体不交”的一个充分条件是两圆心距不小
 14 于

$$d_{\text{safe}} = R_{\text{circ}} + R_m. \quad (6)$$

15 记 $p_e(u)$ 为本船在控制 u 下一个决策步之后的位置， u_{nom} 为线性化基点（取裁剪进动作箱
 16 的策略输出）， $p_{\text{nom}} = p_e(u_{\text{nom}})$ 。取分离方向为由他船指向本船标称落点的单位向量

$$n = \frac{p_{\text{nom}} - p_m^+}{\|p_{\text{nom}} - p_m^+\|}, \quad \delta = \|p_{\text{nom}} - p_m^+\|. \quad (7)$$

17 把落点沿控制作一阶展开， $p_e(u) \approx p_{\text{nom}} + J(u - u_{\text{nom}})$ ，其中 $J = \partial p_e / \partial u \in \mathbb{R}^{2 \times 2}$ 为落点
 18 对控制的雅可比。将“落点位于分离超平面的安全侧”写成 $n^\top (p_e(u) - p_m^+) \geq d_{\text{safe}}$ ，代入
 19 展开式即得对 u 的一条线性不等式

$$\underbrace{-n^\top J}_{g^\top} u \leq \underbrace{-(d_{\text{safe}} - \delta + n^\top J u_{\text{nom}})}_h, \quad U_{\text{cf}}(s) = \{u : g^\top u \leq h\}. \quad (8)$$

20 这里需要说明一阶展开与保守性的关系。线性化本身既非内近似也非外近似，其余
 21 项符号随曲率变化，故仅由式 (8) 并不能直接断言保守。使该断言成立的是安全距离
 22 中预留的裕度。他船占据圆的半径取其外接圆再叠加 $2\ell_m$ 的安全裕度（ ℓ_m 为逐场景
 23 真实他船船长，本库中 $\ell_m \in [200, 300]$ m，故该裕度为 400–600 m）。另一方面，落点
 24 线性化的余项在整个执行器量程箱上有界。在全速域与全艏向上数值求其上确界，得
 25 $\sup \|p_e(u) - p_{\text{nom}} - J(u - u_{\text{nom}})\| \leq 10.4$ m，不足该裕度的 3%。余项因而被裕度整体吸收
 26 ， U_{cf} 内的控制满足原始的无碰条件，反之不然。这一论证依赖于裕度的存在，若改用不
 27 含裕度的占据表示，则须把余项界显式加入 d_{safe} 才能保持该性质。

28 需要一并说明这一裕度的量级及其后果。叠加裕度后，无碰撞约束实际施加在约
 29 590–840 m 的中心距上（ $d_{\text{safe}} = R_{\text{circ}} + R_m$ ，按本库他船尺寸实算，中位约 714 m），而
 30 两船真正接触约在 240 m 的中心距，即约束点是真实接触距离的二至三倍。这一选择使无
 31 碰撞约束在本基准上极少成为紧约束，安全动作集也因此很少为空（第 4.2 节末给出该现
 32 象的实测），代价是绕行距离与终端对准难度的增加。两种情形下该线性化不成立，须
 33 转入兜底，其一是 $\delta \rightarrow 0$ （标称落点与他船占据圆心重合，分离方向无定义），其二是
 34 $\|n^\top J\| \approx 0$ 且该约束处于紧约束状态（本船在该分离方向上没有控制权限，例如近零速时
 35 落点对转艏率的雅可比降秩），此时式 (8) 退化为 $0 \leq h < 0$ ，对一切 u 不可行。

4.2.2 安全动作集与投影算子

安全动作集取三者之交

$$U_{\text{safe}}(s, \rho) = U_{\text{box}} \cap U_{\text{colregs}}(\rho) \cap U_{\text{cf}}(s), \quad (9)$$

它是 $\mathbb{R}^2$ 中的凸多边形。给定策略给出的期望控制 u_{policy} ，实际执行的控制取其在 U_{safe} 上的欧氏投影

$$u_{\text{safe}} = \Pi_{U_{\text{safe}}}(u_{\text{policy}}) = \arg \min_{u \in U_{\text{safe}}} \|u - u_{\text{policy}}\|_2^2. \quad (10)$$

式 (10) 的可行集是若干半平面之交，可统一写成 $U_{\text{safe}} = \{u : Au \leq b\}$ ，其中

$$A = \begin{bmatrix} I_2 \\ -I_2 \\ c^\top \\ g^\top \end{bmatrix} \in \mathbb{R}^{6 \times 2}, \quad b = \begin{bmatrix} u_{\text{hi}} \\ -u_{\text{lo}} \\ c_0 \\ h \end{bmatrix}, \quad (11)$$

前四行为动作箱 $u_{\text{lo}} \leq u \leq u_{\text{hi}}$ ，第五行 $c^\top u \leq c_0$ 为式 (4) 给出的合规方向半平面（如让路态的 $\omega \leq -\omega_{\text{turn}}$ 对应 $c = [0, 1]^\top$ 、 $c_0 = -\omega_{\text{turn}}$ ； ρ_0 与 ρ_5 无此行， ρ_1 则为两条逐轴区间），第六行为式 (8) 的无碰撞约束。因此这是一个两变量、至多六条约束的二次规划，其解存在且唯一。我们把 $\|u_{\text{safe}} - u_{\text{policy}}\|$ 记为投影修正量，它度量策略输出与规则要求之间的差距，并在实验中作为一项诊断指标上报。

4.2.3 安全动作集为空时的兜底

安全动作集为空时投影无解，此时须由一条不提供保证的替代规则给出控制，本文称之为兜底。兜底的处置按态势分支，而非按一条固定优先级依次尝试，可分为两条互斥的通道。

- 紧急态通道。紧急态 ρ_5 自成一派，该态不构造无碰撞约束、也不求解式 (10)，而是直接交给紧急控制器。该控制器是一个有状态的三模式几何律，其生命周期对应一次完整的紧急事件。进入 ρ_5 的首步选定模式并记录初始快照，此后模式不再重选（ahead 模式可单向切换到 base）。模式判据互斥，

$$\begin{aligned} \text{ahead} &: |\beta| \leq \Delta_{\text{ah}} \wedge \text{两船航向近反向 (带宽 } \Delta_{\text{ah}}), \\ \text{stern} &: \text{他船位于本船后方扇区 (偏移 } \Delta_{\text{st}}) \wedge \text{沿 } u_{\text{acc}} \text{ 加速可确定解除紧急}, \\ \text{base} &: \text{其余情形}, \end{aligned} \quad (12)$$

其中 $\Delta_{\text{ah}} = 45^\circ$ 、 $\Delta_{\text{st}} = 20^\circ$ 。三种模式的控制律如下。ahead 模式跟踪一个由初始快照确定的固定目标点，该点位于初始位置沿规定转向一侧 90° 方向、距离 $d_{\text{ah}} = 3\ell_m$ 处；当本船自初始位置起的行驶距离超过该阈值而紧急仍未解除时，单向切换到 base。stern 模式取

$$u = \begin{cases} (a_{\text{st}}, 0), & t < T_{\text{react}}, \\ (0, 0), & t \geq T_{\text{react}}, \end{cases} \quad a_{\text{st}} = 0.2a_{\text{max}}, \quad (13)$$

即在反应窗内直线加速脱离、其后停止施控。base 模式跟踪一个随他船当前位置移动的目标点。三种模式都经同一个位置跟踪律换算为 (a, ω) 。该控制器不提供任何保证，它的作用范围由第 4.4 节的迫近不可避判据界定。

- 其余态势的兜底。 $\rho_0\text{--}\rho_4$ 只在 $U_{\text{safe}} = \emptyset$ 时兜底，且先判一种退化情形。若线性化给不出可用的分离方向，即本船标称落点与他船膨胀占据的圆心重合、或本船在该分离方向上没有控制权限（近零速时落点对转艏率的雅可比降秩），则直接返回箱内投影占位（记为“退化”），不再求解任何二次规划。否则先放松方向约束、只保留动作箱与无碰撞约束求解（记为“放松”），仍不可行才改解一个最小化最坏碰撞侵入量的软约束二次规划（记为“碰撞风险最小化”）。

有两点须注意。其一，占据仅仅已经相交并不会触发退化，那种情形照常走放松与碰撞风险最小化。其二，放松与碰撞风险最小化都在执行器物理量程上求解并整块丢弃合规约束，故转艏率可达 ω_{max} 。因此紧急控制器与后三支互斥，前者只出现在 ρ_5 ，后三支只出现在 $\rho_0\text{--}\rho_4$ 。这一支是经验性的，不提供任何保证。本文从两个方向界定这一支。在第 4.4 节给它配一个可判定的边界，即一个保守判据，用来识别“碰撞在物理上已不可避免”的状态；同时用一组专门构造的对抗场景检验它是否真的会被触发。

后一点是必要的，因为在本文使用的公开基准上，兜底几乎不发生。我们实测该基准的场景，本船若保持航向航速，与他船的最近中心距中位数约 1300 m，只有极少数算例会真正逼近，安全动作集因而基本不会为空。三支兜底的实测触发率也印证了这一点。在该基准上，碰撞风险最小化占决策步的 0.18%，放松与退化两支均未触发；即便在下述专门构造的真冲突算例上，退化一支仍未触发。因此三支兜底虽在实现上必须完备，其在本基准上的实际影响很小，本文据此把篇幅留给真正被频繁使用的紧急通道。为此我们以该基准场景为模板、只重造他船轨迹，使本船的保向航迹与他船的恒速航迹在指定时刻真正相交，从而得到真冲突的算例；会遇态势一律用与安全盾同一套谓词复判。在这组算例上，兜底分支确实被触发。碰撞风险最小化一支的触发率由基准上的 0.18% 升至 1.58%，放松一支则由从未触发变为可被观测到。该结果只用于刻画兜底机制本身是否可被激活，其场景为合成算例，不与主结果表并列。

4.3 策略学习

4.3.1 带盾的马尔可夫决策过程

我们不把安全盾放在策略之后作为事后纠正，而是把式 (10) 并入环境的转移。策略输出 u_{policy} ，环境施加 u_{safe} 并返回相应的后继状态与回报，即策略面对的是复合转移

$$s_{t+1} \sim P(\cdot \mid s_t, \Pi_{U_{\text{safe}}(s_t, \rho_t)}(u_t)), \quad u_t \sim \pi(\cdot \mid s_t), \quad (14)$$

而非事后滤波所对应的 $P(\cdot \mid s_t, u_t)$ 。这样策略学习到的是经过投影之后的转移，因而会主动适应投影的存在，而不必在训练结束后再与一个陌生的滤波器磨合。

4.3.2 回报函数

回报结构沿用 (Krasowski and Althoff 2024) 的设定，除本节末声明的三处偏离外逐项相同。回报由五项相加而成，

$$r = r_{\text{sparse}} + r_{\text{goal}} + r_{\text{velocity}} + r_{\text{deviate}} + r_{\text{colregs}}, \quad (15)$$

各项定义如下，系数取值见表 2。

- 终止稀疏项 r_{sparse} 在回合终止时按事件给出，到达为 c_{goal} 、超时为 c_{time} 、原地停住为 c_{stop} 、碰撞为 c_{coll} ，并对每一个进入紧急控制的决策步给固定惩罚 c_{em} 。它另含一个“驶出航行区”事件 c_{area} ，但本基准场景不带航行区边界，该事件与其观测位在本文全部实验中恒不触发，此处列出以保证实现描述完整。

- 趋近项为稠密的向目标位移奖励,

$$r_{\text{goal}} = c_{\text{reach}}(\|p_{t-1} - p_g\| - \|p_t - p_g\|), \quad (16)$$

其中 p_g 为目标位置。

- 航速项 r_{velocity} 对航速落在巡航区间 $[2.5, 8.0]$ m/s 之外的部分按偏离量线性惩罚。
- 偏差项 r_{deviate} 惩罚偏离起点至目标参考线的横向距离, 并在 2000 m 处饱和。
- 软性合规项 r_{colregs} 为随距离衰减的合规惩罚, 其中他船径向速度按其速度上界 10.0 m/s 归一化、指数项施加上限钳制。它只在软性奖励对照组与离散动作屏蔽配置上启用 (后者忠实复现 (Krasowski and Althoff 2024) 的原始设定, 该工作在动作屏蔽之外保留了这一惩罚项), 无盾基线与本文全部连续动作配置一律置零, 因为本文方法的合规由式 (4) 的硬约束承担。各配置取值见表 4。

相对 (Krasowski and Althoff 2024) 的公开设定, 本文有三处偏离, 需要显式声明。其一, 趋近项 r_{goal} 取上式的差分方向。按另一种常见写法, 趋近目标反而得到负回报, 与“奖励趋近目标”的意图相悖, 我们采用物理上一致的写法。其二, 软性合规项 r_{colregs} 的原始参数是在约 150 m 的作用尺度上标定的, 而本任务的场景尺度约 8000 m, 直接代入会使其指数项发散, 故我们将他船径向速度按其速度上界归一化, 并对指数项施加上限钳制。其三, 紧急态的解除判据含三项合取, 即他船落在本船后 $\pm 90^\circ$ 、两船艏向单位向量点积不为正 (即航向夹角不小于 90°), 以及中心距不小于 $2L$ 。第三项在原文中文字面写作“距离不大于该阈值”, 与其自身注文所述的“距离足够大”相悖, 我们判为笔误并按物理语义取不小于。该判据决定紧急态的驻留时长, 因而影响紧急控制步的占比, 故一并声明。

4.3.3 有界动作分布

连续策略通常输出无界高斯分布并在送入环境前裁剪到动作箱。这一组合与式 (10) 相冲突, 原因有两点, 都与“裁剪”这一操作本身有关。其一, 常见实现把裁剪后的动作用于环境、却把裁剪前的动作用于策略梯度, 于是一旦分布的均值移出动作箱, 再往外移动不改变任何回报, 梯度进入平高原, 任何以动作平顺性为目标的惩罚项都失去着力点。其二, 高斯分布的微分熵为 $\sum_i \log \sigma_i + \text{const}$, 没有上界, 而熵正则项的系数是常数, 于是标准差存在一条“只涨不跌”的通道, 把越来越多的采样推到箱外, 加剧前一个问题。

我们改用支撑为闭区间的 Beta 分布。动作因此按构造不可能越箱, 裁剪退化为恒等映射, 上述两条通道同时封闭; 平顺性惩罚处处可微, 且 Beta 的熵有上界 (在均匀分布处取得)。具体地, 网络对每个控制轴输出两个实数 $(\tilde{\alpha}, \tilde{\beta})$, 形状参数与执行动作由

$$\alpha = \text{softplus}(\tilde{\alpha}) + 1, \quad \beta = \text{softplus}(\tilde{\beta}) + 1, \quad u = u_{l0} + (u_{hi} - u_{l0})z, \quad z \sim \text{Beta}(\alpha, \beta) \quad (17)$$

给出, 评估时取确定性动作, 即以众数 $z^* = (\alpha - 1)/(\alpha + \beta - 2)$ 代替采样。这一参数化使两个形状参数严格大于 1。这一约束不可省。当形状参数小于 1 时 Beta 呈 U 形, 密度在两端发散, 等价于一个数学形式的 bang-bang 控制; 更关键的是此时分布的众数落在区间端点, 而区间内部的驻点是密度的极小值, 由于评估一律使用确定性动作 (取众数), 这会静默地污染每一个上报数字, 且在聚合指标上无从察觉。需要说明的是, 该约束只保证分布单峰且端点密度有限, 并不阻止策略选择接近饱和的动作; 真正起作用的是“支撑落在箱内”与“熵有上界”这两条。

4.3.4 让路态入口的对称化

状态机中“无冲突 → 让路”这一转移原本只由持续性条件触发，而“直航 → 让路”另有一条即时条件。我们补上对称的一支，即持续性条件未命中时，再检查即时条件是否已成立，成立即进入让路态。该改动使让路义务的识别时机在两条入口上一致，代价是它改变安全盾实际施加的动作，因此训练与评估必须在同一设置下进行。这一改动的必要性可以在专门构造的算例上直接看到。若一次会遇在初始时刻就已满足让路谓词，则持续性条件中“当前尚未成立”这一必要合取项恒不成立，持续性条件永远不会触发，该会遇因而始终不被识别为让路态。我们在一组这样的真冲突算例上实测。仅用持续性入口时让路态决策步为 0，补上即时支之后为 201 步。该测量取自合成的对抗算例，用于说明机制差异，不与主结果表并列。

4.3.5 训练配置

训练超参见表 2。除熵正则系数（取 0.01）与有界动作分布外，其余强化学习超参一律取 stable-baselines3 2.3.2 的默认值、未作调整，其具体数值已列入表 2；离散与连续两类配置在这些值上逐项相同，故超参不构成两类配置之间的差异来源。观测与回报的滑动归一化不是可选项，不做时式 (15) 中大尺度的趋近项会把策略推向“原地停船”的退化解。完整配置另含四项塑形，全部仅作用于连续动作策略，即三项势函数型塑形（进门势、横向进带势、终端保速势）与一项动作增量惩罚，其权重与半径见表 2。动作增量惩罚需明确其形式与作用范围，它惩罚相邻两个决策步之间策略指令的变化量，按策略动作箱各轴的半宽（ a_{op}, ω_{op} ，非物理量程）归一化后取平方和，因此同时作用于加速度轴与转艏轴，而不只作用于转艏；它也不是势函数，不具备势函数型塑形的策略不变性。这四项塑形是一并启用或一并关闭的，本文未逐项拆开做消融，因此关于它们的结论只能表述为“这一组塑形共同带来多少变化”。又由于其中的动作增量惩罚同时作用于两个控制轴，凡涉及转艏增量、油门增量与 *jerk* 这三项指标的比较，都必须在同样启用该惩罚的两组之间进行，否则差异分不清是控制器带来的还是训练目标带来的。这一点在实验部分再次强调，也限定了后文关于平顺度的全部结论。

4.4 安全性保证与作用域

前几节给出的是机制的构造，本节说明它能够严格保证什么。四条性质按同一格式给出，即陈述、假设、证明要点与作用域，其中作用域一栏写明该性质没有覆盖的情形。全文中“证明”一律指严格引理，存在性级与经验级结论逐条标注。完整推导见补充材料。

性质 1 (远场单步无碰). 设本船与单个他船的中心距为 d 。若

$$d \geq d_{\text{safe}} + v_{\text{obs,max}} \Delta t + \rho_{\text{ego}}, \quad (18)$$

则一个决策步之后，两船以外接圆保守占据必不相交。其中 d_{safe} 为两船外接圆半径之和， ρ_{ego} 为本船单步最大位移。

假设。 单他船，多他船须对每个目标分别满足；他船速度不超过 9.5 m/s，该上界不由式 (1) 约束，须独立给出，我们在全库 2000 个场景、342,000 个障碍状态上实测，最大值为 7.10 m/s；他船在步内恒速。

证明要点。 由三角不等式，步后中心距不小于 d 减去两船各自的单步位移上界，故不小于 d_{safe} ，两外接圆不交，船体亦不交。

TABLE 2 回报函数与训练超参

类别	符号	含义	取值
回报函数	c_{goal}	到达 (正)	+50
	$c_{\text{time}}, c_{\text{area}}$	超时 / 出界	-25, -5
	$c_{\text{stop}}, c_{\text{coll}}$	原地停住 / 碰撞	-40, -50
	c_{em}	每一步紧急控制	-0.5
	$c_{\text{reach}}, c_v, c_{\text{dev}}$	趋近 / 速度 / 偏航	1.5, -2.0, -0.001
	—	塑形权重 (进门/进带/保速/动作增量)	200, 200, 20, 1.0
	—	塑形半径 (进门/进带/保速)	500/80/400 m
强化学习	—	策略/价值网络	多层感知机, 2 层 $\times$ 64
	γ	折扣因子	0.99
	—	熵正则系数 (常数)	0.01
	—	学习率	3×10^{-4}
	—	采样步数 / 批大小	2048 / 64
	—	GAE 折扣 λ	0.95
	—	裁剪范围	0.2

表注。强化学习超参除熵正则系数 (0.01) 外均为 stable-baselines3 2.3.2 (Raffin et al. 2021) 的默认取值、未作调整, 离散 (MaskablePPO) 与连续 (PPO) 两类配置在这些值上逐项相同。塑形四项仅用于连续动作策略; 终端保速势的目标航速取 4 m/s。

- 1 作用域。三角不等式与方向无关, 故对遇即为最坏情形, 几何上没有缺口, 这是可证明
- 2 层中最稳的一条。代入本场景库的常数后阈值约为 764 m。它是单步充分条件, 既非前向
- 3 不变性, 也不覆盖近场; 尚未实现为提前退出的快路径。
- 4 **性质 2** (每一让路步的方向合规), 在被状态机判为让路态势、且投影二次规划可行的每一个
- 5 决策步上, 实际执行的 u_{safe} 必落在式 (4) 所定义的合规方向半平面内。
- 6 假设。单他船; 状态机的态势判定正确。后者继承碰撞可能性谓词的一处已知保守偏差
- 7 , 该谓词以两船中心距为准, 对速度接近的尾随会遇存在漏判区间。
- 8 证明要点。合规半平面以硬区间约束进入二次规划, 投影解必然满足它。该结论由构造
- 9 成立, 不依赖任何额外引理, 因而与训练结果和随机种子无关。
- 10 作用域。不覆盖紧急态, 其判据在结构上旁路合规约束; 不覆盖安全动作集为空而转入
- 11 兜底的步。多他船下若两条他船要求相反的让路一侧, 两个半平面之交为空, 该步只能落
- 12 入兜底并记为一次违规。
- 13 **性质 3** (碰撞不可避的保守判据)。设单个恒速他船, $R_{\text{box}}(t)$ 为本船可达中心的过近似集,
- 14 $O(t)$ 为他船船体矩形。若

$$\exists t^* \in [0, T]: R_{\text{box}}(t^*) \subseteq (O(t^*) \oplus \text{disk}(r_{\text{insc}})), \quad (19)$$

- 15 则碰撞不可避, 任何可行控制序列都会在 t^* 与该他船相撞。

- 16 假设。单个恒速他船; 他船船体尺寸不得高估, 若调用方传入大于真实值的船宽, 判据
- 17 将不再可靠; 判据形如存在性命题, 在有限时域 120 s 上以 241 个等距时刻求值。
- 18 证明要点。三步。其一, 速度矢量变化率有界, 二重积分给出 R_{box} 的纵向与横向半轴,
- 19 故它过近似真可达中心; 其二, 内切圆欠近似船体; 其三, 若可达中心整体落入膨胀后的
- 20 他船占据, 则任何控制都无法避开。

- 1 作用域。该判据是可靠的，即只漏报不误报，但不完备，不触发并不意味着可避。它是
2 末端分类器而非早预警，也不覆盖多障碍与机动他船。验证方面，六路对抗审计在 20,000
3 个随机场景与 735 个精选场景上零假阳，包络硬化后在基准集上追加 1500 例模糊测试仍
4 为零假阳，且判据非空。
- 5 **性质 4** (可清障集的控制不变性，暂定)。称控制序列为状态 s 的已认证逃逸，若它逐步可
6 执行、尾段恒速直行、且沿途与他船的距离经可靠证书判定为不减。记全部具有已认证逃
7 逸的状态之集为可清障集 A_{clr} 。对每个 $s \in A_{\text{clr}}$ ，施加其逃逸序列的首个控制一个决策步
8 后所得 s' 仍属于 A_{clr} 。
- 9 **假设**。单个恒速他船； A_{clr} 为真实可清障集的内近似；证书要求尾段恒速，仅航向不变
10 不足以保证距离函数的凸性。
- 11 **证明要点**。施加首个控制之后，原逃逸序列的其余部分就是同一条已通过证书的物理轨
12 迹的后半段，因而仍是新状态的已认证逃逸。合规版本另需首步落在合规半平面内，该构
13 造在让路后继上成立。
- 14 **作用域**。暂定。 A_{clr} 的控制不变性已证、证书经长时域模糊测试为零假阳、终端约束模
15 块已单测，但把该约束接进部署中的安全盾并在训练所得策略上验证闭环尚未完成。因此
16 本文只声明“已证可清障集不变、并据此设计了终端约束”，不声明“已实现前向不变的安全盾”。
- 17 **关于多他船**。本文的实证范围是双船会遇，故不展开推广，仅指出一点作用域事实。碰
18 撞自由在数学上是对全部他船的合取，故性质 1 与性质 3 这类充分条件按逐目标合取即可
19 保守推广；方向合规不能，原因见性质 2 的作用域一栏。这不是本方法的缺陷，而是
20 COLREGs 自身的边界，该规则集成对制定，对多船冲突并未给出规范。

TABLE 3 可证明安全层：保证、状态与诚实作用域

保证	状态	作用域与限制
远场单步无碰（性质 1）	已证（初等引理；多他船合取不额外保守）	$d \gtrsim 764 \text{ m}$ ；他船恒速； $\forall i$ 合取；每个 $v_{\text{obs}} \leq 9.5 \text{ m/s}$ ；单步，非不变性；尚未实现提前退出
每让路步方向合规（性质 2）	构造式成立（作用域受限）	让路相遇（约 13–16%，探索期场景池实测、相遇级非逐步级）；不含紧急态与兜底；多他船下随 N 下降；方向冲突 $\rightarrow$ 兜底（COLREGs 成对性边界）；合规陈述只到让路步一层
紧急迫近不可避证书（性质 3）	可靠充分条件（ $>20,000$ 对抗场景 0 假阳）	仅迫近；他船恒速； $\exists i$ 可合成、可避性不可合成；不完备、非早预警；是分类器不是系统保证
可清障集 A_{clr} 的控制不变性（性质 4，暂定）	暂定： A_{clr} 的控制不变性已证、证书可靠（长时域模糊 0 假阳）；终端约束模块已单测；闭环集成与官方评估流程复算待补	单恒速他船； A 是内近似；可清障态中合规已认证脱离机动的条件存在率三态均 100%（带盾回放的让路状态，非对抗分布）；唯一缺口是交叉态约 2.9% 的状态本身即不可清障 $\rightarrow$ 兜底（非合规冲突）； $A_{\text{clr}} \cap U_{\text{colregs}}$ 的不变性仅情形 1 已证

表注。性质 1 与性质 3 的数学作用域可按目标逐一合取地推广到多他船（碰撞自由是对全部他船的合取），性质 2 不能（方向要求相反时两个半平面的交为空）。但本文部署的安全盾按单他船实现，遇到多于一艘他船时显式报错，故上述推广未经实现，也没有多他船的实验数据支撑。表中凡提“多他船”一律只指数学作用域。

- 22 综合起来，本文可辩护的核心结论是，在连续控制上同时取得 COLREGs 让路条款
23 的方向合规保证，并配以远场单步无碰的严格结论与紧急迫近不可避的可靠证书。该结论

的作用域限于单个恒速他船、让路态势且投影可行的决策步；紧急态与三支兜底不在其内。上述边界在结论中集中说明。

兜底行为的实证边界。当投影在紧急态不可行时，判据在结构上旁路方向约束，兜底控制器最小化碰撞风险。这是经验兜底，不是保证。在一个专门逼出紧急支的对抗性纯几何基线上，我们观察到的碰撞全部发生在归类为紧急控制的步上，即“最后手段尝试并失败”，且都落在性质 1 的适用域（远场、非紧急、单步）之外。它们不是对头条主张的反例，但坐实了紧急态不是保证。此处按来源分类的碰撞计数留待正式实验重评后填入（见第 5.6 节，【待填】）。

5. Experiments

5.1 场景库与对照配置

场景来源与构成。实验在 CommonOcean 基准 (Krasowski and Althoff 2022) 的双船会遇场景库上进行，共 2000 个场景。每个场景规定受控船的初始位姿与航速、他船的初始状态与其既定航迹、以及受控船的目标区域（含位置门、朝向门与时限）。场景的会遇几何是程序化生成的，覆盖不同的相对方位、航向交角与接近速率；受控船为前述 175 m 级机动船，他船为场景库给定的机动船（船长 200–300 m）。回合上限为 170 个决策步，折合 1700 s。

会遇类型分布。按状态机的几何类型谓词（不含 420 s 碰撞可能性这道闸）对全库分类的结果是，交叉与对遇两类占满全库，追越场景数为零。这一点对本文的作用域有直接影响。式 (4) 中 ρ_4 一支虽已实现并可被单元测试触发，但无法在本场景库上得到实证检验，我们在结论中如实列出。就官方测试集 600 个场景而言，交叉 395 个、对遇 205 个。

划分。场景库的官方划分为训练 1400 / 测试 600。我们把官方训练侧再切为 1300 个训练场景与 100 个验证场景（其中训练侧对遇 468、交叉 832；验证侧对遇 36、交叉 64）。验证集只用于训练期监控与存档选取，测试集在训练与调参全程不被访问。

评估样本量。由于全部训练均在官方 1300 上进行，而该集合与官方测试 600 零交集，测试集上不存在任何被训练过的场景，故评估样本量即为 600。该划分经独立复算核验。训练 $\cap$ 测试 = 0、验证 $\cap$ 测试 = 0、训练 $\cup$ 验证 = 官方训练 1400、训练 $\cap$ 验证 = 0。

本文此前的探索性实验使用过一个较小的场景子集，其训练场景与官方测试集有交集、须剔除后才能统计，因而样本量与此处不同。两套样本量下的数值不可放入同一张表；正文如需引用探索期结论，会标明其来源。

5.1.1 九种配置与八级单变量递进序列

表 4 列出九种配置。它们构成一条连通的单变量递进序列。相邻两级之间只改动一个变量，因此每一个机制的贡献都能单独读出来。

⑤⑥这对配置的适用条件。无盾的连续动作配置只能采用极简配置（无界高斯 / 非对称让路入口 / 零塑形），因为让无盾配置启用连续专属塑形会造成相对离散无盾基线的不对称，使归因失效。而无界高斯正是那个会把大量采样推到动作箱边界之外的形态。在探索期的四配置重评上（小规模场景池，非本文正式实验的评估设置），我们实测无界高斯策略有约 73% 的决策步紧贴动作箱边界。因此，“安全盾在连续动作空间中带来多少收益”这一倍数，是在连续动作最差的形态下测得的。同理，③ $\rightarrow$ ⑤所反映的“把动作空间由离散换为连续本身带来多少收益”可能为负；该值应视为一个保守的下界。

TABLE 4 九种配置的配置与单变量递进序列

#	配置	动作空间	合规施加方式	塑形	分布	让路入口	相对上一级只改
①	完整方法	连续	投影盾	全	Beta	对称	由⑧或⑨各补一项
②	离散 + 屏蔽	离散	动作屏蔽 + 软奖励	零	—	原设定	动作屏蔽（相对④）
③	离散基线	离散	无	零	—	—	—（序列的根）
④	离散 + 软奖励	离散	软性合规项	零	—	—	软性合规项（相对③）
⑤	连续无盾	连续	无	零	高斯	原设定	动作空间（相对③）
⑥	连续有盾	连续	投影盾	零	高斯	原设定	安全盾（相对⑤）
⑦	消融基准	连续	投影盾	全	高斯	原设定	连续专属塑形（相对⑥）
⑧	消融。仅有界分布	连续	投影盾	全	Beta	原设定	动作分布（相对⑦）
⑨	消融。仅对称入口	连续	投影盾	全	高斯	对称	让路入口（相对⑦）

表注。 (1) ③ → ⑤这一级不是纯单变量。环境层与奖励层完全一致（逐值比对差为0），两个算法的默认超参也已逐字核对、完全相同；但算法类（带屏蔽的 PPO vs. 普通 PPO）、策略族（49 类别分布 vs. 2 维连续分布）、熵系数的语义（离散熵与微分熵不是同一个量）三者是“换动作空间”不可分割的伴随。故这一级只能理解为“动作空间及其必然伴随的改动共同带来多少收益”。(2) ⑥ → ⑦的“连续专属塑形”是 4 件一起开的捆绑包（进门势 / 横向往进带势 / 终端保速势 / 动作增量惩罚（两轴）），本次没有逐件拆开，因此只能写“这套组合贡献了 X”。(3) ⑦ → ⑧换分布带一个必然伴随。两种分布的初始探索尺度在加速度轴上差约 2.5 倍。高斯的初始标准差是一个由较窄的转艏轴动作箱派生的标量（ $\sigma \approx 0.009$ ），两轴共用；加速度轴箱宽是转艏轴的 2.67 倍，故高斯在加速度轴上相对更窄（ $\sigma / \text{半宽} = 0.19$ vs. 转艏轴 0.50）；Beta 的初始形状按箱宽相对定义（ $\approx 0.48 \times \text{半宽}$ ，两轴相同）。这是换分布的必然伴随，不是集成错误。不存在“既换分布又保持初始探索尺度不变”的写法，因为高斯的尺度是绝对的、Beta 的是相对的。

1 5.2 评价指标与实验方案

COLREGs 违规的计数规则。 违规数不是由安全盾的态势判定给出的，而是由一个独立于安全盾的离线评分器给出，该评分器与安全盾相互独立。评分器只看轨迹。对每一步用裸的态势谓词重新判定本船处于直航还是让路义务下，然后按两条规则计数。直航违规按步计。在一段连续的直航义务期内逐步重判，取该期内的带符号累积航向变化，某一步的累积量绝对值达到 $\Delta_{nt} = 10^\circ$ 即该步记一次（因此本船回正航向、把累积量拉回阈值以下的那些步不计）；直航义务解除时累积量清零。让路违规按会遇计。若一次让路会遇从触发到解除的全程都没有出现达到 $\Delta_{lt} = 20^\circ$ 的规定方向转向，则该次相遇记一次。两者相加即每局违规数。因为评分器独立于安全盾，它对本文方法与对全部基线（包括不含状态机的几何控制器）使用同一套判据，可直接比较。需要补充一处实现事实。评分器与安全盾虽共用同一组阈值取值（ $\Delta_{nt} = 10^\circ$ 、 $\Delta_{lt} = 20^\circ$ ），但二者在实现中各自持有一份常量定义，而非引用同一处。本文统计时两份取值一致。

直航约束与该计数规则之间的一处结构性错配。 式 (4) 中直航态的容差取 $\varepsilon_\omega = \Delta_{nt}/T_M = 0.004363 \text{ rad/s}$ ，即它约束的是单个 $T_M = 40 \text{ s}$ 窗内的航向变化不超过 10° 。而评分器累积的是整段直航义务期，该期可以远长于 T_M 。在容差上界处每个决策步累积 2.5° ，故连续 4 步之后累积量即达阈值。由于安全盾的容差带是闭的（允许恰取 $\pm \varepsilon_\omega$ ），而评分器在累积量达到 Δ_{nt} 时即计违规，两者的判定规则在单个 T_M 窗的闭边界上就已经不一致。一段达到 40 s 的直航期，即使每一步都落在安全盾的约束内，也可能被记为违规。

非零直航违规的三个来源。 上述容差错配只是其中之一，且不是最主要的一个。更基础的一层是义务窗与约束窗并不重合。评分器按裸态势谓词逐帧判定直航义务，而安全盾只在状态机判为 ρ_1 的决策步上施加 $\{|a| \leq \varepsilon_a\} \cap \{|\omega| \leq \varepsilon_\omega\}$ 。两者在两处系统性地错开。其一，紧急判据在状态机中优先于一切态势。一旦触发，该步的态势即为 ρ_5 ，安全

盾不施加任何航向约束，而评分器的直航义务谓词不含任何紧急豁免，仍按义务计数。其二， ρ_1 下安全动作集为空时，“放松”与“碰撞风险最小化”两支兜底在执行器物理量程上求解并整块丢弃合规约束，转艏率可达 $\omega_{\max}$ ，单步航向变化即达 17.2° ，一步便越过 10° 阈值。此外，状态机的态势具有路径依赖（进入 ρ_5 后须满足独立的解除条件才退出），而评分器的谓词是逐帧瞬时的，这使两者的窗口边界进一步错开。

因此安全盾在结构上并不保证直航违规为零，本文也不作此主张。让路一侧存在同类的结构性错配，且方向相反，此处一并声明。安全盾施加的是逐决策步的转艏率下界约束 $\omega \leq -\omega_{\text{turn}}$ ，而评分器判定的是一次让路义务期内累积的航向变化是否达到 Δ_{lt} 。若某次让路会遇的持续时长短于机动段时长 T_M ，则该会遇的每一个决策步都满足硬约束、而整段累积转向仍可能不足 Δ_{lt} ，按评分器规则记为一次违规。因此性质 2 保证的是每一让路步的转向方向，并不蕴含让路违规计数为零。该错配在本文报数中的实际发生频率未作测量。需要区分的是，容差侧的错配原则上可以消除，评分器累积的是带符号航向变化且义务期结束即清零，故可把固定的 ε_ω 换成累积预算式约束 $\omega \in [(-\Delta_{\text{nt}} - c)/\Delta t, (\Delta_{\text{nt}} - c)/\Delta t]$ （ c 为本期已累积量），该区间恒含 $\omega = 0$ 故永不为空、仍是逐轴区间故投影仍精确、且不会随期长把容差压到零；本文未采用该写法，因为正式实验的训练配置在统计前已冻结。真正不能由改约束消除的，是上述义务窗与约束窗的不重合，那是评分规则与安全盾作用域之间的边界。

主指标沿用 (Krasowski and Althoff 2024) 的定义，以保证可比。到达率、碰撞率、每局 COLREGs 违规数、紧急控制步占比、每局时长；违规数进一步拆成让路违规与直航违规。控制质量。转艏增量（分总计 / 让路步 / 其他步）、油门增量、jerk、控制努力、次网格细调率、速度反转次数。安全裕度。最近点中心距 / 净空 / 发生时刻、最近点处航向误差与速度。盾的行为，介入步数、兜底触发率、投影修正量（均值 / p95 / 最大 / 零修正比例）。分型。按会遇类型拆全部指标、失败原因分型。实时性。单步求解耗时，分盾 / 策略 / 整步三层。

采集边界（决定了图能怎么画）。训练期每 507,904 步记录验证曲线；每个 rollout（16,384 步）记录策略与值函数损失、熵、KL、裁剪比例、可解释方差、每局回报，以及动作饱和率、舵反转率、盾介入率、盾改写量等行为量（转艏与加速度两轴分开记，盾改写量按箱半宽归一化后再合成，不做量纲直加）。训练期没有违规曲线。违规计数只在评估侧集成，因此违规只有那 20 个评估点。另外，各配置的奖励函数不同，每局回报不可跨配置比较。

5.2.1 训练预算、种子与算力

每条 run 从零端到端训练 **10,158,080 步**（20 段 $\times$ 507,904），不用热启动；分段存档全程开（每段留一份，因此 20 个存档候选）；训练期评估用那 100 个验证场景，曲线即验证曲线。每条 run 用 8 个并行环境。

种子集合 = $\{0, 1, 2, 3, 4, 5, 8, 9\}$ ，共 8 颗互不相同的随机初始化。编号不连续是运行期机器重排造成的（每台机器沿用其已开工的种子号，以免留下无人接管的半截存档），种子号本身只是随机初始化的标签，不含大小或顺序含义；场景的训练与测试划分由另一个固定种子决定，与此处的 run 种子无关，故 8 颗种子看到的是同一批场景。种子取值预先固定并原样报告，逐种子原始值随主表给出。分机器的依据是种子而非配置。同种子配对比较是本文的主统计工具，因此同一颗种子下的全部配置必须落在同一台机器内，否则“机器”会成为混淆变量。评估另说。一张报数表里每种配置必须同一台机器、同一轮内评完。

报数预算取所有 run 都达到的最小段数，同一张表全部配置同一个值，并报实际步

1 数而非名义值。

2 **运行环境。**全部训练与评估在服务器 CPU 上完成，未使用 GPU。单机 32 个
3 vCPU（AMD EPYC 7T83，64 核处理器），内存 60 GB。不使用 GPU 是因为本文策略
4 网络仅两层各 64 个神经元，其前向与反向的算术量远小于数据在主机与显存间往返的开
5 销；真正占用算力的是环境仿真与每步的二次规划求解，二者均在 CPU 上执行。据此，
6 每台机器的并发路数按内存上界而非核数确定。单条训练的常驻内存约 6 GB，故每台并
7 发 6 路（约占内存的 60%），余量用于覆盖启动期与段末评估的瞬时峰值。这一配置同
8 时说明本方法的算力门槛不高，便于在不具备加速硬件的条件下复现。

9 **单步求解耗时的测量方式。**我们上报的单步求解耗时是单线程 CPU 墙钟，随机器
10 而变，须连同上述处理器型号与线程设置一并阅读；比较时看尾部分位（p95 与 p99）而
11 非均值。他船不在感知窗内的决策步会短路、不进入二次规划，这些步不计入耗时分布，
12 否则大量零值会稀释尾部。

13 5.2.2 存档选取与报数

14 选取规则先定死、不带任何可调参数。其中候选 = 全部 20 段；单一指标 = 验证集
15 到达率，取最高；平局取更早的段。存档选取只使用验证集，不接触测试集；所有配置一
16 视同仁。

17 必须两版都报。验证集 $N = 100$ ，到达率的二项标准误约 4 个点；在 20 个候选里
18 取最大值，期望上抬约 7.5 个点，比我们专门立规矩去防的跨轮次抖动（约 1.6 个百分点
19 ）还大 4 倍多。故最佳存档一轮 + 末段存档一轮，两版都报并量化交代这个偏倚。

20 5.2.3 统计方法

21 主检验 = 同种子配对符号检验。8 颗种子时双侧最小可达 $p = 2/2^8 = 0.0078$ ，足
22 以支撑“统计上可辨”的结论。区间 = 按种子重采样的自助法 95% 区间；碰撞用 Fisher
23 精确检验（碰撞是稀有事件，正态近似不适用）。全部自算，不调统计库，脚本随论文给
24 出。

25 我们预先声明一条回退规则。若最终收敛种子数降至 3–4 颗，主检验改为按测试场
26 景配对（每种配置在每个测试场景上的逐局明细， $N = 600$ ），逐种子那一版降级为稳健
27 性检查；换检验的唯一理由是算力受限，且逐场景配对不能替代逐种子回答训练可靠性这
28 一问题，后者只能靠种子数， n 小即如实报告 n 小。

29 “收敛种子数”这一列附判据定义。其中达标 = 严格到达率 $\geq 50\%$ ；发散（陷入
30 原地打转）= 到达 $< 50\%$ 且末段每局时长 ≥ 1360 s（ $= 0.8 \times$ 回合上限）；训练不足 =
31 到达 $< 50\%$ 且末段每局时长 < 1360 s。并报过渡带（1100–1600 s）的条数，该区间内的
32 归类本身不确定。（全库 100 条低到达 run 的实证。发散组落在 [1377, 1700]、训练不足
33 组落在 [567, 1354]，阈值处不重叠，12% 落在过渡带。）

34 5.3 主对照实验

35 表 5 另报“仅计收敛种子”的版本。发散种子会污染逐局平均，且污染方向因配置
36 而异，故两版并报，关键差值为【待填】。逐种子原始值随表给出。

37 5.4 消融实验

38 四条消融配置构成完整的 2×2 （有界分布 $\times$ 让路入口），其余配置逐字相同、同
39 种子配对。定量结果见图 3。换有界分布把转艏增量降到【待填】（配对符号检验 $p =$ 【

TABLE 5 主表：九种配置在官方测试集上的同条件对照（最佳存档轮·全部种子）

配置	n	达标	到达% [CI]	碰撞%	违规/局	转舵 Δ	油门 Δ	紧急%
①本文方法	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
②离散-有盾	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
③基线	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
④软奖励	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑤连续-无盾	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑥连续-有盾	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑦消融·都不改	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑧消融·只 Beta	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】
⑨消融·只对称	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】

表注。官方测试集 600 个场景（与训练集零交集）。训练预算 10,158,080 步，用 100 个验证场景选最佳存档，全部配置同一规则。到达判据 = 官方 `is_reached`（位置 + 朝向 $\pm 9.74^\circ$ + 时限）。区间 = 按种子重采样的自助法 95% 区间；碰撞用 Fisher 精确检验。“达标”判据见第 5.2.3 节。⑤⑥使用极简配置（无界高斯 / 非对称让路入口 / 零塑形）；该配置是无盾连续动作配置唯一合法的形态，故由⑤⑥得到的安全盾的收益是在连续动作最差形态下测得的。转舵增量、油门增量与 `jerk` 三列均不可跨动作空间解读为控制更平顺。连续动作配置训练时开着直接惩罚控制增量的罚项，且该罚项同时作用于两个轴，离散动作配置结构上没有；相关比较见图 3。碰撞如实报，与对标的差异按 Fisher 检验陈述，不写“零碰撞”。

1 待填】），换让路入口把每局让路违规降到【待填】（ $p = \text{【待填】}$ ），两项改进同开
2 为【待填】。转舵平顺度唯一站得住的读法就在这组对照里。四种配置开着同一个动作
3 增量惩罚，因此“⑧比⑦平顺 N 倍”只能归因于有界动作分布，而不是额外的奖励项；
4 跨配置与离散基线比较结构上不成立（我们罚了那个量、离散动作配置拿不到）。⑦ →
5 ⑧这一级的不可分割伴随（初始探索尺度在加速度轴上差约 2.5 倍）见表 4 表注 (3)。按
6 第 5.2.3 节，本组同样给出“仅收敛种子”一版。

7 5.5 训练可靠性与样本效率

8 5.6 安全盾行为

9 紧急通道是本方法唯一不提供保证的一支，因此需要单独刻画它被用到的频率与后
10 果。紧急控制步占全部决策步的【待填】； $\rho_0\text{--}\rho_4$ 上的三支兜底（放松、碰撞风险最小
11 化、退化）合计触发率为【待填】。碰撞按控制来源分类的分布为【待填】。若碰撞全
12 部落在紧急控制一类，则说明碰撞发生在“最后手段已被启用并失败”的步上，而这些步
13 按定义落在性质 1 的适用域（远场、非紧急、单步）之外，这不构成对性质 1 的反例，但
14 坐实了紧急态只是经验兜底。投影修正量的分布（均值 / 第 95 百分位 / 最大值 / 零修正比
15 例）为【待填】，它度量策略输出与规则要求之间的差距。

16 5.7 外部基线对照

17 我们把三条不需要训练的几何避碰控制器放在同一评估管线、同一测试集与同一样
18 本量下运行，作为与学习无关的参照（表 6）。这一组对照的作用不是证明学习方法更强
19 ，而是回答一个更基本的问题。本文所报的差异中，哪些维度上几何方法本来就够用。
20 结果把可辩护的主张收窄到一个维度。控制障碍函数滤波器在本测试集上的碰撞率
21 为 0.00%，即在碰撞这一维度上它与本文方法打平；因此碰撞率不是能区分两类方法的指
22 标。到达率一列同样不能直接使用。几何控制器的标称控制律不含终端对准环节，其位置

【图 2（安全—效率权衡图。到达率 $\times$ 违规，内嵌到达率 $\times$ 碰撞率）占位——数据到手后替换】

Figure 2 安全—效率权衡。横轴为到达率，纵轴为每局 COLREGs 违规数（对数轴），每个标记为一种配置，误差棒为按种子重采样的自助法 95% 区间；左上角为理想区。内嵌小图纵轴换为碰撞率。形状编码：圆 = 连续动作、三角 = 离散动作、方块 = 外部几何基线；实心为带盾（投影盾或动作屏蔽），空心为无盾。离散动作屏蔽为获得合规性付出的代价，与连续投影所付代价之比为【待填】。外部基线的到达率须按第 5.7 节的限定阅读。

1 命中率达 96.8%–99.7%，却卡在终端朝向门之外，这一列反映的是终端约束的类型差异
 2 。平顺度一列则明确不利于本文。物理满量程档的转艏增量低至 0.00032–0.00058，这是
 3 手工调参的几何控制器所能达到的量级；本文与之的比值待数据到手后填入（【待填】）
 4 ，且无论结果如何都不作平顺度优势的主张。
 5 真正的差别在 COLREGs 违规，且集中在一个具体成因上。三条基线的违规几乎全
 6 部是直航违规，控制障碍函数 4.49 次中的 4.04 次、PD 控制器 9.79 次中的 9.35 次、速度
 7 障碍 8.20 次中的 7.70 次（表 6）。这些控制器只以“不碰”为目标，因此在规则要求保
 8 向保速的时段里仍在持续机动。这与第 5.2 节给出的计数规则一致。违规由独立评分器按
 9 裸态势谓词判定，与是否装有安全盾无关，因此这一比较是同条件的。本文的对照结论只
 10 能落在这一维度上。【待填】。

11 6. Discussion

12 6.1 从统计性合规到逐步合规

13 软奖励只能影响策略的期望行为，不能排除任何一个具体动作，而屏蔽与投影都能
 14 ，区别在于屏蔽需要一个可枚举的动作集合。本文的结论是，在连续动作空间里，“可枚
 15 举”这一前提可以用“可投影”替代。合规方向恰好是一个半平面，投影到半平面与箱的
 16 交集上是一个小规模二次规划，实测单步耗时【待填】。

17 6.2 连续动作的收益边界

18 可以确定的收益在合规转向的精细度上，连续动作能精确取到 ω_{turn} 这一下确界，
 19 而本文所复现的 7×7 网格只能取到高出 37.5% 的档位。这一条纯由该网格的分辨率决定
 20 、与训练无关，更细的网格可缩小该差距。油门轴的分辨率差异（离散只有 7 档）同样是

TABLE 6 外部几何基线对照（不训练、无种子；官方测试集 $N = 600$ ）

方法	控制量程	到达%	碰撞%	COLREGs 违规 / 局			转艏 Δ	jerk
				合计	让路	直航		
控制障碍函数	策略量程	70.17	0.00	4.95	0.47	4.48	0.00242	0.171
	同上 + 裕度	69.83	0.00	4.49	0.45	4.04	0.00235	0.167
	物理满量程	69.33	0.00	6.48	0.52	5.97	0.00058	0.050
PD 控制器	策略量程	58.83	18.00	9.79	0.44	9.35	0.00492	0.310
	物理满量程	57.67	16.67	8.10	0.63	7.47	0.00032	0.040
速度障碍	策略量程 + 裕度	57.00	0.00	8.20	0.50	7.70	0.00425	0.279
	物理满量程	42.67	0.00	8.06	0.68	7.38	0.00128	0.071
①本文方法	策略量程	(引表 5)						

表注。（1）三条基线不训练、无随机种子，故不列种子统计；参数按各自最好的配置报，调参用官方训练集另抽的 100 例，与本表的评估集零交集。控制量程两档。“策略量程” = 与本文策略同权限的 $\pm 0.048 / \pm 0.018$ ，“物理满量程” = $\pm 0.24 / \pm 0.03$ ；同时报两档是为了排除“权限差异”这一混淆。（2）到达率不能直接等同于避碰能力。几何控制器的标称律不含终端对准环节，它们的位置命中率达 96.8%–99.7%，却卡在终端朝向门之外，因此该列反映的是终端约束类型的差异。（3）违规数中直航违规占绝大多数（控制障碍函数 4.49 中的 4.04、PD 9.79 中的 9.35）：几何控制器“不撞”的代价是在规则要求保向保速时仍在机动。这是本文相对它们的差别所在，也说明碰撞率不是有效的区分维度，控制障碍函数在本基准上碰撞率为零。（4）平顺度一列不支持任何有利于本文的主张。物理满量程档的转艏增量低至 0.00032–0.00058。与本文的比值待正式实验数据到手后填入（【待填】）；无论结果如何，本文都不作平顺度优势的主张。可辩护的写法只有“平顺度相当，而违规更低”。（5）单局评估耗时（单线程墙钟）。控制障碍函数 0.15 s、PD 0.15 s、速度障碍 0.86 s。（6）三条基线走无盾路径、不推状态机，全部决策步都归在“无冲突”态势下，故本表不给出按态势拆分的转艏增量（让路步 / 其他步的拆分对它们无意义），只报合计；它们的违规数由离线态势评分器给出，与安全盾的态势判定无关，其计数规则见第 5.2 节。

【图3（1×3。转艏增量/让路违规/到达率，同种子配对连线）占位——数据到手后替换】

Figure 3 两项改进的贡献拆解（ 2×2 消融，同种子配对）。横轴为四条消融配置，纵轴分别为转艏增量、每局让路违规与到达率。每个点为一颗种子，细线为同种子配对连线，粗线为中位数，误差棒为按种子重采样的自助法 95% 区间。转艏增量的改善应归因于有界动作分布，而非奖励塑形，四种配置开着同一个动作增量惩罚（不可分割的伴随见表 4 表注 (3)）。

- 1 结构性的，但它不能被直接读成油门增量指标上的优势，因为该指标同时受动作增量惩罚
- 2 影响，而该惩罚只在连续动作配置中启用，因此两种动作空间之间的油门增量差异无法归
- 3 因；可归因的比较只在同样启用该惩罚的连续配置之间成立。到达率一侧则不确定，③
- 4 → ⑤这一级可能为负（表 4 表注 1）。

5 6.3 两项改进为何是连续动作空间特有的

6 量化动作空间不存在动作被裁到箱外的情形，也不存在微分熵无上界的通道。这两

7 个问题是把 COLREGs 安全盾迁入连续动作空间之后才出现的。因此本文的消融不是对两

8 个超参的调节，而是对迁移过程中新出现的两处缺陷的修补。

9 6.4 对自主船舶投入营运的意义

10 把合规做成可投影的硬约束，改变的不只是策略的行为，还有这一层能被如何审查

11 。当合规由训练诱导时，验证只能是统计性的，即在若干场景上抽样、报告违规频次，而

12 结论随策略版本变动；当合规由约束构造成立时，验证对象变成约束本身，即状态机的态

13 势判定是否正确、半平面的方向是否与条款一致、投影是否落在可行集内。这三件事都可

14 以逐步检查，且与训练结果无关。对型式认可与事故复盘而言，后者是更可操作的形态。

15 审查者不需要复现训练过程，只需检查每一个决策步的约束是否被满足。

16 同样值得指出的是，该机制不要求替换既有的控制系统。它接受任意来源的期望控

17 制并输出最近的合规控制，因而可以作为一层独立的合规校验层，叠加在已有的自动舵或

18 路径跟踪控制之上。其在线开销为每步一个两变量、至多六条约束的二次规划，不需要专

19 用加速硬件，这使它在现有船载计算平台上部署是现实的。




Figure 4 样本效率与训练可靠性。全部取自训练期记录，横轴为训练步数。（a）四种主对照配置在 100 个验证场景上的到达率学习曲线（每 507,904 步一个点），实线为跨种子中位数、阴影为四分位距；各条曲线止于该配置最短的那个 run。（b）同种子配对：消融·两项都不改 $\rightarrow$ 本文方法，每条折线一颗种子。（c）到达率达到收敛判据（第 5.2.3 节）的种子数随训练步数的变化。（d）值函数可解释方差，用于区分“还在爬”与“已经崩”。曲线未做平滑，仅按训练步数分箱取中位数。注意：本图的到达率为 100 个验证场景上的数值，与表 5 的官方测试集口径不同，不可互相引用。

1 6.5 与控制理论侧安全滤波器的关系

反应式控制障碍函数滤波器在 10 s 零阶保持下没有递归可行性证明。本文的可清障集给出了一条路径（性质 4），但该结论仍为暂定，闭环集成与官方评估流程复算尚未完成，故本文只把它作为设计方向陈述，不作为已兑现的保证。

5 7. Conclusions

COLREGs 的让路条款要求船舶朝规定的一侧转向，这使合规无法用“最终有没有撞上”来验证。既有工作要么以离散动作加屏蔽换取可证的合规，要么以连续控制加软性奖励换取控制精度，两者各自让掉了一样关键的东西。

本文指出这一取舍并非必然。让路条款在控制量平面上恰好构成一个半平面，因此“逐个枚举并屏蔽”这一前提，可以由“向凸集投影”替代。据此我们把投影式安全盾落到海事 COLREGs 的连续控制上，使每一个投影可行的让路步的方向合规由构造成立，不依赖训练结果，也不受随机种子影响；并把该层能提供的保证按强度分档给出，远场单步无碰为严格结论，紧急迫近不可避配以只漏报不误报的证书；在此之上，可清障集的控制




Figure 5 盾的行为随训练演化（连续动作特有的证据），全部取自训练期遥测。（a）本文方法中每一步控制由哪一支产生：常规投影、紧急控制器、以及 $U_{\text{safe}} = \emptyset$ 时的兜底（纵轴为对数刻度）。（b）动作饱和率，转艏轴与加速度轴分开画，把有界分布配置、无界高斯配置与离散动作配置叠在同一张图上。离散网格的 $|\omega|$ 与 $|a|$ 上界恰好等于连续动作箱的半宽，因此两种动作空间共用同一条打满判据、可直接叠图。无界高斯配置的饱和率随训练升至接近全饱和，有界分布配置则始终维持在低位，这是“有界连续动作 vs. 离散 7×7 网格”这一主张的直接证据。（c）投影修正量（按动作箱半宽归一化）随训练的变化。（d）会遇态势占比随训练的变化（纵轴为对数刻度），其中紧急态 ρ_5 的占比是性质 2 作用域的关键数字。本图为训练期采集，与表 5 的评估口径不同。

- 1 不变性给出了一条通往递归可行性的设计路径，其闭环验证列为后续工作。在官方场景库
- 2 上，九种配置构成的八级单变量递进序列把三组机制逐级拆开（【待填】）。
- 3 这一编码方式并不局限于本文所用的规则集与动力学模型。凡是能被写成动作空间
- 4 中凸约束的行为规范，都可以按同一条路径从“可枚举”迁移到“可投影”，这为把成文
- 5 规则接入连续控制的学习系统提供了一条可复用的途径。后续工作包括把后备机动的终端
- 6 约束接进部署中的安全盾并在训练所得策略上验证闭环；把方向合规推广到多他船情形并
- 7 给出冲突消解规则；以及把远场判据实现为 $O(1)$ 的提前退出，进一步压低单步求解耗时
- 8 。
- 9 最后说明本文结论的边界。安全盾提供的保证不包含无碰撞，性质 4 仍为暂定；方
- 10 向合规成立于每一个投影可行的让路步而非每一步，紧急态在结构上旁路该约束，实测每
- 11 局违规数非零（【待填】）。性质 1、3、4 均建立在他船恒速外推之上，机动他船会使
- 12 保证失效，他船速度上界亦为本基准上的经验值（全池最大 7.10 m/s）。到达率与平顺度
- 13 都不作为效能主张，前者若无统计上可辨的优势即如实报为与离散基线相当，后者因动作

【图6（同一场景 × 四种方法的轨迹）占位——数据到手后替换】

Figure 6 同一场景下四种方法的轨迹对比（场景 T-【待填】，种子 s【待填】）。本船轨迹按会遇态势着色（无冲突 / 直航 / 让路 / 紧急），他船轨迹为灰色，圆点间隔 10 s（一个决策步）；虚线圆为性质 1 的远场阈值（约 780 m）。按各方法的实际轨迹标注其在让路段的转向方向与幅度（【待填】）；选图时以能同时呈现“合规让路”与“无碰撞但方向违规”两类结果为准，具体场景与轨迹形态待数据到手后确定。本图是定性插图，不承担任何定量声明；场景为人工挑选，种子集合（s0/s1/s2）在跑之前已声明。

1 增量惩罚只在连续配置中启用而不可跨动作空间归因。少数种子存在训练不稳定（【待填
2 】），这是训练问题而非场景难度。报数上有两个已知偏倚，最佳存档选择偏倚与跨机器
3 跨轮次抖动，故主表两版并报且强制同机同轮评估。规则覆盖上，本文实现第 13–17 条的
4 方向要求与直航保向保速，未实现直航船的自行避碰义务及其时机判定；且追越一支虽已
5 实现并可被单元测试触发，在本场景库上却没有样本，因而未获实证检验。离散基线为对
6 (Krasowski and Althoff 2024) 的重新实现（其海事评估代码未公开），故该配置的种子脆
7 弱性归因于本文的复现而非原作者。

8 Acknowledgements

9 作者感谢 CommonOcean 基准与 (Krasowski and Althoff 2024) 公开的场景库与规则
10 形式化，它们构成本文实验的基础。本文在代码实现、文档整理、参考文献格式整理与稿
11 件起草环节使用了生成式语言模型 Claude（Anthropic）。全部方法设计、评价方式与数
12 据结论均由作者核定并复核，作者对全文内容的准确性负全部责任。

13 Author Contributions

14 研究构思与方法设计：Weiyu Tang、Jie Xue；软件实现与实验执行：Weiyu Tang
15 ；形式化分析与可证明层推导：Weiyu Tang；数据整理与结果分析：Weiyu Tang、
16 Peijie Yang、Qianbing Li；稿件起草：Weiyu Tang；稿件审阅与修改：全体作者；研究
17 监督与经费支持：Jie Xue。全体作者均已审阅并认可本文的最终版本。

Conflict of Interest

作者声明本研究、署名及发表不存在潜在利益冲突。

Funding

【待填】

References

- Alshiekh, Mohammed, Roderick Bloem, Rüdiger Ehlers, Bettina Könighofer, Scott Niekum, and Ufuk Topcu. 2018. “ Safe Reinforcement Learning via Shielding. ” In *Proceedings of the AAAI Conference on Artificial Intelligence*.
- Ames, Aaron D., Samuel Coogan, Magnus Egerstedt, Gennaro Notomista, Koushil Sreenath, and Paulo Tabuada. 2019. “ Control Barrier Functions: Theory and Applications. ” In *European Control Conference (ECC)*, 3420–3431.
- Benjamin, Michael R., John J. Leonard, Joseph A. Curcio, and Paul M. Newman. 2006. “ A Method for Protocol-Based Collision Avoidance Between Autonomous Marine Surface Craft. ” *Journal of Field Robotics* 23 (5): 333–346.
- Cheng, Yin, and Weidong Zhang. 2018. “ Concise Deep Reinforcement Learning Obstacle Avoidance for Underactuated Unmanned Marine Vessels. ” *Neurocomputing* 272: 63–73.
- Chou, Po-Wei, Daniel Maturana, and Sebastian Scherer. 2017. “ Improving Stochastic Policy Gradients in Continuous Control with Deep Reinforcement Learning Using the Beta Distribution. ” In *Proceedings of the International Conference on Machine Learning (ICML)*.
- Chun, D.-H., M.-I. Roh, H.-W. Lee, J. Ha, and D. Yu. 2021. “ Deep Reinforcement Learning-Based Collision Avoidance for an Autonomous Ship. ” *Ocean Engineering* 234: 109216.
- Dalal, Gal, Krishnamurthy Dvijotham, Matej Vecerik, Todd Hester, Cosmin Paduraru, and Yuval Tassa. 2018. “ Safe Exploration in Continuous Action Spaces. ” arXiv:1801.08757.
- De Lellis, Francesco, Marco Coraggio, Giovanni Russo, Mirco Musolesi, and Mario di Bernardo. 2024. “ Guaranteeing Control Requirements via Reward Shaping in Reinforcement Learning. ” *IEEE Transactions on Control Systems Technology*. arXiv:2311.10026.
- Eriksen, Bjørn-Olav H., Morten Breivik, Erik F. Wilthil, Andreas L. Flåten, and Edmund F. Brekke. 2019. “ The Branching-Course Model Predictive Control Algorithm for Maritime Collision Avoidance. ” *Journal of Field Robotics* 36.
- Fossen, Thor I. 2011. *Handbook of Marine Craft Hydrodynamics and Motion Control*. Chichester: John Wiley & Sons.
- García, Javier, and Fernando Fernández. 2015. “ A Comprehensive Survey on Safe Reinforcement Learning. ” *Journal of Machine Learning Research* 16: 1437–1480.
- Grover, Jaskaran, Changliu Liu, and Katia Sycara. 2023. “ The Before, During, and After of Multi-Robot Deadlock. ” *International Journal of Robotics Research*. arXiv:2206.01781.

- 1 Heiberg, Amalie, Thomas Nakken Larsen, Eivind Meyer, Adil Rasheed, Omer San, and Damiano
2 Varagnolo. 2022. “Risk-Based Implementation of COLREGs for Autonomous Sur-
3 face Vehicles Using Deep Reinforcement Learning.” *Neural Networks* 152: 17–33.
4 arXiv:2112.00115.
- 5 Huang, Yamin, Linying Chen, and P. H. A. J. van Gelder. 2019. “Generalized Velocity Obsta-
6 cle Algorithm for Preventing Ship Collisions at Sea.” *Ocean Engineering* 173: 142–
7 156.
- 8 International Maritime Organization (IMO). 1972. *Convention on the International Regulations*
9 *for Preventing Collisions at Sea (COLREGs)*. London: IMO.
- 10 Johansen, Tor A., Tristan Perez, and Andrea Cristofaro. 2016. “Ship Collision Avoidance and
11 COLREGS Compliance Using Simulation-Based Control Behavior Selection with Predic-
12 tive Hazard Assessment.” *IEEE Transactions on Intelligent Transportation Systems* 17
13 (12): 3407–3422.
- 14 Kim, Kyungmin, Davide Corsi, Andoni Rodríguez, JB Lanier, Benjamí Parellada, Pierre Baldi,
15 César Sánchez, and Roy Fox. 2024. “Realizable Continuous-Space Shields for Safe
16 Reinforcement Learning.” arXiv:2410.02038.
- 17 Kochdumper, Niklas, Hanna Krasowski, Xiao Wang, Stanley Bak, and Matthias Althoff. 2023.
18 “Provably Safe Reinforcement Learning via Action Projection Using Reachability
19 Analysis and Polynomial Zonotopes.” *IEEE Open Journal of Control Systems* 2.
- 20 Krasowski, Hanna, and Matthias Althoff. 2021. “Temporal Logic Formalization of Marine
21 Traffic Rules.” In *Proceedings of the IEEE Intelligent Vehicles Symposium (IV)*, 186–
22 192. DOI: 10.1109/IV48863.2021.9575685.
- 23 Krasowski, Hanna, and Matthias Althoff. 2022. “CommonOcean: Composable Bench-
24 marks for Motion Planning on Oceans.” In *Proceedings of the IEEE Interna-*
25 *tional Conference on Intelligent Transportation Systems (ITSC)*, 1676–1682. DOI:
26 10.1109/ITSC55140.2022.9921925.
- 27 Krasowski, Hanna, and Matthias Althoff. 2024. “Provable Traffic Rule Compliance in Safe
28 Reinforcement Learning on the Open Sea.” *IEEE Transactions on Intelligent Vehicles* 9
29 (12): 7617–7634. arXiv:2402.08502.
- 30 Krasowski, Hanna, Jakob Thumm, Marlon Müller, Lukas Schäfer, Xiao Wang, and Matthias Al-
31 thoff. 2023. “Provably Safe Reinforcement Learning: Conceptual Analysis, Survey,
32 and Benchmarking.” *Transactions on Machine Learning Research*. arXiv:2205.06750.
- 33 Kufoalor, D. K. M., Tor A. Johansen, Edmund F. Brekke, A. Hepsø, and K. Trnka. 2020. “Au-
34 tonomous Maritime Collision Avoidance: Field Verification of Autonomous Surface Ve-
35 hicle Behavior in Challenging Scenarios.” *Journal of Field Robotics* 37.
- 36 Kuwata, Yoshiaki, Michael T. Wolf, Dimitri Zarghitsky, and Terrance L. Huntsberger. 2014. “
37 Safe Maritime Autonomous Navigation with COLREGS, Using Velocity Obstacles.”
38 *IEEE Journal of Oceanic Engineering* 39 (1): 110–119.
- 39 Lee, Changyu, Jinwook Park, and Jinwhan Kim. 2025. “Efficient COLREGs-Compliant
40 Collision Avoidance Using Turning Circle-Based Control Barrier Function.”
41 arXiv:2504.19247.
- 42 Markgraf, Hannah, Shambhuraj Sawant, Hanna Krasowski, Lukas Schäfer, Sébastien Gros, and
43 Matthias Althoff. 2026. “Safe Reinforcement Learning Using Action Projection: Safe-
44 guard the Policy or the Environment?” *Transactions on Machine Learning Research*.
45 arXiv:2509.12833.

- 1 Meyer, Eivind, Amalie Heiberg, Adil Rasheed, and Omer San. 2020. “COLREG-Compliant
2 Collision Avoidance for Unmanned Surface Vehicle Using Deep Reinforcement Learning.
3 ” *IEEE Access* 8. arXiv:2006.09540.
- 4 Müller, Henrik, and Daniel Kudenko. 2025. “Improving the Effectiveness of Potential-Based
5 Reward Shaping in Reinforcement Learning.” In *Proceedings of the International Con-
6 ference on Autonomous Agents and Multiagent Systems (AAMAS)*. arXiv:2502.01307.
- 7 Müller, Marlon, Florian Finkeldei, Hanna Krasowski, Murat Arcak, and Matthias Althoff. 2026.
8 “Falsification-Driven Reinforcement Learning for Maritime Motion Planning.”
9 *Ocean Engineering* 361: 125579. arXiv:2510.06970.
- 10 Ng, Andrew Y., Daishi Harada, and Stuart Russell. 1999. “Policy Invariance Under Reward
11 Transformations: Theory and Application to Reward Shaping.” In *Proceedings of the
12 International Conference on Machine Learning (ICML)*, 278–287.
- 13 Oh, Donggeon David, Duy P. Nguyen, Haimin Hu, and Jaime F. Fisac. 2025. “Provably Opti-
14 mal Reinforcement Learning under Safety Filtering.” arXiv:2510.18082.
- 15 Patil, Mayur S., Nataraj Sudharsan, Veneela Ammula, Jude Tomdio, Jin Wang, Michael Kei,
16 Sivakumar Rathinam, and Prabhakar R. Pagilla. 2026. “COLREGs Compliant Col-
17 lision Avoidance and Grounding Prevention for Autonomous Marine Navigation.”
18 arXiv:2603.02484.
- 19 Pizarro Bejarano, Federico, Lukas Brunke, and Angela P. Schoellig. 2025. “Safety Filtering
20 While Training: Improving the Performance and Sample Efficiency of Reinforcement
21 Learning Agents.” *IEEE Robotics and Automation Letters*. arXiv:2410.11671.
- 22 Raffin, Antonin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah
23 Dormann. 2021. “Stable-Baselines3: Reliable Reinforcement Learning Implementa-
24 tions.” *Journal of Machine Learning Research* 22 (268): 1–8.
- 25 Sarhadi, Pouria, Wasif Naeem, and Nikolaos Athanasopoulos. 2022. “A Survey of Recent Ma-
26 chine Learning Solutions for Ship Collision Avoidance and Mission Planning.” *IFAC-
27 PapersOnLine*. arXiv:2207.02767.
- 28 Schulman, John, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. 2016. “
29 High-Dimensional Continuous Control Using Generalized Advantage Estimation.” In
30 *International Conference on Learning Representations (ICLR)*.
- 31 Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. 2017. “
32 Proximal Policy Optimization Algorithms.” arXiv:1707.06347.
- 33 Shen, Haiqing, Hirotada Hashimoto, Akihiko Matsuda, Yuuki Taniguchi, Daisuke Terada, and
34 Chen Guo. 2019. “Automatic Collision Avoidance of Multiple Ships Based on Deep
35 Q-Learning.” *Applied Ocean Research* 86: 268–288.
- 36 Trott, Alexander, Stephan Zheng, Caiming Xiong, and Richard Socher. 2019. “Keeping Your
37 Distance: Solving Sparse Reward Tasks Using Self-Balancing Shaped Rewards.” In
38 *Advances in Neural Information Processing Systems (NeurIPS)*.
- 39 Vaaler, Aksel, Svein Jostein Husa, Daniel Menges, Thomas Nakken Larsen, and Adil Rasheed.
40 2024. “Modular Control Architecture for Safe Marine Navigation: Reinforcement
41 Learning and Predictive Safety Filters.” arXiv:2312.01855.
- 42 Wabersich, Kim P., and Melanie N. Zeilinger. 2021. “A Predictive Safety Filter for Learning-
43 Based Control of Constrained Nonlinear Dynamical Systems.” *Automatica* 129:
44 109597.
- 45 Zhao, Luman, and Myung-Il Roh. 2019. “COLREGs-Compliant Multiship Collision Avoid-

- 1 ance Based on Deep Reinforcement Learning. ” *Ocean Engineering* 191: 106436.